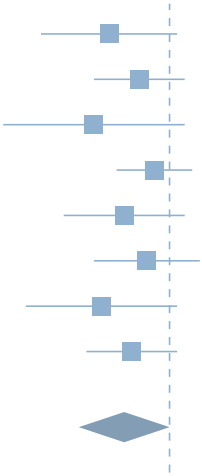
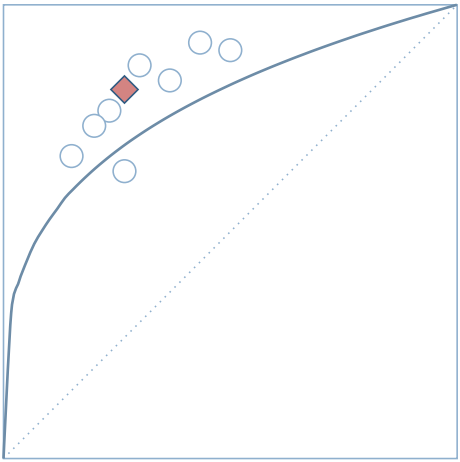
臨床検査技師のための

メタ解析入門

介入の効果から検査の精度まで
R で手を動かす





2026 年 10 月

ダイジェスト 1

介入のメタ解析の手順

メタ解析の手順は、治療や予防などの介入の効果をまとめる方法として整えられてきました。検査のメタ解析も工程はほぼ同じで、主に統計の部分が変わります。そこで、基本になる介入の手順をこのページに、検査で変わるところを次のページに並べました。初めは用語が分からなくても、眺めるだけで構いません。各段階の末尾の括弧は、詳しく書いた章です。

1. **問いを PICO で書く**　対象、介入、比較、アウトカムを一文に書きます。主要アウトカムを一つに決めます（第 2 章）。
2. **解析より先に計画を書いて登録する**　効果指標、モデル、サブグループ、感度分析を決めてから PROSPERO に登録します。結果を見て解析を選ぶと結論が偏るからです（第 2 章）。
3. **複数のデータベースと試験登録を検索する**　同義語を OR、概念どうしを AND でつなぎます。未発表の試験は試験登録で探します（第 3 章）。
4. **2 人で独立に選別する**　抄録で除外し、残りは本文で判断します。除外の理由と件数を PRISMA のフロー図に残します（第 3 章）。
5. **数を抜き出し、バイアスを評価する**　群ごとの事象数と人数を 2 人で抜き出し、RoB 2 で試験ごとに判定します（第 4 章）。
6. **効果を統合する**　リスク比を対数にして、精度の高い試験ほど重く平均します。既定はランダム効果モデル（REML）にして、試験数が少なければ、区間を広めに作る HKSJ 法の区間も並べて比べます（第 5 章）。
7. **ばらつきを読む**　I^2 だけで判断せず、τ^2 と予測区間を見ます。サブグループの差は試験間の比較にすぎないと読みます（第 6 章）。
8. **結果を疑う**　ファネルプロット、バイアスのリスクの高い試験を除いた感度分析を行い、GRADE で確実性を判定します（第 7 章）。
9. **絶対効果に直して報告する**　1000 人あたり何人の差になるかを示し、PRISMA 2020 に沿って書きます（第 7、8 章）。

R での計算は 5.6 節（p. 50）で示します。架空の 10 試験では、リスク比 0.73（95% 信頼区間 0.61〜0.86）、I^2 51%、予測区間 0.46〜1.15 でした。

ダイジェスト 2

検査のメタ解析で変わるところ

工程は前のページとほぼ同じです。大きく違うのは、結果が感度と特異度の 2 つの数で、互いに関係していることです。

1. **問いを 4 つの要素で書く**　対象、対象検査、参照基準、標的疾患を決め、検査を臨床のどこで使うのか（置き換え、トリアージ、追加）を書きます（第 11 章）。
2. **検索にフィルターをかけない**　診断精度研究を確実に拾う検索フィルターはないので、検査名と疾患名だけで探します（第 11 章）。
3. **研究ごとに 2×2 表を作る**　真陽性、偽陽性、偽陰性、真陰性の 4 つの数を抜き出し、カットオフ、測定試薬、検体の違いも記録します（第 12 章）。
4. **QUADAS で評価する**　患者の選び方、対象検査、参照基準、フローとタイミングの 4 領域で評価します。症例対照デザインや一部の人だけの検証は、精度を高く見せます。2026 年に改訂版の QUADAS-3 が出ています（第 12 章）。
5. **カットオフをそろえて統合する**　要約の感度と特異度は、同じカットオフの研究だけで出します。2 つを同時に扱う二変量モデルを使い、カットオフの混ざった研究全体には SROC 曲線を描きます（第 10、13 章）。
6. **ばらつきの原因を探す**　検査のメタ解析ではばらつきが大きいのが普通です。カットオフ、場面、測定法を共変量にして調べ、予測領域で次の研究がどこに来るかを見ます（第 14 章）。
7. **臨床の言葉にして報告する**　有病割合ごとに 1000 人あたりの真陽性、偽陽性、偽陰性、真陰性を示し、PRISMA-DTA に沿って書きます（第 15 章）。

R での計算は 13.3 節（p. 148）で示します。細菌感染症を見分けるプロカルシトニン（PCT）の架空の 10 研究のうち、カットオフ 0.5 ng/mL の 6 研究では、感度 0.75、特異度 0.76、陽性尤度比 3.1、陰性尤度比 0.34 でした。有病割合 10% なら、陽性と出た人のうち菌血症は 4 人に 1 人程度です。

指針の使い分け: 個々の診断精度研究の報告は STARD 2015、検査のメタ解析の報告は PRISMA-DTA、研究ごとのバイアスの評価は QUADAS-2（または QUADAS-3）を使います。

目次

見出しの前の発展の印は、初めて読むときは飛ばしてよい部分です。

第 1 部 メタ解析の基本

第 1 章 メタ解析とは何か 13

- 1.1 一つの試験では答えが出ない理由 13
- 1.2 降圧薬 A の 10 試験 14
- 1.3 統合すると何が分かるか 15
  - 1.3.1 発展 累積メタ解析で結論の動きをたどる 16
- 1.4 メタ解析が答えられないこと 18
- 1.5 系統的レビューの工程 19
- 1.6 この章のまとめ 20

第 2 章 問いを立て、計画を書く 21

- 2.1 問いを PICO に分ける 21
- 2.2 アウトカムの決め方 22
- 2.3 組み入れ基準と除外基準 23
- 2.4 計画を先に書いて登録する 24
- 2.5 解析の計画で先に決めておくこと 25
- 2.6 この章のまとめ 26

第 3 章 文献を探して選ぶ 27

- 3.1 どこを探すか 27
- 3.2 検索式を組み立てる 28
  - 3.2.1 発展 PubMed の検索式の書き方 29
- 3.3 重複を除き、2 人で選別する 29
- 3.4 抄録の選別を練習する 30
- 3.5 選別の経過をフロー図にまとめる 31
- 3.6 この章のまとめ 33

第 4 章 データを取り出し、バイアスを評価する 34

- 4.1 何を取り出すか 34
- 4.2 本文から 2×2 の数を作る 35
- 4.3 バイアスのリスクを評価する 36
- 4.4 抽出したデータを R に読み込む 40
- 4.5 この章のまとめ 41

第 5 章 効果を統合する 42

- 5.1 計算の前に知っておくこと 42
  - 5.1.1 ばらつきを表す量 42
  - 5.1.2 対数と指数 43
  - 5.1.3 重みを分散の逆数にする理由 43
  - 5.1.4 オッズ 44
- 5.2 効果を表す指標 44
- 5.3 重み付き平均という考え方 45
- 5.4 固定効果モデルとランダム効果モデル 46
- 5.5 R で計算する準備 48
- 5.6 metabin で統合する 50
- 5.7 τ^2 の推定法と信頼区間の作り方 52
  - 5.7.1 発展 推定法と区間の作り方の詳細 52
- 5.8 フォレストプロットを読む 53

- 5.9 発展 L'Abbé プロットで両群の発症割合を見る 55
- 5.10 この章のまとめ 57

第 6 章 試験間のばらつきを読む 58

- 6.1 ばらつきを測る三つの数 58
- 6.2 発展 ばらつきの原因になっている試験を探す 60
- 6.3 予測区間と信頼区間 61
  - 6.3.1 発展 予測区間の計算と作図 63
- 6.4 サブグループ解析 64
- 6.5 発展 メタ回帰 67
- 6.6 この章のまとめ 71

第 7 章 結果を疑い、確かさを評価する 72

- 7.1 出版バイアスと小規模研究効果 72
- 7.2 ファネルプロットを読む 73
- 7.3 Egger 検定 74
- 7.4 発展 固定効果とランダム効果の比較、選択モデル、trim and fill 75
- 7.5 未発表の試験を探す 77
- 7.6 感度分析 77
- 7.7 発展 累積メタ解析 79
- 7.8 GRADE で確実性を判定する 80
- 7.9 結果の要約表 82
  - 7.9.1 発展 対照群のリスクを動かした図 83
- 7.10 この章のまとめ 85

第 8 章 メタ解析を報告する 86

- 8.1 PRISMA 2020 の要点 86
- 8.2 方法を書く 87
- 8.3 結果を書く 89
- 8.4 投稿前の確認と公開 90
- 8.5 メタ解析の論文を読むときに見るところ 90
- 8.6 発展 この先に進むときに 91
- 8.7 第 1 部のまとめ 92

第 2 部 検査のメタ解析

第 9 章 検査の精度を表す言葉 95

- 9.1 2×2 表 95
- 9.2 感度と特異度 96
- 9.3 的中割合は有病割合で変わる 97
- 9.4 尤度比と診断オッズ比 98
- 9.5 カットオフを動かすと何が起きるか 99
  - 9.5.1 発展 分布と ROC 曲線を R で描く 103
- 9.6 分析性能と診断精度、基準範囲とカットオフ 104
- 9.7 報告と評価のための指針 105
- 9.8 この章のまとめ 106

第 10 章 検査のメタ解析はどこが違うのか 107

- 10.1 2 つの結果が連動して動く 107
- 10.2 感度と特異度を別々に統合すると何が起きるか 109
- 10.3 感度と特異度を logit の目盛りに直す 110
- 10.4 二変量モデルの考え方 111
  - 10.4.1 発展 二変量モデルの仕組み 111
- 10.5 発展 HSROC モデルとの関係 113
- 10.6 要約点と SROC 曲線のどちらを出すか 114
- 10.7 異質性をどう見るか 115

- 10.8 小規模研究効果の調べ方 116
  - 10.8.1 発展 Egger 検定を使えない理由と Deeks の検定 116
- 10.9 この章のまとめ 117

第 11 章 検査のレビューの問いと文献の選別 118

- 11.1 問いを立てる 118
- 11.2 検索の組み立て 120
- 11.3 抄録の選別の手順 121
- 11.4 抄録の選別の演習 121
- 11.5 演習の答えと判定の理由 122
- 11.6 フロー図 124
- 11.7 この章のまとめ 126

第 12 章 2×2 表を取り出し、バイアスのリスクを評価する 127

- 12.1 抽出フォームの項目 127
- 12.2 本文から 2×2 表を作る 128
- 12.3 抽出で迷う場面 129
- 12.4 QUADAS-2 の 4 つの領域 130
- 12.5 検査の研究に特有のバイアス 131
- 12.6 検査技師の目で読む対象検査 134
- 12.7 QUADAS-2 の演習 135
- 12.8 判定の使い方 137
- 12.9 発展 QUADAS-3 の変更点 138
- 12.10 データを R に読み込む 139
- 12.11 この章のまとめ 140

第 13 章 R で二変量モデルを当てはめる 141

- 13.1 データの準備と研究ごとの精度 141
  - 13.1.1 対のフォレストプロット 143
  - 13.1.2 発展 ROC 平面に研究を置く 144
  - 13.1.3 発展 十字プロット 146
- 13.2 カットオフ 0.5 ng/mL の 6 研究を取り出す 147
- 13.3 glmer() で二変量モデルを当てはめる 147
- 13.4 相関を 0 にしたモデルに単純化する 150
- 13.5 要約点と尤度比 151
- 13.6 要約点と 2 つの領域を図にする 153
  - 13.6.1 発展 図 13.4 を描くコード 154
- 13.7 発展 mada の reitsma() との比較 155
- 13.8 全 10 研究の SROC 曲線 156
- 13.9 発展 実データの AUDIT-C で再現する 157
- 13.10 この章のまとめ 160

第 14 章 ばらつきの原因を探す 161

- 14.1 ばらつきの原因の候補 161
- 14.2 カットオフを共変量にする 162
- 14.3 発展 場面をカットオフで調整して比べる 166
- 14.4 同じカットオフの研究だけでまとめる 168
- 14.5 バイアスのリスクで分ける 170
- 14.6 発展 検査どうしを比べる 172
- 14.7 発展 2 本の Lancet Infect Dis 論文 173
  - 14.7.1 発展 Tang 2007 174
  - 14.7.2 発展 Wacker 2013 174

- 14.7.3 発展 読み比べて分かること 175
- 14.8 既存のメタ解析を読むとき 175
- 14.9 この章のまとめ 176

第 15 章 結果を臨床の言葉にして報告する 177

- 15.1 1000 人あたりの数にする 177
  - 15.1.1 発展 図 15.1 を描くコード 180
  - 15.1.2 有病割合と的中割合 180
  - 15.1.3 発展 検査前確率と検査後確率 181
  - 15.1.4 検査の役割から誤りの重さを決める 183
- 15.2 GRADE で確実性を判定する 184
  - 15.2.1 検査の GRADE で違うところ 184
  - 15.2.2 検査の精度と患者の転帰 185
  - 15.2.3 5 つの領域 185
  - 15.2.4 PCT の例での判定 186
- 15.3 PRISMA-DTA に沿って報告する 188
- 15.4 結果の段落の例文 189
- 15.5 この章のまとめ 190

付録

付録 A R の準備とコードの全文 192

- A.1 R と RStudio の入手 192
- A.2 スクリプト一式をダウンロードする 193
- A.3 作業フォルダを作る 193
- A.4 パッケージのインストール 194
- A.5 スクリプトの実行 195
- A.6 架空データの作成 (010_make_data.R) 196
- A.7 第 1 部の解析 (100_part1.R) 199
- A.8 第 2 部の解析 (200_part2.R) 200
- A.9 動かなかったときに確かめること 203

付録 B 用語集 205

- B.1 英語の用語 205
- B.2 日本語の用語 217
- B.3 ギリシア文字と記号 225

付録 C 参考文献 228

- C.1 教科書 228
- C.2 指針 229
- C.3 方法論 231
- C.4 ソフトウェア 233
- C.5 例題 233

はじめに

この章で分かること

この冊子は、メタ解析をこれから始める臨床検査技師のために書きました。前半で介入の効果を統合する方法を、後半で検査の精度を統合する方法を、架空の例題と実際のデータの両方を使って、R で手を動かしながら説明します。

この冊子が想定している読者

想定している読者は、検査の測定原理、精度管理、基準範囲、カットオフについては日常の業務でよく知っているものの、メタ解析の論文はあまり読んだことがない検査技師です。統計の式は追わなくても読めるように書きました。R はほとんど初めてという前提で、第 A 章（p. 192）と第 5 章（p. 42）で基本の操作から説明します。

検査技師がメタ解析に関わる場面は、検査の精度を調べるときだけではありません。検査部で新しい測定項目を導入するかどうかを決めるとき、医師との共同研究でデータの整理と解析を担当するとき、診療ガイドラインの推奨がどの研究をもとにしているかを確かめるときにも、メタ解析を読む力と自分で計算する力が役に立ちます。第 1 部の例題に降圧薬の臨床試験を選んだのは、介入の効果を統合する考え方が、検査の精度を統合する方法を理解するための前提になるからです。

この冊子の読み方

第 1 部（第 1〜8 章）は、介入の効果を統合するメタ解析を、レビューの工程の順に説明します。問いを立て、文献を探して選び、データを取り出し、統合し、ばらつきを調べ、結果の確かさを評価し、報告するところまでを一通り扱います。第 1 部だけを読んでも、介入のメタ解析を最初から最後まで自分で実行できるように書きました。

第 2 部（第 9〜15 章）は、検査の精度を統合するメタ解析を説明します。第 2 部は第 1 部の第 1〜5 章を読んでいることを前提にしています。検査のメタ解析は、文献の探し方や選び方は介入の場合とほぼ同じで、統計の部分が大きく違います。第 2 部ではその違いを中心に書きました。

各章の頭には「この章で分かること」という囲みを置き、各章の最後の「この章のまとめ」には、その章の要点と覚えておく判断を数行で書きました。時間がないときは、囲みと最後の節だけを拾い読みしても全体の流れがつかめます。

本文の途中にある「(→ 5.1 節（p. 42))」の形の印は、その内容を説明した節と、その節の始まるページを示します。言葉や考え方が分かりにくくなったときは、印の節に戻って読み直してください。途中で読むのをやめても、そこまでに読んだ章の手順はそのまま使えるように、章ごとに話を閉じてあります。

見出しの前や枠の頭に「発展」の印がついた節と枠は、初めて読むときは飛ばして構いません。印のない部分だけを読めば、メタ解析の論文を読む力と、解析者の作業を手伝うときの手順が身につきます。2 回目に読むとき、または自分で解析するときに、印のある部分へ戻ってください。

例題について

この冊子では、2 種類の例題を並べて使います。

架空の例題　第 1 部では、架空の降圧薬 A とプラセボを比べた 10 本のランダム化比較試験を使います。アウトカムは脳卒中の発症です。第 2

部では、発熱のある患者の菌血症をプロカルシトニン（PCT）で診断する精度を調べた、架空の 10 本の研究を使います。

実データの例題　第 1 部では、BCG ワクチンによる結核予防の 13 本の試験（Colditz 1994）を、第 2 部では、飲酒問題を拾い上げる質問票 AUDIT-C の 14 本の研究（Kriston 2008）を使います。どちらも R のパッケージに収められていて、誰でも同じ結果を再現できます。

架空の例題を使うのは、文献の検索から報告までのすべての段階を、同じ例題で通して見せられるからです。実際の論文では、抄録の選別で除外された文献や、本文から数字を取り出す前の記載はふつう公開されません。架空の例題なら、そうした途中の段階も具体的に示せます。著作権の制約を受けずに抄録や本文の抜粋を載せられる利点もあります。

架空の試験と研究には「Aoki 2009」「Kato 2010」のような名前を付けましたが、実在の論文ではありません。架空のデータの数値は、理解しやすいように作ったものであり、降圧薬や PCT の実際の効果や精度を表しているわけではありません。実在の論文を取り上げるときは、その都度、出典を示します。

R とコードについて

本文に載せた R のコードは、そのまま写して実行すると本文と同じ結果が出るように書きました。コードは淡い色の地に左側の青い線で、R の出力は細い枠で囲んで区別しています。

```
library(meta)             # パッケージを読み込む
m <- metabin(ev_t, n_t, ev_c, n_c,
             studlab = study, data = bp, sm = "RR")
```

```
                         RR            95% CI     z  p-value
Random effects model 0.7281 (0.6137 to 0.8637) -3.64   0.0003
```

R の入手、パッケージのインストール、作業用フォルダの作り方は第 A

章（p. 192）にまとめました。コードの全文も付録 A に載せてあります。

言葉の約束

系統的レビュー（システマティックレビュー）は、あらかじめ決めた方法で関連する研究を漏れなく集め、選び、評価する一連の作業を指します。メタ解析は、集めた研究の結果を統計の方法で一つにまとめる計算を指します。メタ解析は系統的レビューの一部として行うのがふつうで、系統的レビューの中にはメタ解析を行わないもの（研究が少なすぎる、研究どうしが違いすぎる場合）もあります。

「率」と「割合」は区別して使います。割合は全体のうちの一部が占める大きさで、分子が分母に含まれます。率は単位時間あたりの変化で、分母に時間が入ります。そのため、ある時点で疾患をもつ人の割合は「有病割合」と書き、感度や特異度も割合として扱います。陽性の結果のうち本当に疾患をもつ人の割合は「陽性的中割合」と書きます。一般には陽性的中率とも呼ばれます。

統計の用語は、初めて出てきたところで説明し、付録 B の用語集にもまとめました。

このあとの章へ

第 2 部でも、重み付き平均（5.3 節（p. 45））、ランダム効果（5.4 節（p. 46））、研究間のばらつき（6.1 節（p. 58））といった第 1 部の考え方をそのまま使います。第 1 章では、一つの試験だけでは答えが出ない理由と、複数の試験を統合すると何が分かるのかを、降圧薬 A の 10 試験を使って説明します。

第 1 部

メタ解析の基本

臨床検査技師のための冊子ですが、第 1 部では検査ではなく、治療や予防などの介入の効果を統合するメタ解析を扱います。メタ解析の基本の手順は介入の研究をまとめる方法として作られ、検査のメタ解析はその手順の一部を変えたものだからです。第 1 部では、この基本の手順を、系統的レビューの工程の順にたどります。第 1 章でメタ解析が何を答え、何を答えられないかを確かめたあと、第 2 章で問いと計画を決め、第 3 章で文献を探して選び、第 4 章で論文から数字を取り出してバイアスのリスクを評価します。第 5 章では R で初めてのメタ解析を実行し、第 6 章で試験間のばらつきを、第 7 章で結果の確かさを調べます。第 8 章では、ここまでの作業を論文の形で報告する方法を説明します。例題は架空の降圧薬 A の 10 試験で、実データとして BCG ワクチンの 13 試験も使います。

第 1 章

メタ解析とは何か

この章で分かること

同じ問いを調べた試験でも、結果は試験ごとにばらつきます。メタ解析は、そうした試験の結果を重みを付けて平均し、一つの試験よりも精度の高い答えを出す方法です。この章では、架空の降圧薬 A の 10 試験を例に、統合すると何が分かるのか、どこで誤るのかを説明し、この冊子全体で使う工程の全体図を示します。

1.1 一つの試験では答えが出ない理由

新しい降圧薬が脳卒中を減らすかどうかを知りたいとします。こうした問いには、ランダム化比較試験（RCT）で答えるのがふつうです。RCT は、参加者をくじ引きのような方法（ランダム化）で 2 つの群に分け、一方に調べたい薬剤を、もう一方にプラセボ（見た目は同じで有効成分を含まない錠剤）を投与して、その後の脳卒中の発症を比べる研究です。ランダム化によって、年齢や持病などの背景が 2 つの群で平均的にそろうので、発症の差を薬剤の作用によるものと考えることができます。

それでも、一つの試験の結果には偶然の揺れが含まれます。150 人ずつ

の小さな試験で、プラセボ群の脳卒中が 17 人、降圧薬群が 7 人だったとしても、同じ試験をもう一度行えば、17 人と 7 人ではなく 14 人と 10 人になるかもしれません。検査の内部精度管理で、同じ管理試料を測っても毎回わずかに違う値が出るのと同じで、標本が小さいほど揺れは大きくなります。

揺れの大きさを示すのが 95% 信頼区間です。脳卒中の起こりやすさを群どうしで割り算した値をリスク比と呼び、リスク比が 1 なら差がなく、1 より小さければ降圧薬群で脳卒中が少ないことを表します。95% 信頼区間は、同じ試験を何度も繰り返して毎回区間を計算したとき、そのおよそ 95% が真の値を含むように作られた区間です。ただし、手元の 1 回の区間に真の値が 95% の確率で入る、という意味ではありません。真の値は決まった一つの値で、区間のほうが試験のたびに動きます。95% は、同じ手順を繰り返したときに区間が真の値を含む割合という、手順の性質を表しています。この区間が 1 をまたいでいれば、その試験だけでは「差がない」可能性を否定できません。

1.2
降圧薬 A の 10 試験

表 1.1 は、この冊子の第 1 部を通して使う架空の 10 試験です。どの試験も高血圧の成人を対象に、降圧薬 A とプラセボを比べ、脳卒中の発症を数えています。対象が高齢者に限られた試験が 5 本、一般の成人を対象にした試験が 5 本あります。

試験	降圧薬 A		プラセボ		リスク比（95% 信頼区間）
	事象	人数	事象	人数	
Aoki 2009	7	150	17	150	0.41（0.18〜0.96）
Berger 2011	48	1200	65	1200	0.74（0.51〜1.06）
Chen 2012	44	420	39	420	1.13（0.75〜1.70）
Dubois 2014	134	2500	145	2500	0.92（0.74〜1.16）
Endo 2015	6	90	12	90	0.50（0.20〜1.27）
Fischer 2016	32	800	38	800	0.84（0.53〜1.33）
Garcia 2018	121	1600	186	1600	0.65（0.52〜0.81）
Hayashi 2019	10	300	23	300	0.43（0.21〜0.90）
Ivanov 2021	112	3000	139	3000	0.81（0.63〜1.03）
Jensen 2022	43	650	83	650	0.52（0.36〜0.74）

表 1.1　架空の降圧薬 A の 10 試験（事象は脳卒中の発症）

10 本のうち、95% 信頼区間が 1 をまたがない試験、つまり単独で統計的に有意な差（偶然だけでは説明しにくい差）を示した試験は、Aoki 2009、Garcia 2018、Hayashi 2019、Jensen 2022 の 4 本だけです。残りの 6 本は区間が 1 をまたいでいて、Chen 2012 にいたっては点推定値が 1.13 と、降圧薬 A の群のほうが脳卒中が多くなっています。

この表だけを見て「有意な試験は 4 本、有意でない試験が 6 本なので、降圧薬 A が脳卒中を減らすかどうかは分からない」と結論するのは誤りです。この数え方は票数え（vote counting）と呼ばれ、メタ解析の教科書がそろって避けるよう勧めている方法です。有意でない試験の多くは、効果がないのではなく、人数が少なくて揺れが大きいために区間が広がり、1 をまたいでいるにすぎません。票数えでは、150 人ずつの試験と 3000 人ずつの試験が同じ 1 票になり、大きな試験のもつ情報が生かされません。

1.3
統合すると何が分かるか

メタ解析では、各試験のリスク比を、試験の精度に応じた重みを付けて平均します。人数が多く事象も多い試験ほど推定が安定しているので、重みを大きくします。重みの付け方は 5.3 節（p. 45）で説明します。

10 試験を統合すると、リスク比は 0.73、95% 信頼区間は 0.61〜0.86 になります。区間は 1 をまたがず、単独の試験よりもずっと狭くなりました。降圧薬 A の群では、脳卒中がプラセボ群のおよそ 4 分の 3 に減っていたと推定できます。プラセボ群で 100 人中 10 人が脳卒中を起こす集団なら、降圧薬 A によって 100 人中およそ 7 人に減る計算です。

10 試験の結果はかなりばらついています。リスク比は 0.41 から 1.13 まで散らばり、その散らばりは偶然の揺れだけで説明するには大きいと判定されました（検定の方法は 6.1 節（p. 58）で説明します）。高齢者の試験と一般の試験で効果が違うのか、試験の質の違いによるのか、それとも別の理由があるのかは、6.4 節（p. 64）で調べます。統合した一つの数字を出して終わりにせず、ばらつきの理由を調べることも、メタ解析の仕事に含まれます。

発展 累積メタ解析で結論の動きをたどる

試験を足していく順序を決めると、統合の結果が積み上がっていく様子が見えます。発表された年の順に 1 試験ずつ足し、足すたびに統合し直す方法を累積メタ解析と呼びます。図 1.1 の各行は、その行の試験までを足した時点の、統合したリスク比と 95% 信頼区間です。

横軸は対数目盛のリスク比で、縦の実線が 1（差なし）です。対数目盛の意味は 5.1.2 節（p. 43）で説明します。一番上の行は Aoki 2009 だけの結果で、リスク比 0.41（0.18〜0.96）です。150 人ずつの小さな試験ですが、区

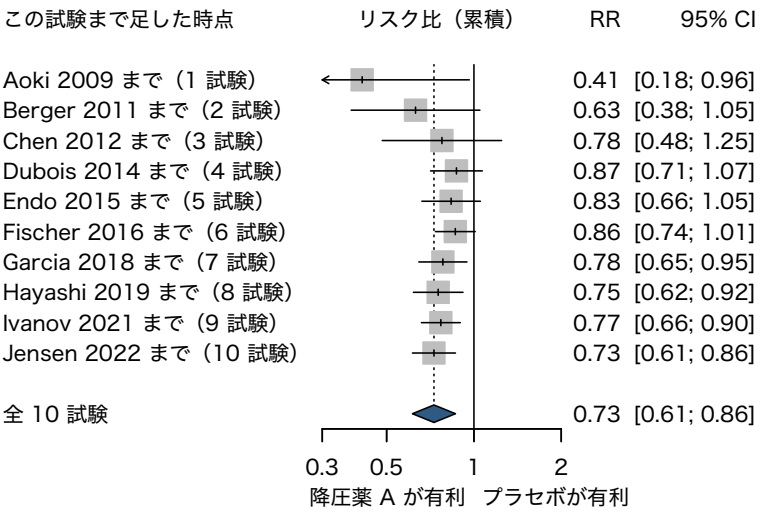


図 1.1　累積メタ解析。発表年の順に試験を足したときの、統合したリスク比と 95% 信頼区間（架空のデータ）

間は 1 をまたいでいません。2 試験目の Berger 2011 を足すと 0.63（0.38〜1.05）、3 試験目の Chen 2012 を足すと 0.78（0.48〜1.25）と点推定が 1 に近づき、区間も 1 をまたぎます。大きな Dubois 2014 を足した 4 試験目では 0.87（0.71〜1.07）と区間が狭まりますが、まだ 1 をまたいでいます。区間は 6 試験目まで 1 をまたぎ続け、7 試験目の Garcia 2018 を足すと 0.78（0.65〜0.95）となって、以後は 1 をまたぎません。10 試験すべてでは 0.73（0.61〜0.86）です。

最初の小さな試験の 0.41 は、試験を足すうちに 0.73 まで上がりました。小さな試験が示す大きな効果は、偶然の揺れで大きく見えている可能性があります。また、有意な試験が 4 本しかなくても、大きな試験を足すたびに統合した区間が狭まり、7 試験目で 1 から離れました。ただし、この図

は試験を発表年の順に足した 1 通りの結果にすぎません。累積メタ解析は、新しい試験が出るたびに結論がどう動いたかをたどる探索のための図で、区間が 1 をまたがなくなった時点を根拠に「何試験あれば十分だった」とは言えません。作り方は発展の 7.7 節（p. 80）で示します。

1.4 メタ解析が答えられないこと

メタ解析は計算としては平均をとるだけなので、入れた試験が偏っていれば、出てくる答えも偏ります。この性質は「ごみを入れればごみが出る（garbage in, garbage out）」と言い表されます。偏りが生じる経路は大きく 3 つあります。

一つ目は、集めた試験そのものの質です。ランダム化の手順が不十分だった試験や、脱落者が多い試験は、それ自体が偏った結果を出しているおそれがあります。統合しても偏りは消えず、信頼区間が狭くなるぶん、偏った結果が確かなものに見えてしまいます。試験の質の評価は 4.3 節（p. 37）で扱います。

二つ目は、どの試験を集めたかです。効果が有意だった試験は論文になりやすく、有意でなかった試験は論文にならずに埋もれやすいことが知られています。発表された試験だけを集めると、効果を大きく見積もることになります。これを出版バイアスと呼び、調べ方は 7.1 節（p. 72）以降で説明します。文献を漏れなく集める工夫（3.1 節（p. 27））は、この偏りを小さくするために行います。

三つ目は、違うものを混ぜることです。対象者も薬剤の量も追跡期間もまったく違う試験を一緒に平均すると、その平均値はどの集団にも当てはまらない数字になるおそれがあります。どこまでを同じ問いとみなして統合するかは、統計の計算を始める前に、問いの立て方（2.1 節（p. 21））で決めておきます。

検査の世界に置き換えると、測定法の違う施設のデータを、換算の確認もせずに一つの基準範囲にまとめるようなものです。数字は出ますが、その数字が何を意味するかは、元のデータの性質で決まります。

1.5 系統的レビューの工程

メタ解析は、系統的レビューという作業の中の一工程です。系統的レビューは、あらかじめ書いた計画に沿って、関連する研究を漏れなく探し、決めた基準で選び、データを取り出し、質を評価したうえで結果をまとめる一連の作業を指します。統合の計算そのものは全体のごく一部で、作業時間の大半は文献の検索、選別、データの抽出に使われます。

図 1.2 は、この冊子で扱う工程を順に並べたものです。各工程の横に、その工程を説明する章の番号を付けました。第 2 部の検査のメタ解析も、統合の計算の部分を除けば、同じ工程をたどります。

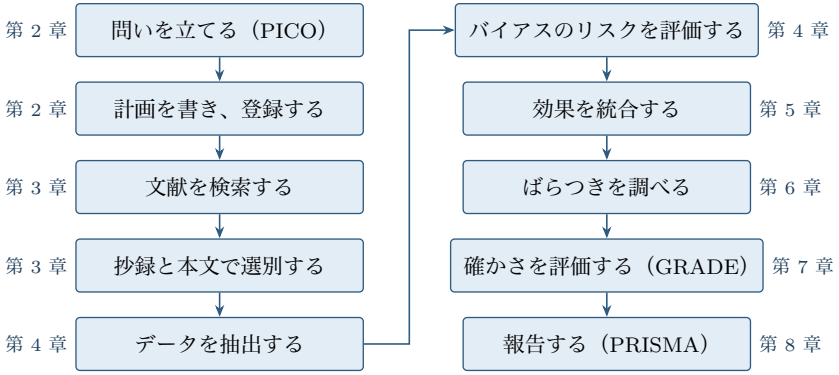


図 1.2　系統的レビューとメタ解析の工程（左列の下から右列の上へ続く）

工程は一方向に進むとは限りません。データを抽出している途中で、組み入れ基準の解釈が人によって違うことに気づき、選別に戻ることもあり

ます。そうした変更は、いつ、なぜ行ったかを記録しておき、報告の際に書きます。後から基準を変えると結果が都合よく動いてしまうおそれがあるためで、計画を先に書いて登録しておく理由もここにあります（2.4 節 (p. 24)）。

1.6 この章のまとめ

一つの試験の結果は偶然の揺れを含み、有意な試験の数を数える方法では答えを誤ります。メタ解析は試験の精度に応じた重みで平均をとる方法で、降圧薬 A の 10 試験からはリスク比 0.73（95% 信頼区間 0.61〜0.86）という推定が得られました。ただし、統合の結果は集めた試験の質と範囲で決まるので、統合の前の工程を丁寧に行う必要があります。次の章では、その最初の工程として、問いを PICO の形に書き下し、計画を文書にするところから始めます。

第 2 章

問いを立て、計画を書く

この章で分かること

メタ解析の結果は、どの研究を集めるかで決まり、どの研究を集めるかは問いの立て方で決まります。この章では、降圧薬 A の例で問いを PICO の形に書き下し、組み入れ基準と除外基準、解析の計画を、データを見る前に文書にしておく方法を説明します。

2.1 問いを PICO に分ける

「降圧薬 A は効くのか」という問いは、そのままでは文献を探すことも選ぶこともできません。誰に対して、何と比べて、何が変わるのかが決まっていないからです。介入の効果を調べる系統的レビューでは、問いを 4 つの要素に分けて書くのが標準のやり方で、それぞれの頭文字をとって PICO と呼びます（図 2.1）。

P（Population、対象）　どんな人を対象にするのか。降圧薬 A の例では、高血圧のある成人とします。

I（Intervention、介入）　何を行うのか。例題では降圧薬 A の投与です。

C（Comparison、比較）　何と比べるのか。例題ではプラセボとします。

O（Outcome、アウトカム）　何で効果を測るのか。例題では脳卒中の発症とします。

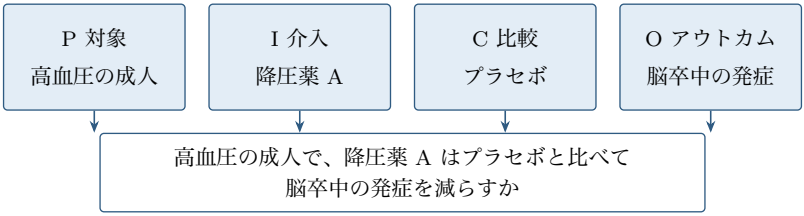


図 2.1　降圧薬 A の問いを PICO の 4 要素に分ける

4 つの要素を決めると、問いは「高血圧の成人で、降圧薬 A はプラセボと比べて脳卒中の発症を減らすか」という一文になります。この一文が、文献の検索式（3.2 節（p. 28））、組み入れの判断（3.3 節（p. 29））、データの抽出項目（4.1 節（p. 34））のすべての出発点になります。

要素の決め方によって、集まる試験は大きく変わります。比較を「プラセボ」とすれば、降圧薬 A と別の降圧薬を比べた試験は入りません。比較を「プラセボまたは他の降圧薬」とすれば試験は増えますが、プラセボと比べた効果と、他の降圧薬と比べた効果は意味の違う数字なので、一緒に平均してよいかという問題が生じます。1.4 節（p. 18）で述べた、違うものを混ぜる問題は、この段階で問いを絞ることで避けます。

2.2 アウトカムの決め方

アウトカムは、検査でいえば測定項目にあたります。何を測るのかが曖昧だと、試験ごとに違うものを数えた結果を平均することになります。

アウトカムには、患者にとって意味のある出来事（脳卒中、死亡、入院）

と、その代わりに測る指標（血圧の値）があります。血圧が下がることと脳卒中が減ることは関連していますが、同じではありません。血圧をよく下げても脳卒中が減らない薬剤があれば、血圧だけを見たレビューは誤った安心を与えます。そのため、レビューの主要アウトカムには、患者にとって意味のある出来事を選ぶのが原則です。この例では脳卒中の発症を主要アウトカムとし、血圧の変化や有害事象は副次アウトカムとして別に扱います。

アウトカムの定義も先に決めておきます。脳卒中を「画像検査で確認されたもの」に限るのか、「医師の診断」でよいのか。脳梗塞と脳出血を合わせて数えるのか、分けるのか。何年の追跡時点の値を使うのか。試験によっては「脳卒中、心筋梗塞、心血管死のいずれか」のような複合アウトカムしか報告していないこともあります。複合アウトカムは中身の内訳によって意味が変わるので、脳卒中だけの数が取り出せない試験をどう扱うかも、この段階で決めておきます。

2.3 組み入れ基準と除外基準

PICO の 4 要素に、研究デザインなどの条件を加えて、どの研究を組み入れ、どの研究を除外するかの基準を作ります。降圧薬 A のレビューでは、たとえば次のように書きます。

研究デザイン　ランダム化比較試験に限ります。観察研究（薬剤を飲んでいた人と飲んでいなかった人を、ランダム化せずに比べた研究）は、両群の背景の違いが結果に混ざるため除外します。

対象　18 歳以上の高血圧の患者とします。高齢者に限った試験も、一般の成人の試験も組み入れます。

介入と比較　降圧薬 A とプラセボを比べた試験とします。他の降圧薬との比較試験は除外します。

アウトカム　脳卒中の発症を報告している試験とします。

追跡期間　1 年以上とします。短すぎる試験では脳卒中がほとんど起こらないためです。

言語と出版形態　言語は制限しません。学会抄録や試験登録の結果も探します。

言語を英語に限ると作業は楽になりますが、英語以外の言語で発表された試験が系統的に抜け落ちます。効果がはっきり出た試験ほど英語の国際誌に投稿されやすいという報告もあり、言語の制限は偏りの原因になりえます。翻訳の手間を見込んででも、言語は制限しないのが原則です。

基準は、迷ったときに 2 人の評価者が同じ判断に至るよう、具体的に書きます。「適切な追跡期間」ではなく「1 年以上」と書くのは、糖尿病型の判定を「空腹時血糖が高め」ではなく「126 mg/dL 以上」と数値で定めるのと同じ理由です。

2.4 計画を先に書いて登録する

問いと基準が決まったら、データを集める前に、レビューの計画書（プロトコル）を書きます。計画書には、問い、組み入れ基準と除外基準、検索するデータベース、選別とデータ抽出の手順、バイアスのリスクの評価方法、統計解析の方法を書きます。プロトコルに書く項目は PRISMA-P という計画書の書式（Moher 2015）にまとめられているので、それに沿って書けば抜けが生じにくくなります。

計画書は、PROSPERO という国際的な登録のウェブサイトに登録するのが一般的です。計画を登録すると登録番号が付き、計画の内容と登録日が公開され、誰でも見られるようになります。

計画を先に書いて公開する理由は、結果を見てから方法を選ぶことを防ぐためです。メタ解析には、どの試験を入れるか、どの効果指標を使うか、

どのモデルを使うかといった選択肢が数多くあります。結果を見ながら選ぶと、意識していなくても、都合のよい結果が出る選択に寄っていきます。検査の世界で、測定結果を見てから基準範囲の決め方を変えれば、どんな結果でも「正常」にできてしまうのと同じです。計画書を事前に登録しておけば、計画から外れた解析をしたときにそれが外から分かり、読者は結果をその分だけ割り引いて読むことができます。

データを集めてから初めて分かることもあるので、計画は途中で変えてもかまいません。変えたときは、いつ、何を、なぜ変えたかを記録し、論文に書きます。

2.5 解析の計画で先に決めておくこと

統計解析の計画には、少なくとも次の項目を書きます。各項目の意味は第 5〜7 章で説明します。初めて読むときは、効果指標（5.2 節（p. 44））とモデル（5.4 節（p. 46））を先に決めることだけを押さえれば十分です。

項目	降圧薬 A のレビューでの決め方
効果指標（第 5 章）	リスク比
統合のモデル（第 5 章）	ランダム効果モデル（τ^2 は REML で推定）
異質性の評価（第 6 章）	I^2、τ^2、予測区間
サブグループ解析（第 6 章）	対象（高齢者と一般の成人）
感度分析（第 7 章）	バイアスのリスクが高い試験を除く
出版バイアス（第 7 章）	試験数が 10 以上ならファネルプロットと Egger 検定
確かさの評価（第 7 章）	GRADE

表 2.1　解析計画に書く項目と、降圧薬 A のレビューでの決め方

サブグループ解析は、事前に決めたものだけを主な結果として扱います。

データを見てから「この区分で分けたら差が出た」というサブグループは、偶然に見つかった差である可能性が高く、新しい仮説の候補にとどめます。表 2.1 で高齢者と一般の成人という区分を挙げたのは、高齢者では脳卒中の起こりやすさが高く、効果の大きさが違う可能性があると、データを見る前から考えられるからです。

2.6 この章のまとめ

問いは PICO の 4 要素に分けて一文に書き、アウトカムは患者にとって意味のある出来事を選んで定義まで決めます。組み入れ基準は 2 人が同じ判断に至るよう具体的に書き、言語は制限しません。そのうえで、解析の方法まで含めた計画書を、データを見る前に書いて登録します。次の章では、この計画に沿って文献を探し、組み入れる試験を選びます。

第 3 章

文献を探して選ぶ

この章で分かること

系統的レビューでは、問いに合う試験を、偏りなく、できるだけ漏れなく集めます。この章では、データベースの選び方、検索式の組み立て方、2 人で抄録を選別する手順を説明し、架空の抄録を使って組み入れの判断を練習します。最後に、選別の経過を PRISMA のフロー図にまとめます。

3.1 どこを探すか

一つのデータベースだけを検索すると、そこに収録されていない雑誌の試験が抜け落ちます。介入のレビューでは、少なくとも次の 3 つを検索するのが標準です。

MEDLINE（PubMed）　米国国立医学図書館のデータベースで、無料で使えます。医学の主要な雑誌はほぼ収録されています。

Embase　欧州の雑誌や、薬剤に関する雑誌の収録が厚い有料のデータベースです。MEDLINE と重複しない論文がかなり含まれます。

CENTRAL　Cochrane が集めた比較試験の登録簿で、他のデータベースから抽出した試験や、学会抄録の試験も含まれます。

日本語の論文を探すなら医中誌 Web を加えます。さらに、試験登録のデータベース（ClinicalTrials.gov、日本の jRCT、WHO の ICTRP）も検索します。試験登録には、計画段階で試験が登録されているので、結果が論文にならなかった試験も見つかります。1.4 節（p. 18）で述べた出版バイアスを小さくするには、この試験登録の検索が役に立ちます。学会抄録や報告書のように、雑誌に載らない文献（灰色文献）も、必要に応じて探します。

3.2 検索式を組み立てる

検索式は、PICO の要素ごとに言葉を集めて作ります。一つの要素の中では同義語を OR でつなぎ、要素どうしは AND でつなぎます。OR は「どれか一つでも含む」、AND は「すべてを含む」という意味なので、要素の中で候補を広げ、要素の間で絞り込むことになります。

言葉には 2 種類を使います。一つは、データベースが論文に付けている統制語です。MEDLINE では MeSH（Medical Subject Headings）と呼ばれ、たとえば Hypertension という MeSH を指定すると、論文の中で high blood pressure と書かれていても拾えます。もう一つは、題名や抄録に出てくる自由語です。新しい論文はまだ統制語が付いていないことがあるので、両方を OR でつなぎます。

アウトカム（脳卒中）は、ふつう検索式に入れません。抄録には主要アウトカムしか書かれていないことが多く、脳卒中を副次アウトカムとして報告した試験が漏れてしまうからです。比較（プラセボ）も同じ理由で入れません。検索式は、図書館の司書や検索の専門家に見てもらうと、漏れが大きく減ります。

発展 PubMed の検索式の書き方

降圧薬 A は架空の薬剤なので、形だけの例を示します。PubMed では次のように書きます。

```
#1 "drug A"[tiab] OR "XY-123"[tiab]
#2 "Hypertension"[MeSH] OR hypertens*[tiab]
   OR "high blood pressure"[tiab]
#3 "randomized controlled trial"[pt]
   OR randomi*[tiab] OR placebo[tiab]
#4 #1 AND #2 AND #3
```

[tiab] は題名と抄録から探す指定、[pt] は論文の種類の指定、末尾の * は語尾が何でもよいという指定（hypertension も hypertensive も拾う）です。#3 は RCT に絞るための組み合わせで、Cochrane が漏れの少ない検索式（高感度検索式）を公開しています。この RCT フィルターは MEDLINE のように試験以外の論文も大量に含むデータベースに使うもので、CENTRAL には使いません（Cochrane ハンドブック 4.4.7）。CENTRAL は比較試験を集めた登録簿で、フィルターをかけると本来拾える試験を落とす恐れがあるからです。

3.3 重複を除き、2 人で選別する

複数のデータベースを検索すると、同じ論文が何度も出てきます。文献管理ソフトで重複を除いてから選別に入ります。

選別は 2 段階で行います。最初に題名と抄録だけを読み、明らかに基準に合わないものを除きます。残ったものについて本文を入手し、基準に合うかを確かめます。Cochrane ハンドブック（4.6 と MECIR の基準）は、抄録の段階の選別は 1 人でもよいとし、本文による最終的な適格性の判定は 2 人が独立に行うよう求めています。本書は、どちらの段階でも 2 人が

それぞれ独立に判断することを勧めます。判断が分かれたものは話し合うか、3 人目の判断で決めます。1 人で選別すると、判断の誤りや思い込みに気づく機会がなくなるからです。

発展 2 人の判断がどれだけ一致したかは κ（カッパ）係数という指標で示すことがあります。偶然の一致を差し引いた一致の度合いで、1 に近いほどよく一致していることを表します。

抄録の段階では、迷ったものは残します。抄録で除いた文献はふつう二度と見ないので、ここでの除外は本文の段階より慎重に行います。選別の作業には Rayyan のような専用のツールが使えます。

発展 選別を機械学習で助ける方法もあります。関連が高いと推定した記録を先に並べ替えて、読む順序を工夫する使い方です。一方、機械が除外と判断した記録を人が見直さないままにすることは、Cochrane ハンドブック（4.6.6）では勧められていません。自動化の道具を使ったときは、その方法をフロー図とあわせて方法の節に書きます。

3.4 抄録の選別を練習する

検索で見つかった架空の抄録を 6 件示します。2.3 節（p. 23）で決めた基準（高血圧の成人、降圧薬 A とプラセボを比べた RCT、脳卒中を報告、追跡 1 年以上）に照らして、組み入れるか、除外するか、本文で確かめるかを考えてから、続く解説を読んでください。

抄録 1　Garcia 2018（架空）。65 歳以上の高血圧患者 3,200 人を降圧薬 A 群とプラセボ群に無作為に割り付け、中央値 4 年追跡した。主要評価項目の脳卒中は、降圧薬 A 群で有意に少なかった。

抄録 2　Kimura 2017（架空）。診療記録のデータベースから、降圧薬 A を処方された 12,000 人と処方されなかった 30,000 人を抽出し、脳卒中の発症を比べ

た。降圧薬 A の処方は脳卒中の低いリスクと関連していた。

抄録 3　Lee 2016（架空）。高血圧患者 800 人を、降圧薬 A 群とアムロジピン群に無作為に割り付けた。3 年間の脳卒中の発症に差はなかった。

抄録 4　Novak 2013（架空）。高血圧患者 240 人を降圧薬 A 群とプラセボ群に無作為に割り付け、24 週後の収縮期血圧を比べた。降圧薬 A 群で 12 mmHg 低かった。

抄録 5　Garcia 2020（架空）。Garcia 2018 の試験の参加者を対象に、5 年目までの追跡結果と腎機能の変化を報告する。

抄録 6　Endo 2015（架空）。75 歳以上の高血圧患者 180 人を降圧薬 A 群とプラセボ群に無作為に割り付けた。主要評価項目は心血管イベントで、降圧薬 A 群で少ない傾向がみられた。

抄録 1 は、基準をすべて満たしているので組み入れます。抄録 2 は、診療記録から薬剤を飲んだ人と飲まなかった人を比べた観察研究です。処方されるかどうかは医師が患者の状態を見て決めるので、両群の背景が違い、その違いが結果に混ざります。基準どおり除外します。抄録 3 は RCT ですが、比較が他の降圧薬なので除外します。抄録 4 は、アウトカムが血圧だけで追跡も 24 週と短いので除外します。

抄録 5 は判断に迷う例です。新しい試験ではなく、抄録 1 と同じ試験の追加報告です。同じ参加者を 2 回数えると、その試験の重みが二重になるので、別の試験として組み入れてはいけません。一つの試験に複数の論文がある場合は、試験を単位にしてまとめ、データはどの論文から取るかを決めます。この例では、主要な結果は抄録 1 の論文から取り、5 年目の結果が必要なら抄録 5 の論文を参照します。

抄録 6 は、主要評価項目が「心血管イベント」で、脳卒中を別に報告しているかが抄録からは分かりません。こうした文献は抄録の段階では除かず、本文を入手して確かめます。本文に脳卒中の数が示されていれば組み入れ、なければ著者に問い合わせます。

3.5
選別の経過をフロー図にまとめる

選別の経過は、何件を探し、どの段階で何件を、どんな理由で除いたかを、PRISMA 2020（Page 2021）の形式のフロー図にまとめます。降圧薬 A のレビューの架空の例を図 3.1 に示します。

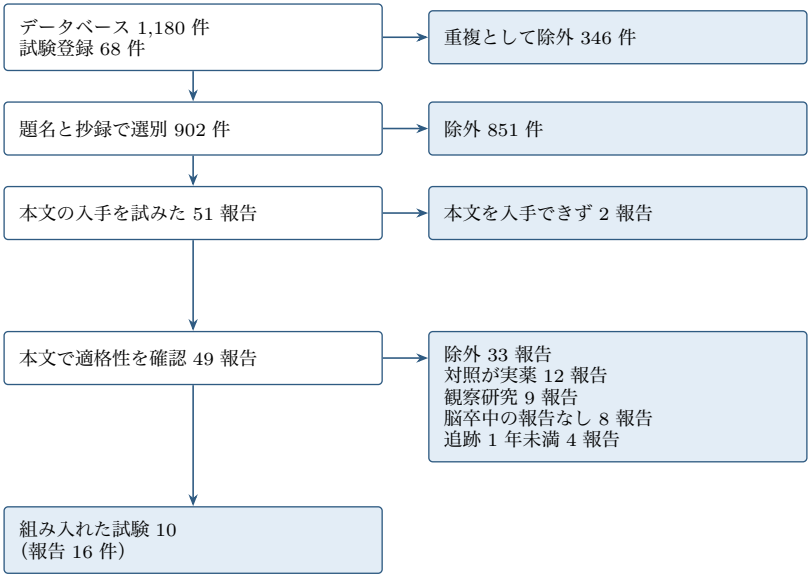


図 3.1　降圧薬 A のレビューの PRISMA 2020 フロー図（架空の数）

図 3.1 では、本文の段階から数える単位を、文献（報告）の数にしています。同じ試験について複数の報告が出ていることがあり、その場合は試験の数と報告の数が一致しないからです。本文を確認した 49 報告のうち、除外したのは 33 報告（対照が実薬 12、観察研究 9、脳卒中の報告なし 8、追跡 1 年未満 4）です。残りの 16 報告は 10 の試験についての報告で、1 試験につき主要な報告が 1 本、同じ試験の追加報告が合わせて 6 本あります

(49 − 33 = 16、10 + 6 = 16)。PRISMA 2020 は、組み入れた試験の数と、その報告の数を別々に示すよう求めています。同じ試験の追加報告は、除外した文献ではなく、組み入れた試験にまとめた報告として数えます。

フロー図を見れば、読者は検索がどこまで及んだか、どんな理由の除外が多かったかを一目で確かめられます。本文の段階で除外した文献は、理由とともに一覧表にして付録に載せるのがふつうです。抄録の段階の除外は件数だけで構いません。

3.6 この章のまとめ

検索は MEDLINE、Embase、CENTRAL と試験登録を基本にし、PICO の要素ごとに統制語と自由語を OR でつなぎ、要素どうしを AND でつなぎます。アウトカムは検索式に入れません。選別は抄録と本文の 2 段階で、2 人が独立に判断し、同じ試験の重複報告は試験単位にまとめます。経過は PRISMA 2020 のフロー図に残します。次の章では、組み入れた 10 試験の論文から数字を取り出し、それぞれの試験の偏りを評価します。

第 4 章

データを取り出し、バイアスを評価する

この章で分かること

組み入れた試験の論文から、統合に使う数字と試験の特徴を取り出し、それぞれの試験がどれくらい偏りにくいかを評価します。この章では、抽出フォームの作り方、本文の記載から 2×2 の数を作る方法、RoB 2 によるバイアスのリスクの評価を説明し、取り出したデータを R に読み込むところまで進めます。

4.1 何を取り出すか

データの抽出は、試験ごとに同じ項目を同じ形で書き写す作業です。項目は、あらかじめ抽出フォーム（表計算ソフトの表で十分です）にしておきます。フォームを先に作るのは、試験ごとに取り出す項目がぶれないようにするためで、検査でいえば検査依頼書の様式を統一しておくのと同じ役割を果たします。降圧薬 A のレビューでは、次の項目を取り出します。

試験の識別　筆頭著者、発表年、試験名、試験登録番号を書き、同じ試験

の論文が複数あれば一覧にします。

試験の方法　研究デザイン、実施国と施設数、追跡期間、ランダム化と割り付けの方法を書きます。

対象　組み入れ基準、人数、年齢、性別、試験開始時の血圧、脳卒中の既往がある人の割合を書きます。

介入と比較　降圧薬 A の用量、プラセボの内容、併用を認めた薬剤を書きます。

アウトカム　脳卒中の定義と判定方法、評価の時点、群ごとの発症数と解析対象の人数を書きます。

バイアスのリスク　RoB 2 の各領域の判定と、その根拠になった本文の記載を書きます（この章の後半で説明します）。

抽出も、選別と同じく 2 人が独立に行い、食い違いを話し合って解決します。数字の書き写しは単純に見えますが、群の取り違え、表の行の読み違い、時点の取り違えが意外に多く起こります。2 人で独立に抽出して突き合わせれば、こうした誤りの多くを見つけられます。転記した数字は、どの論文の何ページの何の表から取ったかも記録しておきます。

4.2 本文から 2×2 の数を作る

脳卒中のような「起きた、起きなかった」で数えるアウトカムでは、群ごとに発症した人数と解析した人数の 2 つずつ、合わせて 4 つの数を取り出します。この 4 つの数を並べたものを 2×2 表と呼びます（表 4.1）。

	脳卒中あり	脳卒中なし	合計
降圧薬 A 群	121	1,479	1,600
プラセボ群	186	1,414	1,600

表 4.1　架空の Garcia 2018 の 2×2 表

いちばん楽なのは、本文に人数がそのまま書かれている場合です。架空の Garcia 2018 の結果の段落に「脳卒中は降圧薬 A 群 1,600 人中 121 人（7.6%）、プラセボ群 1,600 人中 186 人（11.6%）に発生した」とあれば、121、1,600、186、1,600 をそのまま写します。括弧の中の割合は、121 ÷ 1,600 = 0.0756 から計算できるので、転記の誤りを確かめるのに使えます。

割合しか書かれていない場合は、割合と人数から発症数を逆算します。架空の Fischer 2016 の本文に「脳卒中の発症は降圧薬 A 群 800 人の 4.0%、プラセボ群 800 人の 4.8%」とあれば、降圧薬 A 群は 800 × 0.040 = 32 人、プラセボ群は 800 × 0.048 = 38.4 人と計算できます。人数は整数なので 38 人とします。割合が丸められているときは、逆算した値が整数からずれることがあります。そのときは、ずれの大きさから元の人数を絞り込み、本文の別の箇所（表や図の注）とも照らし合わせて確かめます。

どの人数を分母にするかにも注意が要ります。RCT の結果は、割り付けた全員をそのまま割り付けた群で解析する方法（ITT 解析、intention-to-treat）と、計画どおりに薬剤を飲み続けた人だけで解析する方法（per protocol 解析）の 2 通りで報告されることがあります。途中で薬剤をやめた人を除くと、やめた理由（副作用や病状の悪化）が群によって違う場合に、ランダム化でそろえた背景が崩れます。効果の推定には ITT 解析の数を使うのが原則です。

結果がグラフ（累積発症曲線など）にしか示されていない場合は、まず著者に問い合わせます。それでも数が得られなければ、グラフから値を読み取るソフトを使うこともありますが、読み取った値であることを記録し、感度分析で除外したときの結果も確かめます（7.6 節（p. 77））。

4.3
バイアスのリスクを評価する

RCT はランダム化によって両群の背景をそろえますが、試験の進め方によっては結果が偏ります。それぞれの試験がどれくらい偏りやすいかを評価する道具として、RCT では RoB 2（Sterne 2019）が使われています。RoB 2 は、結果を偏らせる経路を 5 つの領域に分け、領域ごとにバイアスのリスクを「低い」「懸念あり」「高い」の 3 段階で判定します。

ランダム化の過程　割り付けの順番が予測できない方法で作られ、その順番が登録の担当者から隠されていたか（割り付けの隠蔽）。降圧薬 A の試験で、担当者が次の患者はプラセボ群だと前もって分かるようでは、重症の患者を降圧薬 A 群へ割り当てるといった操作ができてしまいます。隠蔽は、割り付ける時点で順番を伏せることです。

意図した介入からの逸脱　割り付けたあとに、参加者や治療者がどちらの群かを知っていたために、治療の内容が変わっていないか。降圧薬 A の錠剤がプラセボと見た目で区別できると、医師が降圧薬 A 群の患者にだけ他の降圧治療を控える、といったことが起こりえます。どちらの群かを伏せておくことを盲検化と呼び、隠蔽とは時点が違います。

アウトカムデータの欠測　脱落や追跡不能で結果が分からない人が多すぎないか、その理由が群で違わないか。降圧薬 A 群だけ副作用で来院をやめた人が多ければ、残った人の脳卒中の数は比べられません。

アウトカムの測定　脳卒中かどうかを判定した人が、患者がどちらの群かを知らずに判定したか。知っていると、判定の境界の症例で判断がぶれます。

報告される結果の選択　計画段階で決めたアウトカムと解析を、そのとおりに報告しているか。血圧の変化も脳卒中も測っていた試験が、結果のよかったほうだけを報告していないかを見ます。

5 つの領域に分けて点検するやり方は、誤報告の原因を検査前、検査、検査後の工程に分けて調べるのに似ています。試験全体の判定は、5 つの領域の判定から決めます。どれか一つでも「高い」があれば全体も高い、すべてが「低い」なら全体も低い、それ以外は「懸念あり」とするのが基本の規則です。ただし、複数の領域で懸念ありが重なり、結果への信頼を大きく損なうと判断すれば、全体を「高い」とすることもできます。

降圧薬 A の 10 試験の判定を図 4.1 に示します。架空の判定ですが、理由の書き方を 3 試験ぶん示します。架空の Aoki 2009 は、割り付けの順番の作り方は書かれているものの、隠蔽の方法の記載がないので、ランダム化の過程が「懸念あり」です。架空の Chen 2012 は、脳卒中の判定者が群を知らされていたかどうかの記載がなく、アウトカムの測定が「懸念あり」です。架空の Endo 2015 は、隠蔽の記載がないうえ、割り付けた 180 人のうち 38 人が途中で追跡できなくなっていました。論文はその人たちを脳卒中なしとみなして、分母を 90 人ずつのまま解析しており、追跡できなかった理由も群ごとに示されていません。数の流れは、割り付け 180 人、追跡できず 38 人、追跡できて結果が分かる 142 人です。表 1.1 の 6 人と 12 人は、結果が分かる 142 人から数えた脳卒中で、追跡できなかった 38 人は 0 人として分母にだけ入っています。追跡できなかった人に脳卒中が起きていれば結果が変わるので、アウトカムデータの欠測を「高い」と判定し、試験全体も「高い」としました。

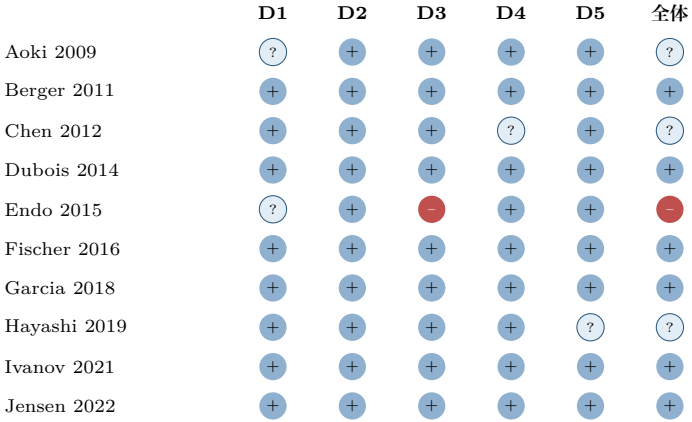


図 4.1　架空の 10 試験の RoB 2 の判定。D1 ランダム化の過程、D2 意図した介入からの逸脱、D3 アウトカムデータの欠測、D4 アウトカムの測定、D5 報告される結果の選択。＋ 低い、？ 懸念あり、– 高い

判定には、必ず本文の該当箇所を根拠として書き添えます。「記載がない」ことも根拠の一つです。論文に書かれていない手順は、実際に行われていても評価者には確かめようがないので、記載がなければ懸念ありとするのがふつうです。必要なら著者や試験登録の記録で確かめます。

バイアスのリスクの判定は、点数にして合計しないでください。5 つの領域は結果を偏らせる経路が違い、どの領域の問題がどれだけ結果を動かすかも試験ごとに違うからです。評価の結果は、6.4 節（p. 64）のサブグループ解析と 7.6 節（p. 77）の感度分析で、判定の違う試験の間で結果が変わるかを調べるのに使います。

発展　この冊子の例は RCT だけですが、介入のレビューでは非ランダム化研究を含めることもあります。その場合の評価には ROBINS-I（Sterne 2016）を使います。交絡や対象者の選び方による偏りを、仮想的なランダム化試験と比べる形で評価する道具です。改訂版の ROBINS-I V2 は、riskofbias.info で 2025 年 11 月版が草案として公開

されていますが、確定版の論文は確認できませんでした。使うときは最新の版と手引きを確かめてください。

4.4 抽出したデータを R に読み込む

抽出した数は、1 行を 1 試験とし、列に項目を並べた表にして、CSV 形式（項目をカンマで区切ったテキスト）で保存します。列名は英字で短く付けておくと、R で扱いやすくなります。降圧薬 A のデータでは、試験名（study）、対象（pop）、バイアスのリスクの全体判定（rob）、降圧薬 A 群の発症数と人数（ev_t、n_t）、プラセボ群の発症数と人数（ev_c、n_c）の 7 列にしました。

R で CSV を読み込むには read.csv() を使います。日本語を含むファイルは、文字コードを指定して読み込みます。

```
bp <- read.csv("data/bp_stroke.csv",
               fileEncoding = "UTF-8")
str(bp)    # 列の名前と型を確かめる
```

```
'data.frame':        10 obs. of  7 variables:
 $ study: chr  "Aoki 2009" "Berger 2011" "Chen 2012" ...
 $ pop  : chr  "高齢者" "一般" "高齢者" "一般" ...
 $ rob  : chr  "懸念あり" "低" "懸念あり" "低" ...
 $ ev_t : int  7 48 44 134 6 32 121 10 112 43
 $ n_t  : int  150 1200 420 2500 90 800 1600 300 3000 650
 $ ev_c : int  17 65 39 145 12 38 186 23 139 83
 $ n_c  : int  150 1200 420 2500 90 800 1600 300 3000 650
```

str() の出力で、10 行 7 列のデータが読み込まれ、発症数と人数が整数（int）として入っていることを確かめます。数が文字（chr）になっていたら、どこかの値に数字以外の文字（全角数字や空白）が紛れ込んでいま

す。読み込んだら、発症数が人数を超えていないか、合計人数（10 試験で 21,420 人）が抽出フォームと一致するかも確かめておきます。

4.5 この章のまとめ

データは、あらかじめ作った抽出フォームに 2 人が独立に書き写し、出典の箇所も記録します。発症数は ITT 解析の数を使い、割合しかなければ人数から逆算します。各試験のバイアスのリスクは RoB 2 の 5 つの領域で判定し、根拠を書き添え、点数にはしません。抽出したデータは 1 行 1 試験の CSV にして R に読み込みました。次の章では、この 10 試験のリスク比を R で統合します。

第 5 章

効果を統合する

この章で分かること

4.2 節（p. 35）で作った 10 試験の 2×2 の数を、一つの効果の推定値にまとめます。分散、対数、オッズといった計算の前提を精度管理の言葉で確かめたあと、効果をどの指標で表すか、試験にどう重みを付けるか、固定効果モデルとランダム効果モデルのどちらを使うかを決め、R の meta パッケージで計算します。結果はフォレストプロットで読みます。τ^2 の推定法の詳細と L'Abbé プロットは「発展」の印をつけた部分で扱うので、初めて読むときは飛ばして構いません。

5.1 計算の前に知っておくこと

この章の計算は、分散、標準誤差、対数、オッズという四つの言葉の上に成り立っています。どれも精度管理で使う感覚に置き換えられます。

ばらつきを表す量

標準偏差（SD）は、測定値のばらつきの大きさです。同じ管理試料を測ると、値は測るたびに SD ほどぶれます。分散は SD を 2 乗した値です。標準誤差は、個々の測定値ではなく、平均やリスク比のような推定値そのものの不確かさを表します。管理試料を 1 回だけ測った値より、20 回測った平均のほうがぶれが小さいのと同じで、標準誤差は人数や測定回数が多いほど小さくなります。平均の標準誤差は SD を測定回数の平方根で割った値なので、20 回の平均のぶれは 1 回の値の約 4.5 分の 1 です。試験でも、人数が多いほど推定値のぶれは小さくなります。

対数と指数

リスク比 0.5 と 2 は、向きが逆で大きさの同じ効果です。ところが数直線の上では、1 からの距離が 0.5 と 1 で違います。対数をとると、0.5 は − 0.69、1 は 0、2 は 0.69 になり、0 を中心に左右対称に並びます（表 5.1）。log は掛け算を足し算に変える計算で、$\log(1) = 0$ です。対数をとった値は、exp（指数）をとると元の比に戻ります。

リスク比	0.25	0.5	1	2	4
1 からの距離	0.75	0.5	0	1	3
対数をとった値	− 1.39	− 0.69	0	0.69	1.39

表 5.1　リスク比と、その対数をとった値

重みを分散の逆数にする理由

精度管理では、CV の小さい、ぶれの少ない測定ほど信用します。メタ解析も同じで、ぶれの小さい試験を重く見ます。ぶれの大きさを表すのが分散なので、分散の逆数を重みにします。降圧薬 A の Endo 2015（各群 90

人）と Garcia 2018（各群 1600 人）では、リスク比の対数の分散が約 0.23 と約 0.012 で、Garcia の重みは Endo の約 18 倍になります。

オッズ

オッズは、ある出来事が起きる割合 p を、起きない割合 1 − p で割った p/(1 − p) です。発症割合が 0.2 なら、オッズは 0.2/0.8 = 0.25 で、発症する人 1 人に対して発症しない人が 4 人いることを表します。オッズは 9.4 節（p. 98）と 10.3 節（p. 110）でも使います。

5.2 効果を表す指標

メタ解析で統合するのは、試験ごとの効果の大きさです。降圧薬 A の試験では、アウトカムが脳卒中を起こしたか起こさなかったかの 2 値なので、二つの群の発症割合を比べる指標を使います。代表的なものが三つあります。

リスク比（RR） 介入群の発症割合を対照群の発症割合で割った値です。架空の Garcia 2018 では降圧薬 A 群が 1600 人中 121 人（7.6%）、プラセボ群が 1600 人中 186 人（11.6%）なので、リスク比は 7.6 ÷ 11.6 で 0.65 になります。1 より小さければ介入群で発症が少なかったことを表し、0.65 は発症が 35% 少ないと読めます。

オッズ比（OR） オッズ（5.1.4 節（p. 44））を群どうしで割った値です。発症がまれなアウトカムではリスク比とほぼ同じ値になりますが、発症割合が高くなるほどリスク比より 1 から遠い値になります。臨床の言葉に直しにくいので、RCT のメタ解析ではリスク比を選ぶことが多くなります。

リスク差（RD） 発症割合の差です。Garcia 2018 では 121/1600 −

186/1600 で約 − 4.1 ポイント（7.56% − 11.63%）になります。1000 人あたり何人減るかという形で判断に結びつけやすい指標ですが、対照群の発症割合が試験ごとに違うと試験間で大きくばらつくので、統合にはあまり使いません。

アウトカムが血圧の値や検査値のような連続量なら、平均の差（平均差、MD）を使います。生活の質を別々の質問票で測った試験のように、試験ごとに尺度の単位が違うときは、平均差を標準偏差で割った標準化平均差（SMD）を使います。

リスク比とオッズ比は、そのままではなく対数をとってから統合します（対数は 5.1.2 節（p. 43）で説明しました）。比は 1 を中心に左右対称ではないからです。統合した結果は最後に指数をとって比に戻します。フォレストプロットの横軸が対数目盛になっているのはこのためです。

この冊子ではリスク比を使います。降圧薬 A を使うかどうかを考える人にとって、何割減るかが最も読み取りやすく、対照群の発症割合が試験ごとに約 5〜13% と違っていても比はばらつきにくいからです。

5.3 重み付き平均という考え方

10 試験のリスク比を単純に平均すると、各群 90 人の Endo 2015 と各群 3000 人の Ivanov 2021 を同じ重さで扱うことになります。大きな試験ほど偶然のぶれが小さく、推定値を信用できるので、重みを大きくするのが自然です。重みの考え方が分かりにくいときは、先に 5.1.3 節（p. 43）を読み直してください。

メタ解析の標準的な重みは、推定値の分散の逆数です。この重みの付け方を逆分散法と呼びます。

対数リスク比の分散は、主に事象の数で決まります。人数が多くても脳卒中がほとんど起きなければ、推定値は安定しません。Garcia 2018 は両群

で 307 件の脳卒中が起きたので分散が小さく、固定効果モデルでは 10 試験の中で最も重い 23.9% の重みを受けます。Endo 2015 は 18 件しかないので、重みは 1.3% にとどまります。統合した値は、この重みで対数リスク比を平均したものです。

計算の補足

対数リスク比の分散は、1/（介入群の事象数） − 1/（介入群の人数） + 1/（対照群の事象数） − 1/（対照群の人数）で計算できます。Endo 2015 なら 1/6 − 1/90 + 1/12 − 1/90 を計算し、Garcia 2018 なら同じ式に 121、1600、186、1600 を入れます。標準誤差は分散の平方根で、Endo 2015 は約 0.48、Garcia 2018 は約 0.11 です。

5.4 固定効果モデルとランダム効果モデル

重みを付けて平均するとき、試験の背後にある真の効果をどう考えるかで、二つのモデルに分かれます。

同じ管理試料を複数の施設で測る場面で考えます。固定効果モデルは、どの施設も同じ真の値を測っていて、施設ごとの結果の違いは測定の偶然誤差だけだと考えます。試験でいえば、すべての試験が同じ一つの真の効果を推定していて、試験ごとの結果が違うのは偶然のぶれだけだという前提です。R の meta パッケージは、このモデルを common effect model（共通効果モデル）と表示します。

ランダム効果モデルは、施設ごとに校正や試薬ロットの違いによる系統的なずれがあり、施設が測っている値そのものが少しずつ違うと考えます。試験でも、対象の年齢、併用している治療、追跡期間が違えば、真の効果が少しずつ違います。このモデルでは、試験ごとの真の効果が一つの分布から出てきたとみなし、その分布の平均を推定します。真の効果の散らばりの大きさを研究間分散と呼び、τ^2（タウ二乗）で表します。τ^2 は施設

間のずれの大きさに当たり、各施設の中の偶然誤差、つまり各試験の分散とは別のものです。

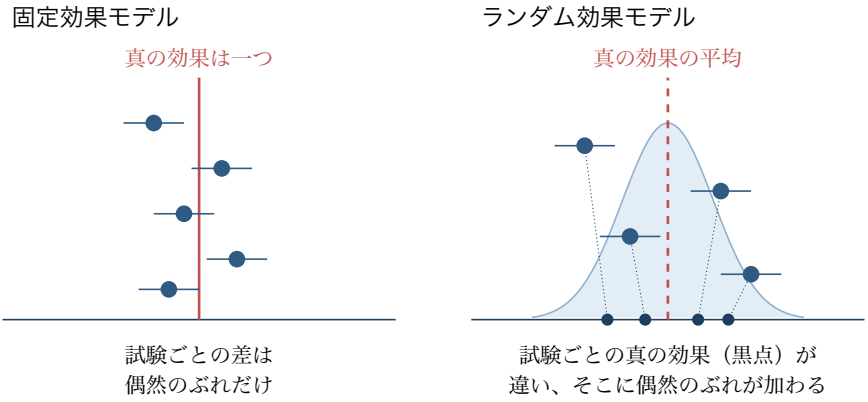


図 5.1　二つのモデルの考え方。青い点と横線は試験ごとの推定値と信頼区間

二つのモデルの違いは、重みの付け方に表れます。ランダム効果モデルでは、各試験の分散に τ^2 を足したものの逆数を重みにします。τ^2 はどの試験にも同じだけ足されるので、もともと分散が小さかった大きな試験ほど重みが大きく目減りし、試験間の重みの差が縮まります。Endo 2015 の分散 0.23 に τ^2 の 0.034 を足すと 0.26、Garcia 2018 の 0.012 に足すと 0.046 で、重みの比は約 18 倍から約 6 倍に縮みます。重みの割合でみると、Garcia 2018 の重みが 23.9% から 16.5% に下がり、Endo 2015 は 1.3% から 2.9% に上がります。小さな試験の重みが相対的に増えるので、7.1 節（p. 72）で扱う小規模研究効果があるときには、この性質が結果を動かします。

図 5.2 の横軸は、10 試験の合計を 100 としたときの各試験の重み（%）です。各試験に 2 本の棒があり、薄い青が固定効果モデル、濃い青がランダム効果モデルの重みを表します。下の 3 試験（Endo 2015、Aoki 2009、Hayashi 2019）はどれも合計 600 人以下の小さな試験で、濃い青の棒が薄い青より長くなっています。上から 3 本の大きな試験（Ivanov 2021、Dubois

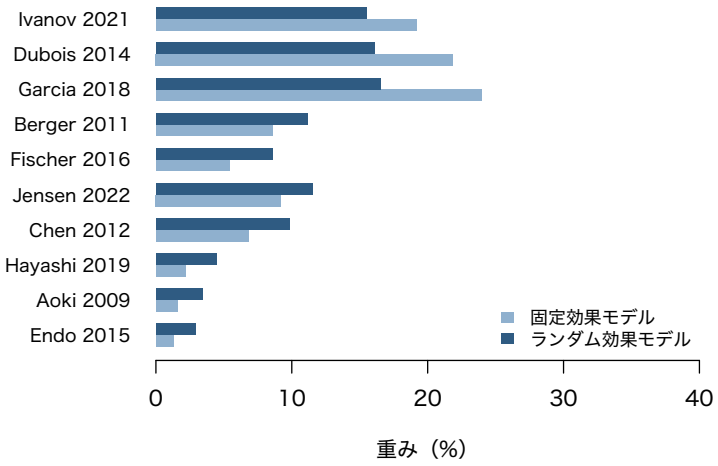


図 5.2　固定効果モデルとランダム効果モデルでの重み。各試験の上の棒が固定効果、下の棒がランダム効果。試験は合計人数の少ない順に下から並べた

2014、Garcia 2018）では逆に、濃い青の棒が短くなっています。

もう一つ読み取れることは、棒の長さが人数の順になっていないことです。Garcia 2018 は合計 3,200 人で、Dubois 2014（5,000 人）や Ivanov 2021（6,000 人）より少ないのに、固定効果モデルでは最も重くなっています。脳卒中の件数が多く（307 件）、推定が安定しているからです。重みは人数ではなく、推定のぶれの小ささで決まります。ランダム効果モデルで重みの差が縮んでも、並び順は大きくは変わりません。

どちらを主解析にするかは、データを見る前に計画の段階で決めます。臨床試験は対象や介入の条件が試験ごとに違うのが普通なので、この冊子ではランダム効果モデルを主解析にします。ランダム効果モデルが推定するのは真の効果の平均で、どの集団でもその効果が得られるという意味ではありません（予測区間は 6.3 節（p. 62）で説明します）。

5.5
R で計算する準備

ここから R を使います。R を初めて使う読者は、付録 A の手順で R と RStudio を入れ、作業フォルダ（中に data、fig、out の 3 つのフォルダ）を作ってから読み進めてください。

RStudio の File メニューから New File、R Script と選ぶとスクリプトの画面が開きます。命令を書いた行で Command と Return（Windows では Ctrl と Enter）を押すと、その行が実行され、結果が Console に出ます。# から右は R が読み飛ばす注釈なので、写すときに省いてもかまいません。

最初に、メタ解析のパッケージを読み込みます。インストール（付録 A）は一度だけ、読み込みは R を起動するたびに行います。

```
library(meta)       # メタ解析の関数をまとめたパッケージ
```

次に、第 4 章で作った CSV ファイルを読み込みます。read.csv は CSV を表の形のデータ（データフレーム）として読み込む関数です。左向きの矢印 <- は、右側の結果を左側の名前で保存するという意味で、この例では読み込んだ表を bp という名前にしています。

```
bp <- read.csv("data/bp_stroke.csv",
               fileEncoding = "UTF-8")
str(bp)             # 列の名前と型を確かめる
```

```
'data.frame':        10 obs. of  7 variables:
 $ study: chr  "Aoki 2009" "Berger 2011" "Chen 2012" ...
 $ pop  : chr  "高齢者" "一般" "高齢者" "一般" ...
 $ rob  : chr  "懸念あり" "低" "懸念あり" "低" ...
 $ ev_t : int  7 48 44 134 6 32 121 10 112 43
 $ n_t  : int  150 1200 420 2500 90 800 1600 300 3000 650
 $ ev_c : int  17 65 39 145 12 38 186 23 139 83
 $ n_c  : int  150 1200 420 2500 90 800 1600 300 3000 650
```

10 行 7 列の表として読み込めました。ev_t と n_t が介入群の事象数と人数、ev_c と n_c が対照群の事象数と人数です。ファイルが見つからないときは作業フォルダの設定（Session メニューの Set Working Directory）を、文字化けするときは fileEncoding を確かめます。Windows の Excel で保存した CSV は fileEncoding = ”CP932” で読めることがあります。

5.6 metabin で統合する

2 値のアウトカムを統合する関数が metabin です。介入群の事象数、介入群の人数、対照群の事象数、対照群の人数の順に列名を渡し、続けて設定を書きます。この 4 つは、4.2 節（p. 35）の 2×2 表（表 4.1）では、降圧薬 A 群の行の「脳卒中あり」のマス（ev_t）と合計のマス（n_t）、プラセボ群の行の「脳卒中あり」のマス（ev_c）と合計のマス（n_c）に当たります。「脳卒中なし」のマスは渡しません。設定のうち、sm = ”RR” はリスク比、method = ”Inverse” は逆分散法、method.tau = ”REML” は τ^2 の推定法の指定です。

```
m <- metabin(ev_t, n_t, ev_c, n_c,
             studlab = study, data = bp,
             sm = "RR",             # 効果指標はリスク比
             method = "Inverse",    # 逆分散法
             method.tau = "REML",   # τ² の推定法
             common = TRUE, random = TRUE,
             prediction = TRUE)     # 予測区間も出す
summary(m)
```

出力の後半に、統合した結果が出ます（一部を抜き出し、列の間隔を詰めています）。

```
                         RR           95% CI      z  p-value
Common effect model  0.7481 (0.6724 to 0.8324) -5.33 < 0.0001
```

```
Random effects model 0.7281 (0.6137 to 0.8637) -3.64   0.0003
Prediction interval         (0.4600 to 1.1523)

 tau^2 = 0.0336 (0.0000 to 0.2950); tau = 0.1833
 I^2 = 50.8% (0.0% to 76.1%); H = 1.43 (1.00 to 2.05)

     Q d.f. p-value
 18.30    9  0.0318
```

最初に見るのは、Random effects model の行です。ランダム効果モデルで統合したリスク比は 0.73（95% 信頼区間 0.61〜0.86）で、脳卒中の発症がプラセボに比べて平均で 27% 少ないという推定です。信頼区間が 1 を含まないので、この差が偶然だけで生じたとは考えにくいと判断できます（信頼区間の意味は 1.1 節（p. 13）で説明しました）。固定効果モデル（Common effect model）の 0.75（0.67〜0.83）より区間が広いのは、試験間の真の効果のばらつき（$\tau^2 = 0.034$）も不確かさに数えるからです。Prediction interval から下の行（tau^2、I^2、H、Q）は 6.1 節（p. 58）で読むので、初めて読むときは飛ばして構いません。

発展 method = "MH" とすると、固定効果モデルに Mantel-Haenszel 法を使います。事象の少ない試験が多いときに逆分散法より安定し、RevMan の既定値でもあります。metabin は method を書かないと method = "MH" になります。このとき Mantel-Haenszel 法になるのは固定効果モデルだけで、ランダム効果モデルは逆分散法のままです。この章のコードで method = "Inverse" と書いたのはそのためです。この例の固定効果の値は、逆分散法で 0.7481、Mantel-Haenszel 法で 0.7456 と小数第 3 位から違うだけで、小数第 2 位までは同じ 0.75（0.67〜0.83）です。片方の群で事象が 0 件の試験は、各セルに 0.5 を足して（連続補正）計算されます。両群とも 0 件の試験は効果の向きの情報を持たないので、既定では統合から外れます。
事象がまれなときの方法は、Cochrane ハンドブック（10.4.4）が整理

しています。事象の割合が 1% を下回り、2 群の人数が大きく違わず、効果もあまり大きくないときは、Peto 法の偏りが最も小さく、検出力も高いと報告されています（Bradburn 2007）。Peto 法は、各試験で観察された事象数と、群の差がないと仮定したときに期待される事象数との差から、オッズ比を直接求める方法です。連続補正が要らないので、事象が 0 件の群があっても使えますが、オッズ比にしか使えません（metabin では method = ”Peto”）。事象がそれより多いときは、連続補正をしない Mantel-Haenszel 法が勧められます。0.5 を足す連続補正は、推定値を差なしの方向へ偏らせる欠点があります。

5.7
τ^2 の推定法と信頼区間の作り方

ランダム効果モデルでは、τ^2 をデータから推定してから重みを決めます。この章では REML という推定法を使いました。試験が少ないときは、区間が狭くなりすぎるのを補う HKSJ 法の区間も並べて比べます。降圧薬 A の 10 試験では、REML の通常の区間が 0.61〜0.86、HKSJ 法の区間が 0.59〜0.89 で、HKSJ 法のほうが広くなりました。

発展 推定法と区間の作り方の詳細

ランダム効果モデルでは、τ^2 をデータから推定してから重みを決めます。推定法にはいくつかあり、論文の方法の欄に書くべき選択です。古くから使われてきたのが DerSimonian-Laird 法（DL 法、DerSimonian 1986）で、多くのソフトの既定値でしたが、試験数が少ないと τ^2 を小さく見積もりやすいことが知られています。現在は REML（制限付き最尤法）や Paule-Mandel 法が勧められることが多く、meta パッケージの既定値でこの例でも使った REML は、その一つです。

信頼区間の作り方にも選択肢があります。正規分布を使う標準的な方法は、試験数が少ないと区間が狭くなりすぎ、95% のはずの区間が真の値を含む割合がそれより低くなります。Hartung-Knapp-Sidik-Jonkman 法（HKSJ 法。Hartung-Knapp 調整とも呼ばれます）は、各試験の推定値が統合値からどれだけ散らばっているかを使って標準誤差を計算し直し、正規分布の代わりに t 分布で区間を作る方法です。t 分布は t 検定で使うものと同じで、試験の数（自由度）が少ないほど区間が広くなります。この方法は、試験数が少ないときの区間の狭さを補います（Hartung 2001、Sidik 2002、IntHout 2014）。

```
m_hk <- update(m, method.random.ci = "HK")
m_hk
```

```
                         RR           95% CI    z|t  p-value
Random effects model 0.7281 (0.5930 to 0.8938) -3.50   0.0067
```

update は、前の結果の設定を一部だけ変えて計算し直す関数です。点推定は変わらず、95% 信頼区間は 0.59〜0.89 に広がり、p 値は 0.0003 から 0.0067 になりました。HKSJ 法は区間を広げることが多い方法ですが、いつも適切とは限りません。Cochrane ハンドブック（10.10.4）によると、試験が 2 本か 3 本しかないときは区間が広すぎることがあり、τ^2 が 0 と推定されたときは逆に狭すぎることがあります。後者への対策として、HKSJ 法の標準誤差が標準的な方法より小さくなるときは標準的な方法の値を使う修正も提案されています（IntHout 2014。meta では adhoc.hakn.ci 引数）。どちらの区間を主解析にするかは、データを見る前に計画へ書き、他方は感度分析として並べます。

5.8
フォレストプロットを読む

統合の結果は、フォレストプロットという図で示します。forest 関数に metabin の結果を渡すと描けます。

```
forest(m, sortvar = TE,      # 効果の大きさの順に並べる
       label.left  = "降圧薬 A が有利",
       label.right = "プラセボが有利")
```

Mac で日本語が四角に化けるときは、forest の中に fontfamily = ”Hiragino Sans” を足します。図 5.3 は、付録 A のスクリプトで列を減らして保存したものです。

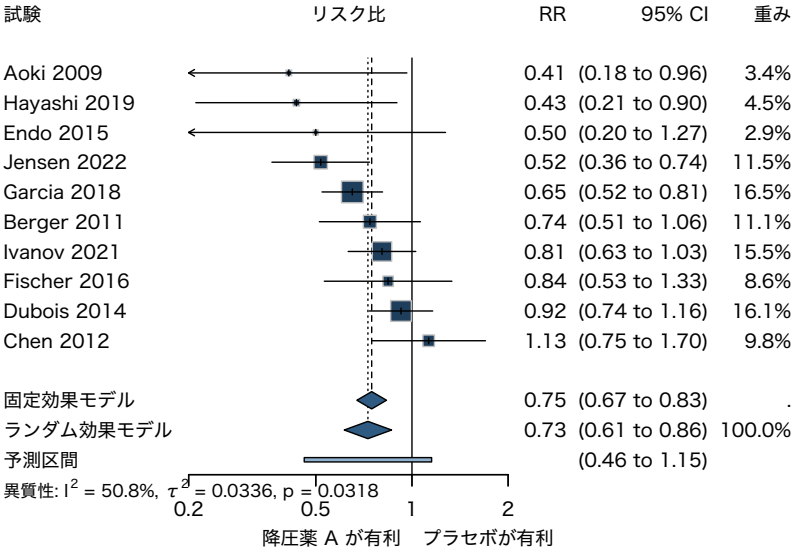


図 5.3　降圧薬 A の 10 試験のフォレストプロット（架空のデータ）

図 5.3 は、上から次の部品でできています。

試験の行　1 行が 1 試験です。四角が点推定、左右の横線が 95% 信頼区間を表します。四角の面積は重みに比例するので、Garcia 2018 や Ivanov 2021 の四角が大きく描かれています。横線が縦の実線（リスク比 1、効果なし）と交わらない試験は、その試験だけで有意な差を示したことになります。

菱形　統合した結果です。菱形の中心が点推定、左右の端が 95% 信頼区間です。上が固定効果モデル、下がランダム効果モデルで、ランダム効果モデルの菱形のほうが横に長くなっています。

予測区間の帯　菱形の下の横帯が予測区間で、読み方は 6.3 節（p. 62）で説明します。菱形よりずっと広く、右端がリスク比 1 を越えています。その下に I^2、τ^2、異質性の検定の p 値が出ます。

縦の点線　統合した効果の位置を示す補助線です。横軸は対数目盛（5.1.2 節（p. 43））で、右端の列は各試験のリスク比、95% 信頼区間、ランダム効果モデルでの重みです。

10 試験のうち信頼区間が 1 をまたがないのは 4 試験だけで、残りの 6 試験は単独では有意差なしでした。それでも点推定はほとんどが 1 より左にあり、統合すると菱形は 1 から離れました（1.3 節（p. 16））。一方で Chen 2012 のように点推定が 1 より右の試験もあります。

5.9 発展 L'Abbé プロットで両群の発症割合を見る

フォレストプロットはリスク比だけを示すので、各試験で脳卒中がどれくらい起きていたのかは分かりません。L'Abbé（ラベ）プロットは、各試験の 2 つの群の発症割合そのものを、1 試験を 1 点として置く図です。

```
labbe(m, random = TRUE, common = FALSE)
```

横軸はプラセボ群の発症割合、縦軸は降圧薬 A 群の発症割合です。円の

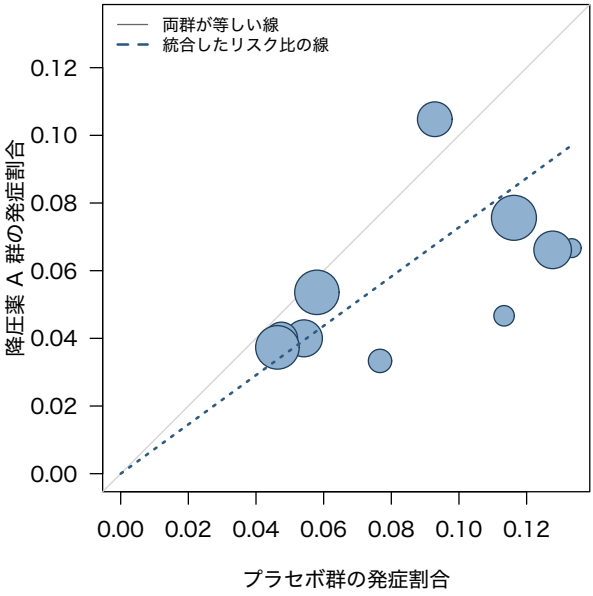


図 5.4　降圧薬 A の 10 試験の L'Abbé プロット。円の大きさは重み、細い実線は両群が等しい線、破線は統合したリスク比（0.73）の線

中心がその試験の 2 つの割合の組で、円の面積は重みに対応します。左下から右上への細い実線は、両群の発症割合が等しい（リスク比 1）位置です。この線より下にある試験は降圧薬 A 群のほうが発症が少なく、上にある試験は多いことを表します。破線は、統合したリスク比 0.73 に対応する線で、プラセボ群の割合に 0.73 をかけた位置を通ります。

図 5.4 では、ほとんどの試験が実線の下にあり、降圧薬 A が脳卒中を減らす方向にそろっていることが一目で分かります。実線の上にあるのは Chen 2012 だけで、1.2 節（p. 14）で見た点推定 1.13 に対応します。点が破線のまわりでどれくらい散らばるかを見れば、異質性の大きさの見当もつきます（6.1 節（p. 58））。また、試験ごとの対照群の発症割合が、横軸の上でおよそ 5% から 13% に広がっていることも、この図ではっきりします。リスク比が同じでも、発症割合が高い試験ほど実線からの距離が大き

く、防げる人数は多くなります。この関係は、7.9 節（p. 83）の結果の要約表で、対照群のリスクを置いて人数に直す理由になっています。

5.10 この章のまとめ

効果指標にはリスク比を選び、対数をとって、推定値の分散の逆数を重みにして平均します。主解析は、真の効果が試験ごとに違うと考えるランダム効果モデルとし、τ^2 は REML で推定します。試験数が少ないときの区間の狭さは、HKSJ 法の区間を並べて確かめます。metabin の出力では、まずランダム効果モデルの行を見ます。どちらを主解析にするかは、データを見る前に計画へ書きます。降圧薬 A の 10 試験では、リスク比は 0.73（95% 信頼区間 0.61〜0.86）、HKSJ 法の区間は 0.59〜0.89 でした。フォレストプロットでは、試験ごとの結果と菱形、予測区間をあわせて読みます。第 6 章（p. 58）では、試験間のばらつきを調べます。

第 6 章

試験間のばらつきを読む

この章で分かること

統合した値が同じ 0.73 でも、試験の結果がそろっているときと、大きく食い違っているときでは、意味が違います。試験間のばらつき（異質性）を測る三つの数と、予測区間の読み方を説明します。続いて、ばらつきの原因を特徴ごとに探すサブグループ解析を降圧薬 A の例で実行します。原因になっている試験を探す Baujat プロットと、連続した特徴で探すメタ回帰は発展の節に置いてあり、初読では飛ばせます。

6.1 ばらつきを測る三つの数

5.6 節（p. 50）の出力には、統合した効果の下に Q、I^2、τ^2 という三つの数が並んでいました。どれも試験間のばらつきに関係する数ですが、測っているものが違います。

Q 統計量　各試験の推定値が統合した値からどれだけ離れているかを、重みを付けて 2 乗して足した値です（重みは 5.1.3 節（p. 43）で説明し

た分散の逆数です)。各試験の対数リスク比を y_i、その重みを w_i、統合した値を $\bar{y}$ とすると、$Q = \sum_i w_i(y_i - \bar{y})^2$ と書けます（$\sum_i$ は全試験を足すという記号です)。試験の結果のばらつきが偶然だけなら、Q はおおよそ自由度（試験数 − 1）くらいの値になります。自由度は t 検定で使うものと同じ考え方で、この場合は試験数から 1 を引いた数です。降圧薬 A では Q = 18.30 で、自由度 9 のおよそ 2 倍でした。Q を使った異質性の検定の p 値は 0.032 です。

I^2 試験の結果の散らばりのうち、偶然のぶれでは説明できない部分の割合です。Q と自由度から（Q − 自由度）÷ Q で計算し（Higgins 2002)、降圧薬 A では（18.30 − 9）÷ 18.30 で 51% になります。

τ^2 真の効果の散らばりそのものの大きさです。ランダム効果モデルの研究間分散（5.4 節（p. 46））で、効果指標と同じ目盛（ここでは対数リスク比）で表されます。降圧薬 A では $\tau^2 = 0.034$、その平方根の τ は 0.18 でした。

異質性の検定は、試験数が少ないと差を検出できません。10 試験程度では、本当にばらつきがあっても p 値が 0.05 を下回らないことがよくあります。そのため、p 値が 0.05 以上でも「異質性はない」とは結論できません。有意水準を 0.10 にする慣習もありますが、検定の結果だけで判断しないほうが安全です。

I^2 は割合なので、効果の散らばりの大きさそのものは表しません。

> 発展 同じ τ^2 でも、一つ一つの試験が大きく精度が高いほど偶然のぶれが小さくなるので、I^2 は大きくなります。たとえば第 2 部に出てくる検査の研究のように、人数の多い研究を集めると、臨床的には小さな違いでも I^2 が 90% を超えることがあります。

I^2 を 25%、50%、75% で「小さい、中くらい、大きい」と区切る目安が使われることがありますが（Higgins 2003)、この区切りは臨床的な重大さを表すものではありません。I^2 には信頼区間も付きます。降圧薬 A の I^2

は 51% でしたが、95% 信頼区間は 0〜76% と広く、10 試験では異質性の程度をほとんど決められないことを示しています。

> 発展 Cochrane ハンドブック（10.10.2）は、0〜40%、30〜60%、50〜90%、75〜100% という重なりのある範囲を、それぞれ重要でない可能性、中等度、相当、非常に大きいの大まかな目安として挙げ、閾値で機械的に異質性を判断しないよう注意しています。

τ^2 は対数の目盛なので、そのままでは読みにくい数です。$\tau = 0.18$ は、真のリスク比が平均の 0.73 から、おおよそ 0.51〜1.04 の範囲に散らばっていることを表します。この幅を、統合した値の不確かさも含めて表したものが、次に説明する予測区間です。

6.2 発展 ばらつきの原因になっている試験を探す

Q と I^2 は異質性の大きさを一つの数で示すだけで、どの試験がそれを作っているかは教えてくれません。Baujat（ボジャ）プロットは、試験ごとに 2 つの数を計算して 1 点として置く図です。

```
baujat(m)
```

横軸は、その試験が Q にどれだけ寄与しているかです。統合した値から大きく離れていて、しかも精度が高い試験ほど右に来ます。縦軸は、その試験を除いて統合し直したときに統合結果がどれだけ動くかです。右にあるほど異質性の原因になっており、上にあるほど結果への影響が大きいことになります。

図 6.1 では、Dubois 2014 が右上に離れて位置しています。2,500 人ずつの大きな試験で、点推定が 0.92 と統合値の 0.73 から離れているため、Q への寄与も、除いたときの統合結果の動きも大きい試験です。Jensen 2022

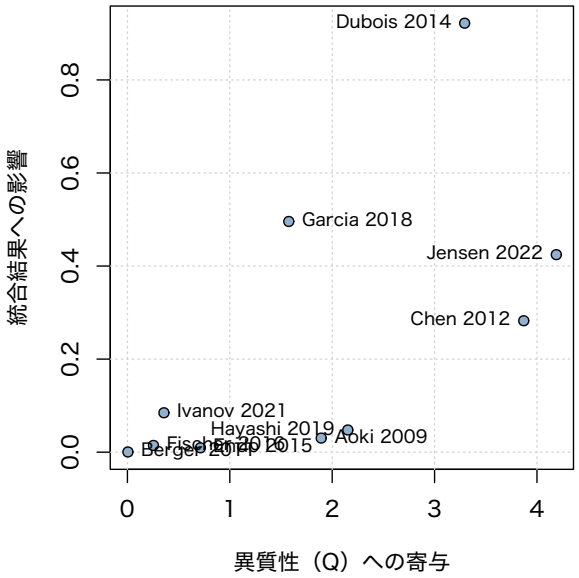


図 6.1　降圧薬 A の 10 試験の Baujat プロット。点の横の文字は試験名

と Chen 2012 は Dubois 2014 よりさらに右にあり、Q への寄与はいっそう大きいものの、縦の位置は低く、除いても統合結果はそれほど動きません。Jensen 2022 は統合値より効果が大きい側に、Chen 2012 は逆向き（点推定 1.13）に外れた試験で、外れる向きは反対です。Baujat プロットの既定の計算は固定効果モデルに基づくので、7.6 節（p. 77）のランダム効果モデルで 1 試験ずつ除く解析の数値とは一致しません。

Baujat プロットは、異質性の原因を探す探索用の図です。右上にある試験を見つけたら、その試験の対象、介入、追跡期間、バイアスのリスクに他の試験と違う点がないかを調べる手がかりにします。外れているという理由だけで、その試験を解析から除く根拠にはなりません。除くかどうかは、計画書に書いた基準で決めます。

6.3
予測区間と信頼区間

信頼区間の意味が分かりにくいときは 1.1 節（p. 13）を、τ^2 が分かりにくいときは 5.4 節（p. 46）を読み直してください。

ランダム効果モデルの 95% 信頼区間 0.61〜0.86 は、真の効果の平均がどこにあるかを表す区間です。試験を増やしていけば、この区間はいくらでも狭くなります。一方で、試験ごとの真の効果は τ だけ散らばっているので、平均が正確に分かっても、ある一つの場面での効果は平均からずれます。

予測区間は、新しい試験を一つ行ったとき（あるいは自分の施設で使ったとき）に、その場面での真の効果がどこに来そうかを表す区間です（Riley 2011）。平均の不確かさと、τ^2 で表される真の効果の散らばりの両方を含むので、信頼区間より必ず広くなります。降圧薬 A の予測区間は 0.46〜1.15 でした。予測区間は meta の出力にすでに含まれています（5.6 節（p. 50）で prediction = TRUE としました）。二つの区間の違いを表 6.1 に示します。

	信頼区間	予測区間
何の区間か	真の効果の平均がある範囲	新しい一つの試験の真の効果が来そうな範囲
試験を増やすと	狭くなる	τ の分だけ広いまま残る
降圧薬 A	0.61〜0.86	0.46〜1.15
使う場面	平均の効果があるかを見る	自分の場面で効果が期待できるかを見る

表 6.1　信頼区間と予測区間の違い（降圧薬 A のランダム効果モデル）

予測区間が 1 をまたいでいるので、降圧薬 A の平均の効果は確かでも、試験を行う場面によっては効果がほとんどない、あるいは逆向きの場面もありうると読みます。メタ解析の結果を診療ガイドラインや施設の方針に使うときには、信頼区間だけでなく予測区間も報告することが勧められて

います（IntHout 2016）。

発展 予測区間の計算と作図

図 6.2 は、信頼区間と予測区間の違いを、試験ごとの真の効果の分布と並べて描いたものです。

```
mu  <- m$TE.random          # 真の効果の平均（対数リスク比）
tau <- sqrt(m$tau2)         # 真の効果のばらつき
x <- seq(log(0.35), log(1.6), length.out = 400)
plot(exp(x), dnorm(x, mu, tau), type = "l", log = "x",
     ylim = c(-0.9, 2.3), yaxt = "n", ylab = "",
     xlab = "リスク比（対数目盛）")
abline(v = 1, lty = 2)
segments(exp(m$lower.random), -0.3,    # 信頼区間
         exp(m$upper.random), -0.3, lwd = 5)
segments(exp(m$lower.predict), -0.7,   # 予測区間
         exp(m$upper.predict), -0.7, lwd = 5)
```

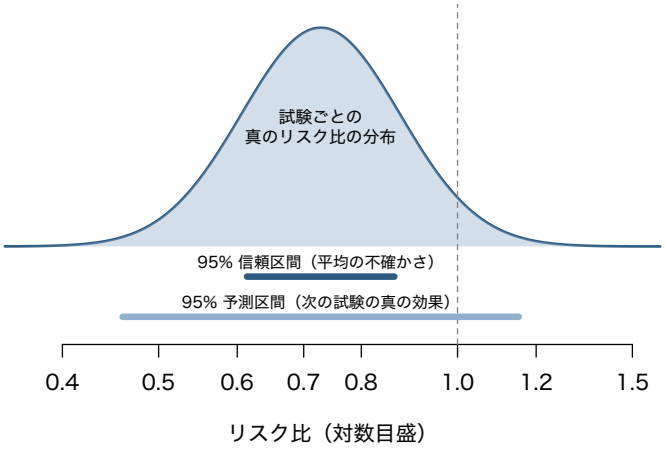


図 6.2　試験ごとの真のリスク比の分布（平均 0.73、$\tau = 0.18$）と、95% 信頼区間（0.61〜0.86）、95% 予測区間（0.46〜1.15）

釣り鐘の曲線は、試験ごとの真のリスク比が平均 0.73、$\tau = 0.18$（対数目盛で）の分布に従うという、ランダム効果モデルの考え方を描いたものです。この分布の中央 95% は、平均の対数 $\pm$ 1.96 τ を比に戻した 0.51〜1.04 にあたります。横軸はリスク比の対数目盛で、点線が 1（差なし）です。上の太い線が 95% 信頼区間で、この分布の平均がどこにあるかの不確かさを表し、1 をまたぎません。下の太い線が 95% 予測区間で、これから行う一つの試験の真の効果がどこに来そうかを表します。分布そのものの広がりを含むので、信頼区間よりずっと長く、右端が 1 を越えます。

図の曲線は平均と τ をそのまま使った近似で、予測区間の端とは一致しません。予測区間は平均の推定の不確かさも含めて t 分布で計算しており、10 試験では τ そのものの推定も不安定なので、結果は目安として扱います。

6.4 サブグループ解析

ばらつきがあると分かったら、次はその原因を探します。最も単純な方法がサブグループ解析で、試験をある特徴で群に分け、群ごとに統合して比べます。降圧薬 A では、計画の段階で「高齢者を対象にした試験とそれ以外で効果が違うか」を調べると決めていたとします。

```
m_sub <- update(m, subgroup = pop)
m_sub
```

```
Results for subgroups (random effects model):
              k     RR           95% CI   tau^2
pop = 高齢者  5 0.6470 (0.4606 to 0.9089) 0.0856
pop = 一般    5 0.8221 (0.7139 to 0.9467) <0.0001

Test for subgroup differences (random effects model):
                  Q d.f. p-value
```

```
Between groups 1.63    1  0.2020
```

高齢者を対象にした 5 試験ではリスク比 0.65（0.46〜0.91）、一般の成人の 5 試験では 0.82（0.71〜0.95）でした。点推定だけ見ると高齢者で効果が大きいようですが、二つの群の差の検定は p = 0.20 で、差があるとは言えません。図 6.3 では、高齢者の群の中でも Chen 2012 だけが 1 より右にあり、群の中のばらつき（I^2 60%）が大きいことが分かります。

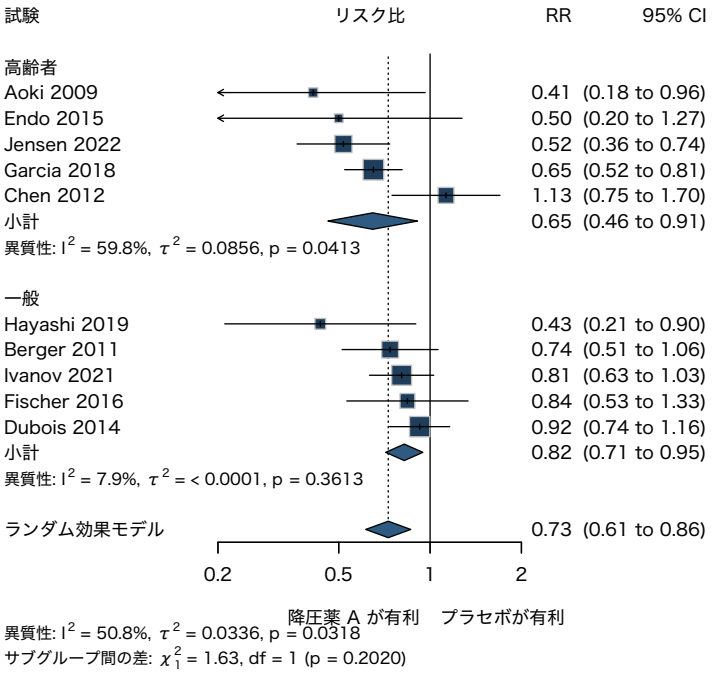


図 6.3　対象集団で分けたフォレストプロット（架空のデータ）

発展 同じ比較を固定効果モデルで行うと、差の検定は Q = 4.01、p = 0.045 となり、有意になります。固定効果モデルは群の中の真の効果のばらつきを無視するので、群の平均の不確かさを小さく見積もり、群の差を検出しやすくなるからです。Cochrane ハンドブック（10.11.3.1）も、サブグループ間の差の検定はランダム効果モデルに基づくもののほうが望ましいとしています。どちらのモデルで検定するかによって結論が変わるこの例は、サブグループ解析の結果がもろいことを表しています。

サブグループ解析を読むときは、次の点を確かめます。

事前に決めていたか　結果を見てから分け方を探すと、偶然の差がいくらでも見つかります。計画書に書いたサブグループかどうかを確かめます。

差の検定を見ているか　一方の群だけ有意で他方が有意でないことは、群の間に差があることを意味しません。群の差そのものの検定（Test for subgroup differences）を見ます。

試験の中の比較か、試験の間の比較か　高齢者の試験と一般の試験は、対象の年齢以外にも、実施した国、時期、併用治療などが違うかもしれません。サブグループ解析で比べているのは試験どうしであり、ランダム化で保証された比較ではないので、観察研究と同じく交絡を受けます。年齢による効果の違いを本当に知りたいなら、各試験の中で年齢別の結果を集めるほうが信頼できます。

群の試験数　1 群に数本しか試験がないと、群ごとの推定も差の検定も不安定です。

バイアスのリスクで分けたサブグループ（低 6 試験 0.74、懸念あり 3 試験 0.63、高 1 試験 0.50。差の検定 p = 0.67）も同じように計算できます。こちらは 7.6 節（p. 77）の感度分析で扱います。

発展の 6.2 節（p. 60）で紹介した Baujat プロットのように、外れた試験

を見つけて異質性の原因の手がかりにすることはできますが、外れているというだけでその試験を解析から除く根拠にはなりません。除くかどうかは、計画書に書いた基準で決めます。

対象の平均年齢や投与量のような連続した特徴で効果の違いを調べる方法をメタ回帰と呼び（発展の 6.5 節（p. 67））、14.2 節（p. 163）では検査のカットオフを共変量にして同じ考え方を使います。サブグループ解析もメタ回帰も、説明に使う特徴 1 つあたり少なくとも 10 試験が必要とされています（介入の Cochrane ハンドブック）。降圧薬 A のように試験が 10 本前後しかないときは、事前に決めた 1 つの特徴にとどめ、結果は仮説の提示として扱います。また、これらが扱うのは試験の平均の特徴なので、試験単位の関連を個人の関連と読み替える誤り（生態学的誤謬）に注意が要ります。たとえば対象の平均年齢と効果に関連があっても、各試験の中で高齢の人ほど効果が大きいとは限りません。

6.5
発展 メタ回帰

サブグループ解析を、連続した特徴（対象の平均年齢、試験の年、投与量など）に広げたものがメタ回帰です。試験ごとの効果の大きさを、試験の特徴で説明する回帰分析で、点の大きさが重みに対応します。回帰直線の傾きは、特徴が 1 単位増えたときの効果の変化を表し、切片は特徴が 0 のときの効果を表します。

降圧薬 A の 10 試験では、メタ回帰を行う目安（サブグループ解析の節の終わりに述べました）にぎりぎり届く程度です。そこで、13 試験ある実データを使います。R の metadat パッケージに入っている dat.bcg は、結核を予防する BCG ワクチンの 13 の RCT をまとめたデータです（Colditz 1994）。メタ解析の教科書で繰り返し使われてきた例で、試験を行った土地の緯度（ablat）が記録されています。

```
library(metafor)   # meta と並ぶメタ解析のパッケージ
dat <- escalc(measure = "RR",
              ai = tpos, bi = tneg,   # ワクチン群
              ci = cpos, di = cneg,   # 対照群
              data = dat.bcg)
r0 <- rma(yi, vi, data = dat, method = "REML")
r1 <- rma(yi, vi, mods = ~ ablat, data = dat,
          method = "REML")
r1
```

escalc は試験ごとの対数リスク比（yi）とその分散（vi）を計算する関数で、rma がランダム効果モデルの当てはめです。mods に説明に使う特徴を書くとメタ回帰になります。まず緯度を入れないモデル（r0）の結果は、リスク比 0.49（0.34〜0.70）、$I^2 = 92\%$、予測区間 0.15〜1.55 で、効果は試験によって大きく散らばっていました。

これを試験ごとに見るには、フォレストプロットを緯度の順に並べます。metagen は、試験ごとの効果とその標準誤差（分散の平方根）をそのまま統合する関数です。

```
mb <- metagen(yi, sqrt(vi), data = dat, sm = "RR",
              studlab = paste(author, year),
              common = FALSE)
forest(mb, sortvar = ablat,            # 緯度の順に並べる
       leftcols = c("studlab", "ablat"))
```

図 6.4 の横軸は対数目盛のリスク比で、1 より左ならワクチン群で結核が少ないことを表します。最下段の菱形がランダム効果モデルで統合した結果で、リスク比 0.49（0.34〜0.70）です。しかし I^2 は 92% と非常に大きく、統合した値は個々の試験の結果をあまり代表していません。試験の行を上から順に追うと、緯度が低い（上の）試験では区間が 1 を含むか 1 に近く、緯度が高い（下の）試験ほど区間が 1 から離れて左に寄る傾向が見えます。試験の並べ方を変えるだけで、ばらつきに並び方（パターン）があることが分かります。この並び方を数にするのが、次のメタ回帰です。

緯度を入れたモデル（r1）の出力の要点を抜き出します。

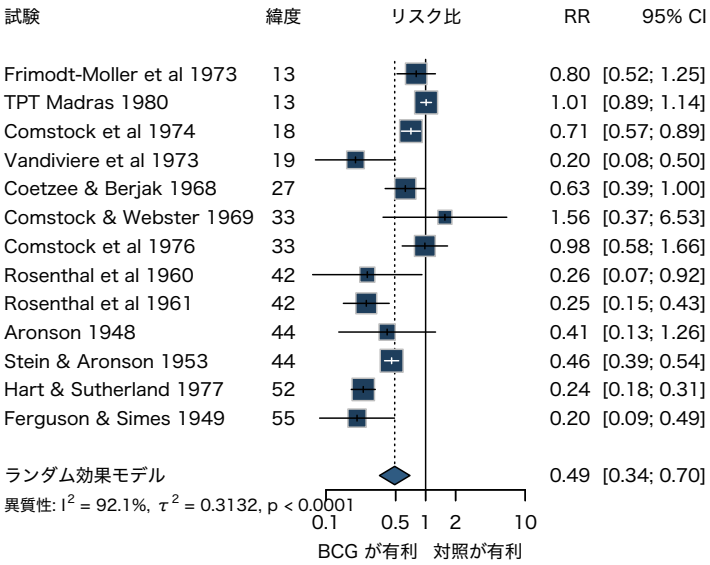


図 6.4　BCG ワクチンの 13 試験のフォレストプロット。緯度（左から 2 列目）の低い順に並べた

```
tau^2 (estimated amount of residual heterogeneity): 0.0764
I^2 (residual heterogeneity / unaccounted variability): 68.39%
R^2 (amount of heterogeneity accounted for):            75.62%

Test of Moderators (coefficient 2):
QM(df = 1) = 16.3571, p-val < .0001

         estimate      se     zval    pval    ci.lb    ci.ub
intrcpt    0.2515  0.2491   1.0095  0.3127  -0.2368   0.7397
ablat     -0.0291  0.0072  -4.0444  <.0001  -0.0432  -0.0150
```

ablat の係数（傾き）− 0.029 は、緯度が 1 度上がるごとに対数リスク比が 0.029 下がる、つまりワクチンの効果が大きくなることを表します。切

片 0.25 は緯度 0 度のときの対数リスク比です。R^2 の 76% は、試験間の真の効果のばらつき（τ^2）のうち 76% を緯度で説明できたという意味で、τ^2 は 0.31 から 0.076 に減りました。それでも残りのばらつき（残差の I^2 68%）は小さくありません。緯度 20 度、40 度、55 度での予測リスク比は、それぞれ 0.72（0.55〜0.93）、0.40（0.32〜0.51）、0.26（0.17〜0.38）です。

試験数が少ないメタ回帰では、発展の 5.7.1 節（p. 52）で説明した Hartung-Knapp 調整を係数の検定と区間に使うことが多く、metafor では rma() に test = "knha" を足すだけです。

```
r1k <- rma(yi, vi, mods = ~ ablat, data = dat,
           method = "REML", test = "knha")
```

調整すると、ablat の係数は同じ − 0.029 のまま、p 値は 0.0046、95% 信頼区間は − 0.047〜− 0.011 となり、区間は広がりますが、緯度が高いほど効果が大きいという結論は変わりません。

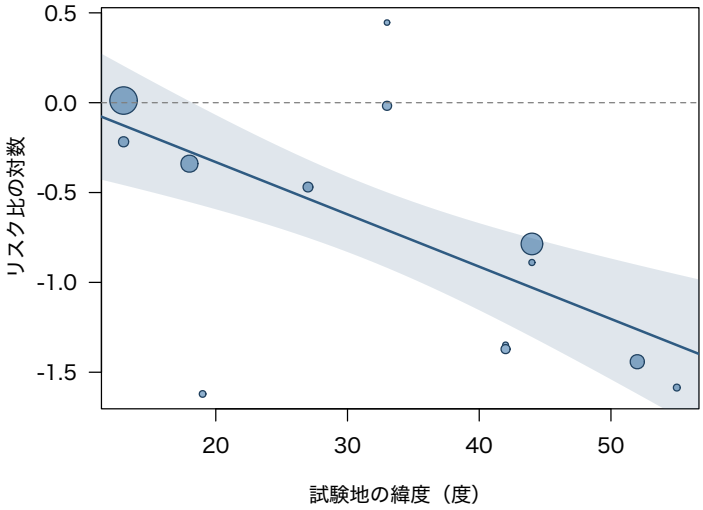


図 6.5　BCG ワクチンの 13 試験のメタ回帰。円の大きさは重み、帯は回帰直線の 95% 信頼区間

赤道に近い地域では、環境中の抗酸菌にもともと触れているためにワクチンの上乗せ効果が小さくなる、という説明が考えられてきました。ただし、メタ回帰で見つかった関連は、試験の間の観察にすぎません。緯度の違う試験は、実施した年代、割り付けの方法、対象の年齢なども違っており、緯度がそれらの代わりに関連を示している可能性があります。

6.6 この章のまとめ

異質性は三つの数で見ます。Q と検定は試験数が少ないと差を検出できず、I^2 は偶然では説明できない散らばりの割合であって散らばりの大きさではなく、τ^2 が真の効果の散らばりそのものです。降圧薬 A の予測区間 0.46〜1.15 は 1 をまたいでおり、平均の効果が明らかでも、場面によって効果が小さくなりうることを示しています。サブグループ解析は試験どうしの比較なので交絡を受け、事前に決めた少数の特徴にとどめます。降圧薬 A の対象集団による違いは、ランダム効果モデルでは有意ではありませんでした。発展の節で扱った Baujat プロットとメタ回帰は、異質性の原因を探す手がかりであり、除外や因果の根拠にはなりません。次の章では、集めた試験そのものに偏りがないか、結果がどこまで確かかを調べます。

第 7 章

結果を疑い、確かさを評価する

この章で分かること

統合した結果は、集めた試験に偏りがあれば偏ったままです。発表されなかった試験が抜け落ちていないかをファネルプロットと Egger 検定で調べ、解析の選び方で結論が変わらないかを感度分析で確かめます。最後に GRADE の考え方で、降圧薬 A の結果がどこまで確かかを判定し、結果の要約表にまとめます。固定効果モデルとランダム効果モデルの比較、累積メタ解析、1000 人あたりの人数を描く図は発展の節に置いてあり、初読では飛ばせます。

7.1 出版バイアスと小規模研究効果

有意な結果が出た試験は論文になりやすく、有意差の出なかった試験は投稿されなかったり、掲載が遅れたり、知名度の低い雑誌に載ったりします。その結果、文献データベースで見つかる試験は、行われた試験全体よりも効果が大きい側に偏ります。これを出版バイアスと呼びます。メタ解析は見つかった試験しか統合できないので、出版バイアスがあれば統合した効果も大きく出ます。

出版バイアスは、小さな試験で特に起こりやすい偏りです。大きな試験は費用と手間がかかっているので、結果にかかわらず発表されることが多い一方、小さな試験は効果が大きく出たときだけ発表される傾向があります。このため、小さな試験ほど効果が大きく出る傾向（小規模研究効果）が、出版バイアスの手がかりになります。ただし、小規模研究効果の原因は出版バイアスだけではありません。小さな試験は方法の質が低いことが多く（割り付けの隠蔽が不十分、など）、その分だけ効果が大きく出ることがあります。対象の重症度が違う、介入の強さが違う、といった本当の違いが原因のこともあります。小規模研究効果を見つけても、それがすなわち出版バイアスだとは言えない点に注意します。

7.2 ファネルプロットを読む

小規模研究効果を目で見る図がファネルプロットです。横軸に各試験の効果（ここではリスク比、対数目盛）、縦軸に標準誤差をとって試験を点で置きます。縦軸は上ほど標準誤差（5.1.1 節（p. 43））が小さく、つまり大きな試験が上に来るように逆向きにとります。

```
funnel(m, common = FALSE,
       xlab = "リスク比（対数目盛）")
```

偏りがなければ、大きな試験は統合値の近くに集まり、小さな試験は左右に広く散らばるので、点は上がとがった漏斗（funnel）を逆さにした形に、左右対称に並びます。小さな試験のうち効果の小さい側（図の右下）が発表されずに抜けていると、左右が非対称になります。

図 7.1 では、下の方にある小さな試験（Endo 2015、Aoki 2009、Hayashi 2019）がそろって左側、つまり効果の大きい側にあり、右下はがら空きです。小さくて効果のない試験が抜けているのかもしれない、という読み方ができます。ただし、点が 10 個しかないと、偶然でもこの程度の非対称は

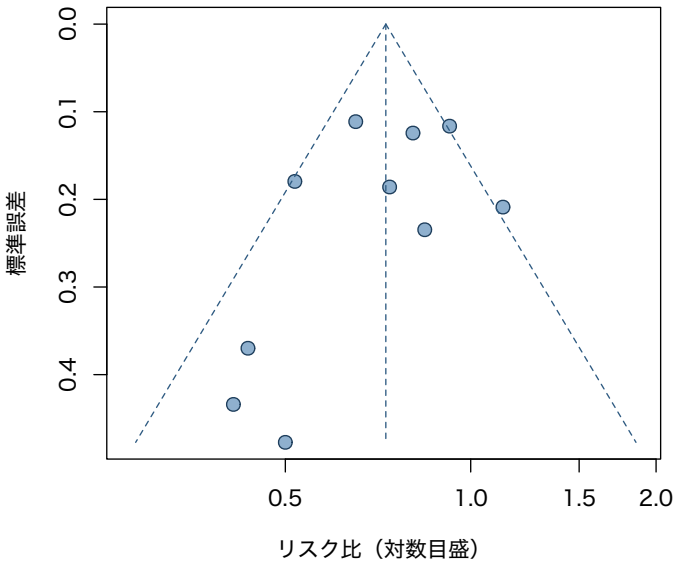


図 7.1　降圧薬 A の 10 試験のファネルプロット（架空のデータ）。縦の破線はランダム効果モデルの統合値、斜めの破線はその値から 95% の範囲

よく起こります。目で見た印象は人によって違うので、数で確かめる方法が次の Egger 検定です。

7.3 Egger 検定

Egger 検定は、ファネルプロットの非対称を数で見る検定です（Egger 1997）。試験が 10 本未満では当てになりません。

```
metabias(m, method.bias = "Egger", k.min = 10)
```

```
Linear regression test of funnel plot asymmetry
```

```
Test result: t = -1.17, df = 8, p-value = 0.2741
Bias estimate: -1.2370 (SE = 1.0535)
```

p = 0.27 で、非対称さは有意ではありませんでした。しかし、この結果から「出版バイアスはない」とは言えません。Egger 検定は試験数が少ないと検出力が低く、本当に偏りがあっても見逃しやすい検定です。目安として、試験数が 10 本未満ならファネルプロットの検定は行わないことが勧められており（Sterne 2011）、meta パッケージも既定では 10 本未満のときに計算しません（上の k.min = 10 はその下限です）。降圧薬 A の 10 試験は、ちょうどその下限にあたります。

発展 Egger 検定は、ファネルプロットの非対称さを回帰で調べます。各試験の効果を標準誤差で割った値（どれだけ 0 から離れているか）を、精度（標準誤差の逆数）に対して回帰し、切片が 0 からずれているかを検定します。小さな試験ほど効果が大きく出ていれば、切片が 0 からずれます。試験の大きさがどれも似ているときや、異質性が大きいときも、この検定は当てになりません。効果指標がオッズ比のときは、Egger 検定そのものが勧められていません。Cochrane ハンドブック（13.3.4.4）は、オッズ比では Harbord の検定や Peters の検定を使うよう勧めています（metabias の method.bias で選べます）。降圧薬 A はリスク比なので、Egger 検定のまま進めます。

7.4 発展 固定効果とランダム効果の比較、選択モデル、trim and fill

Egger 検定のほかに、小規模研究効果の大きさを調べる方法として、固定効果モデルとランダム効果モデルの統合値を比べる方法があります。ランダム効果モデルは小さな試験に相対的に大きい重みを与えます。5.4 節

（p. 46）の数値では、Endo 2015 の重みは固定効果モデルの 1.3% からランダム効果モデルの 2.9% に増え、Garcia 2018 は 23.9% から 16.5% に減りました。そのため、小さな試験ほど効果が大きく出ているときは、ランダム効果モデルの統合値のほうが固定効果モデルより効果を大きく見せます。この比較が使えるのは、試験の間にばらつきがある（$\tau^2 > 0$）ときだけです（Cochrane ハンドブック 13.3.4.6）。ばらつきがなければ、二つのモデルは同じ値になり、比べる意味がありません。

```
round(exp(c(common = m$TE.common,
            random = m$TE.random)), 2)
```

```
common random
  0.75   0.73
```

降圧薬 A では固定効果モデルが 0.75（0.67〜0.83）、ランダム効果モデルが 0.73（0.61〜0.86）で、差は小さく、向きもランダム効果のほうが効果を大きく見せる側ですが、結論を変える大きさではありません。この比較は、小規模研究効果の影響を大まかに確かめる感度分析として使います。このほか、Cochrane ハンドブックは、出版されやすさを統計モデルで表す選択モデルと、標準誤差などの試験の特徴で効果を回帰する方法を挙げています。いずれも専門家と相談して使う方法なので、この冊子では名前の紹介にとどめます。

論文では trim and fill という方法をよく見かけます。ファネルプロットが左右対称になるように、欠けていると推定される試験を反対側に補って統合し直す方法です。この冊子では使いません。非対称の原因がすべて出版バイアスで、欠けた試験がちょうど対称の位置にあるという強い仮定に立ち、異質性が大きいと性能が悪く、補った試験は実在しないので、補った後の値を補正後の効果として読むことはできないからです。

ファネルプロットと検定が調べているのは小規模研究効果であり、出版バイアスがあるかないかをそれだけで決めることはできません。Cochrane ハンドブック第 13 章（13.3）は、ROB-ME（risk of bias due to missing

evidence、Page 2023）という手順を示しています。研究の中で報告されなかった結果と、研究の間で発表されなかった試験の両方について、結果が欠けた理由が結果の向きや有意性に左右されていないかを、構造的に判定する手順です。この判定は、この後の GRADE の出版バイアスの評価につながります。等高線つきファネルプロットは、非対称の原因を見分ける助けになるとして同じ節（13.3.4.3）で取り上げられていますが、この冊子では扱いません。

7.5 未発表の試験を探す

出版バイアスへの対策として最も確かなのは、統計の工夫ではなく、未発表の試験を探すことです。ClinicalTrials.gov や jRCT などの試験登録には、結果が発表されていない試験も登録されています。登録されているのに結果が見つからない試験が多ければ、それ自体が出版バイアスの証拠になります。3.1 節（p. 27）で試験登録を検索先に入れたのはこのためです。

7.6 感度分析

感度分析は、解析の途中で行った選択を変えても結論が変わらないかを確かめる作業です。第 2 部で検査の「感度」が出てきますが、それとは別の言葉です。検査の感度は病気の人を陽性と判定する割合で、メタ解析の感度分析は結果が選択にどれだけ敏感かを調べることを指します。

降圧薬 A では、計画書で次の感度分析を決めておいたとします。

バイアスのリスクが高い試験を除く　RoB 2 で全体の判定が高かった Endo 2015 を除くと、リスク比は 0.74（0.62〜0.88）で、ほとんど変わりま

せんでした。

1 試験ずつ除く　10 試験から 1 本ずつ除いて 10 回統合し直すと、リスク比は 0.70（Chen 2012 または Dubois 2014 を除いたとき）から 0.77（Jensen 2022 を除いたとき）の範囲に収まりました。特定の 1 試験が結論を左右してはいません。

モデルと方法を変える　固定効果モデルでは 0.75（0.67〜0.83）、Hartung-Knapp 法（5.7 節（p. 52））では 0.73（0.59〜0.89）で、どれも 1 を含みませんでした。

出版バイアスを考慮する　固定効果モデル（0.75）とランダム効果モデル（0.73）の統合値を比べました。ランダム効果モデルでは小さな試験の重みが増えます（5.4 節（p. 46）で、Endo 2015 は 1.3% から 2.9%）が、統合値の差は小さく、結論は動きませんでした。この比較は発展の 7.4 節（p. 75）で説明しています。

```
update(m, subset = rob != "高")   # RoB 高を除く
metainf(m, pooled = "random")    # 1 試験ずつ除く
```

subset には残す試験の条件を書きます。!= は「等しくない」という意味です。metainf の結果は forest に渡すと、1 試験ずつ除いた結果のフォレストプロットになります。

```
mi <- metainf(m, pooled = "random")
forest(mi)
```

図 7.2 の各行は、左の列の試験を除いた 9 試験で統合し直した結果です。1 行が四角と横線で示され、最下段が 10 試験すべての結果（0.73、0.61〜0.86）です。四角の位置は 0.70（Chen 2012 または Dubois 2014 を除いたとき）から 0.77（Jensen 2022 を除いたとき）の間にあり、どの行でも区間は 1 をまたいでいません。Jensen 2022 を除くと、点推定は最も 1 に近づきます。効果の大きい試験を除いたためです。Chen 2012 と Dubois 2014 を除くと逆に 0.70 まで下がり、効果が小さい（点推定が 1 に近いか 1 より大きい）試験を除いたことになります。見るのは、全体の結果から大きく

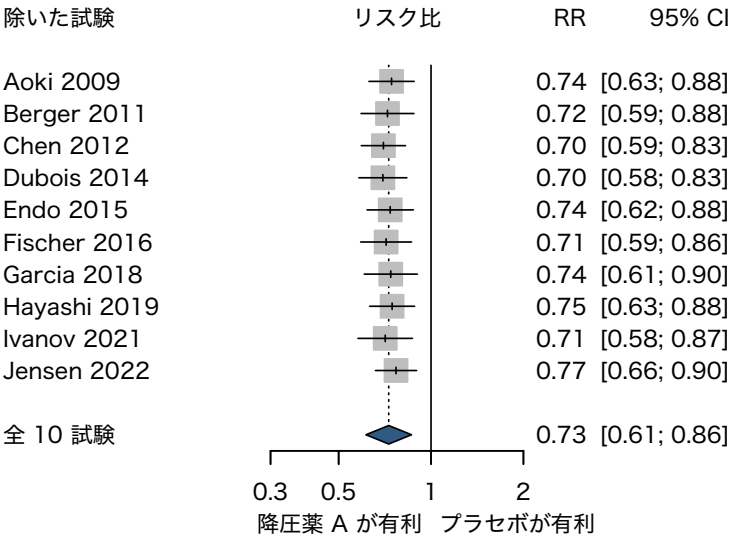


図 7.2　1 試験ずつ除いたときの統合したリスク比（ランダム効果モデル）。各行は、その試験を除いた 9 試験の結果

離れる行があるか、区間が 1 をまたぐ行があるかで、この例ではどちらもありません。

どの感度分析でもリスク比は 0.70〜0.77 の範囲にあり、信頼区間が 1 を含むことはありませんでした。効果の向きと大きさについての結論は、解析の選び方に対して頑健だと言えます。もし感度分析で結論が変わったら、その結果を隠さずに報告し、どちらの結果をどう解釈するかを考察で論じます。

7.7 発展 累積メタ解析

累積メタ解析（1.3.1 節（p. 16）の図 1.1）は、metacum で、発表年の順に足した結果を出せます。

```
year <- as.numeric(sub(".* ", "", bp$study))  # 試験名から年
mc <- metacum(m, sortvar = year, pooled = "random")
mc
forest(mc)
```

```
                          RR            95% CI p-value
Adding Aoki 2009 (k=1)    0.4118 [0.1759; 0.9640]  0.0409
Adding Berger 2011 (k=2)  0.6290 [0.3774; 1.0485]  0.0754
Adding Chen 2012 (k=3)    0.7756 [0.4829; 1.2456]  0.2931
Adding Dubois 2014 (k=4)  0.8704 [0.7086; 1.0692]  0.1860
Adding Endo 2015 (k=5)    0.8343 [0.6613; 1.0525]  0.1265
Adding Fischer 2016 (k=6) 0.8625 [0.7363; 1.0103]  0.0669
Adding Garcia 2018 (k=7)  0.7815 [0.6455; 0.9462]  0.0115
Adding Hayashi 2019 (k=8) 0.7529 [0.6184; 0.9168]  0.0047
Adding Ivanov 2021 (k=9)  0.7690 [0.6590; 0.8975]  0.0009
Adding Jensen 2022 (k=10) 0.7281 [0.6137; 0.8637]  0.0003
```

sortvar に年を渡すと、その順に試験を足します。k = 2 から 6 の行は区間の上限が 1 を超えており、k = 7 から超えなくなります。

7.8 GRADE で確実性を判定する

ここまでの結果を、診療の判断に使えるかどうかの言葉に直すのが GRADE です（Guyatt 2008）。GRADE は、あるアウトカムについての効果の推定値がどれくらい確かかを、高、中、低、非常に低の 4 段階で判定

する方法で、多くの診療ガイドラインで使われています。

RCT だけを集めたメタ解析は、確実性が高から出発します。そこから、次の五つの理由があれば 1 段階か 2 段階下げます。

バイアスのリスク　統合した試験の方法に問題があるか。RoB 2 の判定を、重みの大きい試験を中心に見ます。

非一貫性　試験の結果が食い違っているか。I^2（6.1 節（p. 58））の数字だけで決めず、効果の向きと大きさのずれ、信頼区間の重なり、予測区間が判断の閾値（下の不精確さで説明します）をまたぐかを見ます（Core GRADE 3）。信頼区間と予測区間の違いは 6.3 節（p. 62）で説明しました。

非直接性　試験の対象、介入、比較、アウトカムが、知りたい問いとずれていないか。

不精確さ　信頼区間が広すぎて、判断が変わる範囲にまたがっていないか。判断の閾値は、結論が変わる境目の効果の大きさです。効果なし（リスク比 1）を置くことも、最小重要差（患者や臨床医が意味があると考える最小の差）を置くこともあります。閾値を先に決めておき、信頼区間がその閾値をまたぐかで判断します（Core GRADE 2）。事象の数が少なすぎないかは補助として見ます。

出版バイアス　発表されていない試験が抜けている疑いが強いか。

観察研究のメタ解析は低から出発し、効果が非常に大きい、量反応関係がある、といった理由があれば上げることができます（ROBINS-I で評価する場合は高から出発し、バイアスのリスクの評価で下げる扱いもあります。Cochrane ハンドブック 14.2.1）。

降圧薬 A の脳卒中について判定すると、次のようになります。

バイアスのリスク　重みの大きい Garcia 2018、Dubois 2014、Ivanov 2021 はいずれも低で、高の Endo 2015 を除いても結果は変わらないので、下げません。

非一貫性　点推定は Aoki 2009 の 0.41 から、Chen 2012 の 1 を超える 1.13

までずれています。10 試験のうち 9 試験は 1 より小さいものの、Chen 2012 だけが逆向きです。予測区間は 0.46〜1.15 で、判断の閾値である 1（効果なし）をまたぎます。I^2 は 51% でした。サブグループ解析でも説明できなかったので、1 段階下げます。

非直接性　対象は高血圧の成人、比較はプラセボ、アウトカムは脳卒中で、問いと一致しているので下げません。実際の診療では他の降圧薬と比べたいことが多いので、プラセボとの比較であることは結果の要約表に書き添えます。

不精確さ　判断の閾値を効果なし（リスク比 1）に置くと、信頼区間 0.61〜0.86 はその片側に収まります。対照群のリスクが 5% なら、1000 人あたりの差は 1000 × 0.05 × (1 − リスク比) で求められ、区間の端のリスク比 0.864 と 0.614 を入れると 7〜19 人の減少で（表 7.1）、区間のどこをとっても減る側です。最小重要差を置くなら、1000 人あたり何人の減少から臨床的に意味があるとするかを先に決め、7〜19 人がその値の片側に収まるかを見ます。事象も 1,304 件あるので、下げません。

出版バイアス　小さな試験が効果の大きい側に偏っていますが、Egger 検定は有意でなく、固定効果とランダム効果の統合値も近い値（0.75 と 0.73、発展の 7.4 節（p. 75））でした。疑いはあるものの下げるほどではないと判断し、その旨を記録します。

判定の結果、確実性は高から 1 段階下げて中となります。判定は機械的な点数の計算ではなく、レビューの著者の判断です。だからこそ、どの理由でいくつ下げたかを必ず書き残し、読者が判断の妥当性を確かめられるようにします。

7.9
結果の要約表

GRADE では、アウトカムごとの結果を Summary of findings 表（結果の要約表）にまとめます。相対的な効果（リスク比）だけでなく、絶対的な効果（1000 人あたり何人減るか）を示すのが特徴です。リスク比は集団によらず比較的一定でも、もともとの発症割合が違えば、減る人数は大きく変わるからです。

対照群のリスク	プラセボ	降圧薬 A	差（95% 信頼区間）
5%（一般の成人）	1000 人中 50 人	1000 人中 36 人	14 人少ない（7〜19 人少ない）
10%（高齢者）	1000 人中 100 人	1000 人中 73 人	27 人少ない（14〜39 人少ない）

表 7.1　降圧薬 A と脳卒中の結果の要約（架空のデータ）。リスク比 0.73（0.61〜0.86）、10 試験、21,420 人、確実性は中（非一貫性で 1 段階下げた）

対照群のリスクは、統合した試験の対照群の発症割合（およそ 5〜13%）を目安に、低い場合と高い場合の 2 通りを置きました。降圧薬 A 群の人数は、対照群のリスクにリスク比 0.73 をかけて求めます。1000 人あたり 50 人なら 36 人に、100 人なら 73 人になります。同じリスク比でも、もともと脳卒中を起こしやすい高齢者では、防げる人数がおよそ 2 倍になることが表から読み取れます。対照群のリスクを連続的に動かした図は、発展の 7.9.1 節（p. 83）にあります。

発展 対照群のリスクを動かした図

対照群のリスクを連続的に動かすと、防げる人数がどう変わるかを一枚の図にできます。リスク比 0.73 とその信頼区間の端を使い、対照群のリスク p について 1000 × p × (1 − リスク比) を計算して線にします。

```
rr <- exp(c(m$TE.random, m$lower.random, m$upper.random))
```

```
p0 <- seq(0.01, 0.15, by = 0.001)    # 対照群の 5 年発症割合
plot(100 * p0, 1000 * p0 * (1 - rr[1]), type = "l",
     ylim = c(0, 65), xlab = "プラセボ群の発症割合（%）",
     ylab = "1000 人あたり防げる脳卒中（人）")
lines(100 * p0, 1000 * p0 * (1 - rr[2]), lty = 2)  # 下限
lines(100 * p0, 1000 * p0 * (1 - rr[3]), lty = 2)  # 上限
```

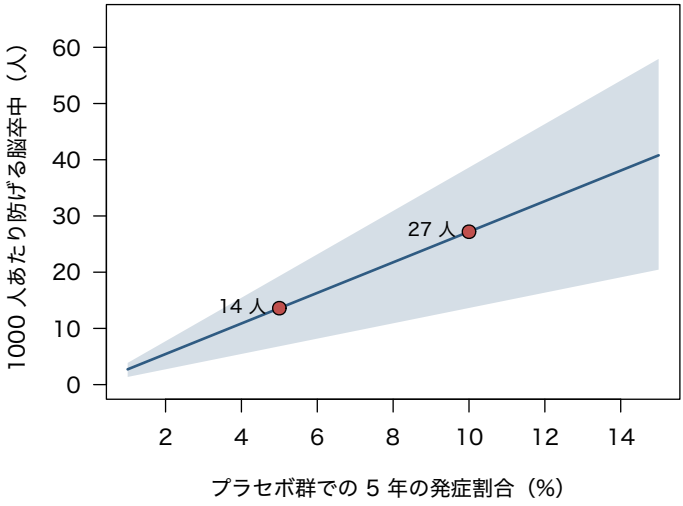


図 7.3　プラセボ群の 5 年の発症割合と、1000 人あたり防げる脳卒中の人数。帯は 95% 信頼区間。赤い点は表 7.1 の 5% と 10%

横軸はプラセボ群での脳卒中の発症割合、縦軸は降圧薬 A によって 1000 人あたり防げる脳卒中の人数で、中央の線が点推定、帯が 95% 信頼区間です。赤い点が表 7.1 の 2 つの行にあたり、5% なら 14 人、10% なら 27 人です。線は原点から右上がりの直線で、リスク比が一定なら、もともとの発症割合が高いほど防げる人数が増えます。帯は右へ行くほど広がり、10% で 14〜39 人です。

読むときの注意は、この線が降圧薬 A のリスク比 0.73 を、どの対照群のリスクにもそのまま当てはめた計算だということです。6.3 節（p. 62）で

見たとおり、効果は集団によって違いうるので、予測区間が 1 をまたぐことを忘れて線を読むと、確かさを過大に見積もります。また、1000 人あたりの人数は期間を決めて初めて意味をもつので、横軸の発症割合が何年間の割合なのかを、図と一緒に書いておく必要があります。

7.10 この章のまとめ

ファネルプロットでは小さな試験が効果の大きい側に寄っていましたが、Egger 検定は試験数 10 で検出力が低く、p = 0.27 でした。固定効果モデル（0.75）とランダム効果モデル（0.73）の統合値の差は小さく、結論は変わりませんでした。バイアスのリスク、1 試験ずつの除外、モデルの選択を変えた感度分析でも、リスク比は 0.70〜0.77 に収まりました。GRADE の判定は非一貫性で 1 段階下げて中とし、結果の要約表に 1000 人あたりの差で示しました。小規模研究効果は出版バイアス以外の原因でも起こり、統計の方法で出版バイアスを取り除くことはできないので、試験登録の検索が最も確かな対策です。次の章では、ここまでの作業を論文として報告する方法を説明します。

第 8 章

メタ解析を報告する

この章で分かること

メタ解析の論文は、読者が同じ手順をたどり直せるように書きます。報告の指針 PRISMA 2020 の要点を確かめたうえで、降圧薬 A のレビューを例に方法と結果の段落を書いてみます。そのあと、他の人が書いたメタ解析を読むときに見るところをまとめ、第 1 部を締めくくります。本書で扱わない方法の紹介は発展の節に置いてあり、初読では飛ばせます。

8.1 PRISMA 2020 の要点

系統的レビューとメタ解析の報告には、PRISMA 2020 という指針を使います（Page 2021）。題名から資金源まで 27 の項目があり、それぞれに何を書くかが決められています。多くの雑誌は、投稿のときにこのチェックリストを埋めて、各項目を原稿の何ページに書いたかを示すよう求めます。抄録だけに使う 12 項目のチェックリストも別にあります。

27 項目の多くは、ここまでの章で行った作業をそのまま書けば満たせます。書き忘れやすいのは次の項目です。

題名　系統的レビューであること（メタ解析を含むならそれも）が題名から分かるようにします。

計画書と登録　PROSPERO の登録番号と、計画書から変えた点があればその内容と理由を書きます。変更を書かないと、後から解析を選んだのではないかと疑われます。

検索　使ったすべてのデータベース、登録簿、ウェブサイトについて、検索日と検索式の全文（使ったフィルターと制限を含む）を載せます。PRISMA 2020 の項目 7 がこれを求めています。全文は補足資料に置いて構いません。検索の報告をさらに詳しく書くための指針として、PRISMA-S（Rethlefsen 2021）があります。

選別と抽出の手順　何人が、独立に行ったか、食い違いをどう解決したかを書きます。

効果の指標と統合の方法　リスク比を使ったこと、ランダム効果モデル、τ^2 の推定法、信頼区間の作り方を書きます。どれを選んだかで数字が変わるので、ソフトウェアとそのバージョンも書きます。

報告バイアスと確実性の評価　出版バイアスをどう調べたか、GRADE で確実性をどう判定したかを、方法の節に書きます。結果の節にだけ書くと、事前に決めた手順だったかどうかが読者に分かりません。

個々の試験の結果　統合値だけでなく、試験ごとの効果と信頼区間を示します。フォレストプロットがこれにあたります。

データとコードの公開　抽出したデータ、解析のコード、その他の資料を公開しているか、どこで手に入るかを書きます。

選別の経過は 3.5 節（p. 32）で描いた PRISMA のフロー図で示します。フロー図の数とチェックリストの数、本文の数がそろっているかは、投稿前に必ず突き合わせます。

8.2 方法を書く

方法の節は、読者が同じ手順をたどれば同じ結果になるように書きます。降圧薬 A のレビューの方法を、架空の例として 2 段落で示します（以下の枠内はすべて架空のレビューです）。検索日と登録番号は架空のものです。

方法の例

本レビューは PRISMA 2020 に従って報告し、計画書は事前に PROSPERO に登録した（CRD000000000）。高血圧の成人を対象に降圧薬 A とプラセボを比べ、脳卒中の発症を報告した RCT を対象とした。MEDLINE、Embase、CENTRAL、医中誌 Web、ClinicalTrials.gov と jRCT を、開始時から 2025 年 6 月 30 日まで、言語の制限なく検索した。題名と抄録の選別、本文の確認、データの抽出は 2 人が独立に行い、食い違いは話し合いで解決した。各試験のバイアスのリスクは RoB 2 で評価した。

効果の指標はリスク比とし、逆分散法によるランダム効果モデルで統合した。τ^2 は REML 法で推定し、95% 予測区間を示した。異質性は I^2 と τ^2 で評価した。事前に決めたサブグループ解析として対象集団（高齢者、一般の成人）とバイアスのリスクの判定で分けた解析を、感度分析としてバイアスのリスクが高い試験を除いた解析、1 試験ずつ除いた解析、固定効果モデルと Hartung-Knapp 法による解析を行った。出版バイアスはファネルプロットと Egger 検定で調べ、固定効果モデルとランダム効果モデルの統合値を比べた。エビデンスの確実性は GRADE で判定した。解析には R 4.5.3 と meta パッケージ 8.5-0 を用いた。

枠内は論文の文体（である調）で書いてあります。統計の段落には、効果の指標、モデル、τ^2 の推定法、信頼区間の作り方、異質性の指標、事前に決めた追加解析、ソフトウェアのバージョンを入れます。どれも数字を

左右する選択なので、一つでも欠けると読者は結果を再現できません。例の中の逆分散法は重み付き平均の計算の仕方（5.3 節（p. 45））、REML は τ^2 の推定法、Hartung-Knapp 法は信頼区間の作り方で、後の二つは 5.7 節（p. 52）で説明しました。

8.3 結果を書く

結果の節は、選別の経過、組み入れた試験の特徴、バイアスのリスク、統合の結果、追加解析、確実性の順に書くのが一般的です。統合の結果の段落を例に示します。

結果の例

> 10 試験、21,420 人（脳卒中 1,304 件）を統合した。降圧薬 A はプラセボと比べて脳卒中を減らした（リスク比 0.73、95% 信頼区間 0.61〜0.86、$p < 0.001$；図 2）。試験間の異質性は中程度で（$I^2 = 51\%$、$\tau^2 = 0.034$）、95% 予測区間は 0.46〜1.15 であった。対象集団で分けると、リスク比は高齢者で 0.65（0.46〜0.91）、一般の成人で 0.82（0.71〜0.95）であったが、サブグループ間の差は有意ではなかった（$p = 0.20$）。バイアスのリスクが高い 1 試験を除いた解析（0.74、0.62〜0.88）、1 試験ずつ除いた解析（0.70〜0.77）、Hartung-Knapp 法による解析（0.73、0.59〜0.89）でも結果は変わらなかった。Egger 検定でファネルプロットの非対称は検出されなかった（$p = 0.27$）。確実性は、非一貫性のため中と判定した（表 3）。

数字の書き方にはいくつかの約束があります。点推定には必ず信頼区間を添え、p 値だけを書くことはしません。リスク比は小数 2 桁、p 値は 2 桁程度にし、0.001 より小さければ $p < 0.001$ とします。サブグループ解析は、群ごとの値だけでなく群の間の差の検定を書きます。群ごとの値だけを並べると、片方だけ有意だったことを差があったと読み違えられやすい

からです（6.4 節（p. 64））。

図表は、PRISMA のフロー図、試験の特徴の表、バイアスのリスクの図、フォレストプロット、結果の要約表をそろえるのが基本です。フォレストプロットの試験の順番、表の試験の順番、本文で試験を挙げる順番をそろえておくと、読者が照らし合わせやすくなります。

8.4 投稿前の確認と公開

投稿の前に、次の点を確かめます。

数の一致　抄録、本文、表、図、フロー図の数（試験数、人数、事象数、効果の推定値）が一致しているか。修正を繰り返すうちに、一か所だけ古い数字が残ることがよくあります。

計画書との一致　計画書に書いた解析をすべて報告しているか。変えた点は理由とともに書いてあるか。

チェックリスト　PRISMA 2020 の各項目について、書いたページを埋められるか。

再現　解析のコードを最初から実行し直して、論文の数字が再現されるか。

抽出したデータと解析のコードは、補足資料に付けるか、OSF や GitHub のような公開の場所に置きます。メタ解析のデータは発表済みの論文から取った試験単位の集計値なので、個人を特定する情報は含まれません。公開しておけば、読者が数字を確かめられ、次にレビューを更新する人がそこから作業を始められます。本書の R スクリプトのように、データの読み込みから図の書き出しまでを一つのスクリプトにまとめておくと、再現が容易になります。

8.5
メタ解析の論文を読むときに見るところ

自分でメタ解析をしなくても、検査技師として診療ガイドラインや総説の根拠になったメタ解析を読む機会はあります。結論を受け取る前に、次の点を確かめます。

問いと対象　PICO がはっきりしているか。対象、介入、比較、アウトカムが、自分の知りたい問いと合っているか。

計画書の登録　事前に登録されているか。登録された計画と報告された解析が一致しているか。

検索の範囲　複数のデータベースと試験登録を検索しているか。言語や発表形式で絞っていないか。

選別と抽出　2 人が独立に行ったか。除外した理由が示されているか。

個々の試験の質　バイアスのリスクを評価しているか。その評価が結論に反映されているか。

統合の妥当性　統合した試験の対象や介入は似ているか。異質性が大きいのに一つの数字だけで結論していないか。予測区間は示されているか。

サブグループ解析　事前に決めたものか。群の間の差を検定しているか。数多くのサブグループのうち一つだけを強調していないか。

出版バイアス　調べているか。試験数が少ないのに Egger 検定の結果だけで「ない」としていないか。

確実性　GRADE などで判定しているか。相対効果だけでなく絶対効果が示されているか。

全部の項目を満たす論文は多くありません。どこが弱いかを把握したうえで結論を読めば、その結論をどこまで診療や検査の判断に使えるかを見積もれます。

8.6 発展 この先に進むときに

この冊子で扱ったのは、2 つの介入を直接比べた試験を、公表された集計値で統合する方法です。次の 4 つは本書では扱いません。必要になったときの手がかりとして、Cochrane ハンドブックの該当箇所を挙げます。

ネットワークメタ解析（第 11 章） 3 つ以上の介入を、直接比べた試験と間接的な比較を組み合わせて一度に比べる方法です。間接比較が成り立つには、試験どうしが効果に影響する要因について似ている必要があり（推移性、11.1.3）、これを確かめる作業が解析の前提になります。

個人データのメタ解析（第 26 章） 試験ごとの集計値ではなく、参加者一人ひとりのデータを集めて統合する方法です（26.1.1）。未報告のアウトカムを使え、解析方法を試験間でそろえられ、年齢や重症度によって効果が違うかを調べる力も高くなりますが、データの提供を受ける手間がかかります。

リビングシステマティックレビュー（22.2.3） 新しい証拠が出るたびに、できるだけ早く取り込んで更新し続ける系統的レビューです。新しい試験を見つけ続ける監視の仕組み（22.2）と組み合わせて運用します。

ベイズ流のメタ解析（10.13） 事前の情報を事前分布として置き、データと合わせて事後分布を求めます。結果は点推定と信用区間で示され、事前分布の選び方に結果が左右されるので、感度分析が勧められています。試験数が少なく τ^2 の推定が不安定なときの選択肢としても挙げられています。

この 4 つはどれも、第 1 部と同じく介入の効果を 1 つの数で統合する流れの中で使う方法です。

8.7
第 1 部のまとめ

第 1 部では、降圧薬 A の 10 試験を使って、介入のメタ解析を問いの設定から報告まで一通りたどりました。問いを PICO で定めて計画書を登録し（2.1 節（p. 21）、2.4 節（p. 24））、試験を検索して選別し（3.2 節（p. 28）、3.3 節（p. 29））、データを取り出して偏りを評価しました（4.2 節（p. 35）、4.3 節（p. 37））。R の meta パッケージでリスク比を統合し（5.6 節（p. 50））、異質性を調べ（6.1 節（p. 58））、出版バイアス（7.1 節（p. 72））、感度分析（7.6 節（p. 77））、GRADE（7.8 節（p. 80））で結果の確かさを評価しました。

結果は、リスク比 0.73（0.61〜0.86）、確実性は中です。降圧薬 A は脳卒中を減らすと考えられますが、予測区間（6.3 節（p. 62））が 1 をまたいでおり、効果の大きさは試験によって違います。この結論は数字一つではなく、試験の集め方（3.1 節（p. 27））、統合の方法（5.4 節（p. 46））、異質性（6.1 節（p. 58））と偏り（7.1 節（p. 72））の評価を合わせて初めて言えるものです。

第 2 部では、プロカルシトニンの 10 研究を使って、検査の診断精度のメタ解析を行います。検索、選別、抽出、報告の流れは第 1 部と同じですが、検査の診断精度は感度と特異度（9.2 節（p. 96））という 2 つの数が互いに関係して動くので、1 つの数で統合する流れそのものが変わります。

第 2 部

検査のメタ解析

第 2 部の主題は、検査の精度を統合するメタ解析です。問いを立て、文献を探して選び、データを取り出し、バイアスのリスクを評価し、統合して報告するという工程は、第 1 部の介入のメタ解析と同じです。違うのは統計の部分で、検査の研究は感度と特異度という互いに関係した 2 つの結果を持つため、介入のときのように 1 つの効果の大きさを平均するわけにはいきません。

第 9 章と第 10 章では、精度を表す言葉と、検査のメタ解析で二変量モデルを使う理由を説明します。第 10 章では、感度と特異度を logit の目盛りに直す考え方が出てきます。第 11 章と第 12 章では、架空のプロカルシトニン（PCT）の研究を例に、抄録の選別、2×2 表の取り出し、バイアスのリスクの評価を練習します。第 13 章から第 15 章で、R による解析と結果の報告に進みます。第 1 部の第 1 章から第 5 章を読んでいることを前提にしますが、第 9 章と第 10 章だけを読んでも、検査のメタ解析の論文を読むための知識は一通り身につきます。第 2 部に入る前に、対数とオッズの 5.1 節（p. 42）、固定効果とランダム効果の 5.4 節（p. 46）、I^2 の 6.1 節（p. 58）、予測区間の 6.3 節（p. 62）、PRISMA のフロー図の 3.5 節（p. 32）を読み直してください。発展の印が付いた部分は、初読では飛ばしても後の章が読めます。

第 9 章

検査の精度を表す言葉

この章で分かること

検査の精度は、2×2 表から計算する感度と特異度で表します。陽性的中割合と陰性的中割合は有病割合によって変わるので、研究どうしを比べる指標には向きません。カットオフを動かすと感度と特異度は逆向きに動き、この性質が第 10 章以降の統計の考え方を決めます。分析性能と診断精度の違い、診断精度に関わる報告の指針も整理します。カットオフを動かして感度と特異度を計算する R のコードは発展の節に置いてあり、初読では飛ばせます。

9.1 2×2 表

診断精度研究では、対象者の全員に、精度を調べたい検査（対象検査）と、正解を決めるための検査（参照基準）の両方を行います。参照基準で標的疾患があると判定された人と、ないと判定された人に分け、それぞれで対象検査が陽性だった人と陰性だった人を数えると、4 つの升目を持つ表ができます。これが 2×2 表で、検査のメタ解析で研究ごとに取り出すデータはこの 4 つの数だけです。

第 2 部の例題は、発熱して受診した成人で、プロカルシトニン（PCT）が菌血症をどれだけ正しく見分けるかを調べた架空の研究 10 本です。参照基準は血液培養で、培養が陽性なら菌血症あり、陰性なら菌血症なしとします。最初の研究である架空の Kato 2010 は、救急外来の患者 355 人を対象にし、カットオフ 0.5 ng/mL 以上を陽性としました。この研究の 2×2 表を図 9.1 に示します。

	参照基準（血液培養）：菌血症あり	参照基準（血液培養）：菌血症なし	
PCT 陽性（0.5 以上）	真陽性 TP 28	偽陽性 FP 61	計 89 人
PCT 陰性（0.5 未満）	偽陰性 FN 17	真陰性 TN 249	計 266 人
	計 45 人	計 310 人	

図 9.1　架空の Kato 2010 の 2×2 表（カットオフ 0.5 ng/mL、355 人）

表の縦の列は参照基準による分け方で、横の行は対象検査の結果です。この並べ方は論文によって入れ替わることがあり、行と列を取り違えると感度と陽性的中割合を取り違えることになります。論文から数を取り出すときは、まず列と行が何で分けられているかを確かめます。

9.2 感度と特異度

感度は、病気のある人のうち検査が陽性になった人の割合です。Kato 2010 では菌血症のある 45 人のうち 28 人が陽性だったので、感度は 28 ÷ 45 で 0.62 になります。特異度は、病気のない人のうち検査が陰性になっ

た人の割合で、菌血症のない 310 人のうち 249 人が陰性だったので、249 ÷ 310 で 0.80 になります。

特異度の裏側にあたる量が偽陽性割合で、病気のない人のうち誤って陽性になった人の割合です。1 から特異度を引いた値と同じで、Kato 2010 では 61 ÷ 310 で 0.20 です。偽陽性割合は第 10 章以降の図の横軸に毎回登場するので、ここで名前を覚えておいてください。

感度と特異度は、どちらも分母が「参照基準で決まった病気の有無」の片側だけで閉じています。感度は病気のある人の列の中だけで、特異度は病気のない人の列の中だけで計算します。そのため、研究に病気のある人が多く含まれていても少なく含まれていても、検査の性質が同じなら感度と特異度は同じ値になると期待できます。研究どうしを比べたり統合したりする指標に感度と特異度を使うのは、この性質があるからです。ただし、この期待は「どの研究でも同じような患者に同じように検査をしている」という前提の上に立っており、現実には対象患者の重症度や測定法の違いで感度と特異度も変わります（Leeflang 2013）。その点は 10.1 節（p. 107）と 14.1 節（p. 161）で扱います。

9.3 的中割合は有病割合で変わる

検査を受ける人の立場では、知りたいのは感度よりも「陽性と言われたとき、本当に病気である見込みはどのくらいか」です。これが陽性的中割合で、陽性になった人のうち本当に病気のある人の割合です（一般には陽性的中率とも呼ばれますが、分母に時間を含まないので、本書では割合と呼びます）。Kato 2010 では陽性 89 人のうち 28 人が菌血症だったので、0.31 になります。陰性的中割合は、陰性になった人のうち本当に病気のない人の割合で、266 人のうち 249 人なので 0.94 です。

的中割合は、検査の性質だけでなく、検査を受ける集団に病気の人がど

れだけいるか（有病割合）で大きく変わります。Kato 2010 の感度 0.62 と特異度 0.80 をそのまま使い、有病割合だけを変えて 1000 人に検査をしたと考えると、表 9.1 のようになります。

有病割合	真陽性	偽陰性	偽陽性	真陰性	陽性的中	陰性的中
5%	31	19	187	763	0.14	0.98
10%	62	38	177	723	0.26	0.95
25%	156	94	148	602	0.51	0.86
50%	311	189	98	402	0.76	0.68

表 9.1　感度 0.62、特異度 0.80 の検査を 1000 人に行ったときの内訳（人数は四捨五入）

有病割合が 5% の集団では、陽性になった人の 7 人に 1 人しか菌血症ではありません。同じ検査を有病割合 50% の集団で使えば、陽性の 4 人に 3 人が菌血症です。救急外来の発熱患者と ICU の重症患者では有病割合が違うので、同じ PCT の結果でも意味が変わります。研究ごとに的中割合を集めて平均すると、検査の性質と集団の性質が混ざった値になってしまいます。検査のメタ解析で的中割合を直接統合しないのはこのためで、統合するのは感度と特異度にし、的中割合は使う場面の有病割合を決めてから計算し直します（15.1 節（p. 177））。有病割合を連続的に動かしたときの的中割合の曲線は、第 13 章で得る要約点を使って、15.1.2 節（p. 180）で扱います。

9.4 尤度比と診断オッズ比

感度と特異度を組み合わせた指標に、尤度比があります。陽性尤度比は、病気のある人で陽性になる割合（感度）を、病気のない人で陽性になる割合（偽陽性割合）で割った値です。Kato 2010 では 0.622 ÷ 0.197 で 3.16 に

なり、病気のある人は、ない人の約 3 倍陽性になりやすいことを表します。陰性尤度比は偽陰性の割合（1 − 感度）を特異度で割った値で、0.378 ÷ 0.803 で 0.47 です。

尤度比は、検査前の見込みを検査後の見込みに換算するときに使います。オッズの考え方は 5.1.4 節（p. 44）で説明しました。検査前の見込み（事前確率）をオッズに直して尤度比を掛けると、検査後のオッズになります。事前確率 10% はオッズで 1 対 9 です。陽性なら 3.16 を掛けて 3.16 対 9、確率に戻すと 0.26 になります。陰性なら 0.47 を掛けて確率に戻すと 0.05 です。表 9.1 の有病割合 10% の行では、陽性的中割合が 0.26、陰性的中割合が 0.95（1 から引いた 0.05 が、陰性でも病気である見込み）で、尤度比から求めた値と一致します。尤度比を使った計算と 1000 人の表は、同じことを別の形で書いたものです。検査前の確率を横軸に、検査後の確率を縦軸にとった曲線は、発展の 15.1.3 節（p. 182）で扱います。

診断オッズ比は、陽性尤度比を陰性尤度比で割った値で、Kato 2010 では 6.72 になります。2×2 表の対角線の積の比（28 × 249 を 61 × 17 で割る）としても計算でき、検査の良さを 1 つの数で表せるので、以前のメタ解析ではよく統合されてきました。感度のオッズ（感度 ÷ (1 − 感度)）を、偽陽性割合のオッズで割った値としても書けます。

しかし、診断オッズ比が同じでも、感度と特異度の組み合わせは違いえます。検査 X の感度が 0.9、特異度が 0.5 のとき、診断オッズ比は (0.9 ÷ 0.1) ÷ (0.5 ÷ 0.5) で 9 です。検査 Y の感度が 0.5、特異度が 0.9 のときも、(0.5 ÷ 0.5) ÷ (0.1 ÷ 0.9) で 9 になります。X は陰性なら病気を除外しやすく、Y は陽性なら病気を確定しやすい検査です。除外に使いたいのか確定に使いたいのかで求める性質は違うので、1 つの数だけでは臨床の判断に使えません。本書では、診断オッズ比は補助的な指標として扱います。

9.5
カットオフを動かすと何が起きるか

PCT は連続量で測る検査で、陽性と陰性を分けるのはカットオフです。菌血症のある人とない人の PCT の値の分布を描くと、図 9.2 のように 2 つの山が重なります。この図は図解のために仮想の分布から描いたもので、研究のデータではありません。PCT の対数が正規分布に従うと仮定し、菌血症のない人は中央値 0.2 ng/mL、ある人は中央値 1.5 ng/mL としました。対数については 5.1.2 節（p. 43）で説明しました。対数をとった値の標準偏差は、ない人で 1.0、ある人で 1.2 です。標準偏差 1.0 は、中央値のおよそ 2.7 倍から 2.7 分の 1 までの幅に、約 3 分の 2 の人が入る広さです。カットオフ 2 ng/mL の線は図解のために加えたもので、第 2 部の研究が使うカットオフは 0.25、0.5、1 ng/mL の 3 つです。

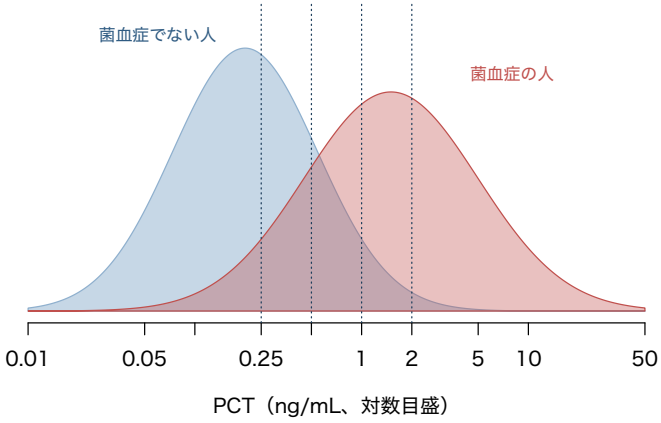


図 9.2　菌血症のある人とない人の PCT の分布（仮想の分布。点線は左から 0.25、0.5、1、2 ng/mL のカットオフ）

カットオフより右側に入った人が陽性になります。菌血症のある人の山

で右側に入った部分が真陽性で、その割合が感度です。菌血症のない人の山で右側にはみ出した部分が偽陽性で、その割合が偽陽性割合です。4 つのカットオフについて、山の面積の割合を計算した結果を表 9.2 に示します（計算の R コードは、この節の終わりの発展に置きます）。

カットオフ（ng/mL）	感度	特異度
0.25	0.93	0.59
0.5	0.82	0.82
1	0.63	0.95
2	0.41	0.99

表 9.2　図 9.2 の仮想の分布での、カットオフごとの感度と特異度

図の横軸は対数目盛なので、0.25、0.5、1、2 ng/mL は等間隔に並んでいます。菌血症のない人の山は 0.2 ng/mL 付近、ある人の山は 1.5 ng/mL 付近に頂点があり、2 つの山は 0.25 から 1 ng/mL のあたりで大きく重なっています。点線を右へ動かすと、菌血症のない人の山からはみ出す部分が減るので特異度は 0.59 から 0.99 まで上がります。同時に、菌血症のある人の山の右側に残る部分も減るので、感度は 0.93 から 0.41 まで下がります。左へ動かせば逆になります。2 つの山が重なっている限り、カットオフをどこに置いても、感度と特異度を同時に上げることはできません。

カットオフを決めるとは、2 つの山の重なりのどこに線を引くかを決めることです。基準範囲は健康な人の山だけを見て決めますが、カットオフは 2 つの山の両方を見て、見逃しと誤りのどちらを減らしたいかで決めます。感度と特異度が 0.82 で等しくなる 0.5 ng/mL は、この仮想の分布に置いた数字から偶然そうなっただけで、実際の検査で 0.5 ng/mL が釣り合う点だという意味ではありません。Kato 2010 のカットオフ 0.5 ng/mL での感度 0.62、特異度 0.80 と値が違うのも、図の分布が研究データではないためです。

カットオフを少しずつ動かしながら、横軸に偽陽性割合、縦軸に感度

をとって点を打っていくと、図 9.3 の ROC 曲線ができます。先の 4 つのカットオフは、曲線の上の 4 つの点にあたります。

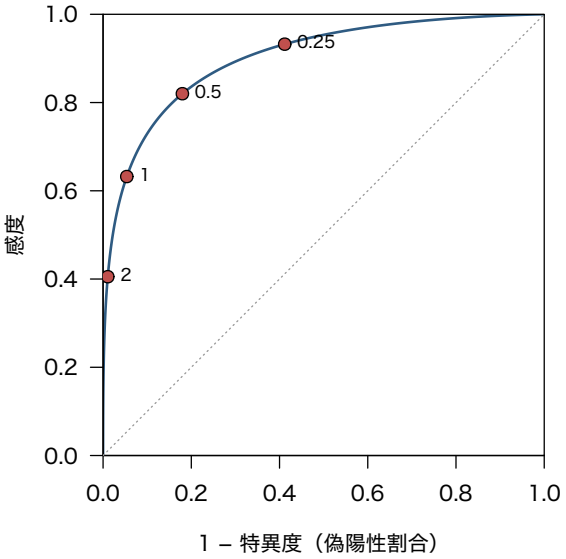


図 9.3　図 9.2 の分布から描いた ROC 曲線。点の横の数字はカットオフ（ng/mL）

横軸は偽陽性割合（1 − 特異度)、縦軸は感度で、曲線上の 1 点が 1 つのカットオフに対応します。カットオフ 2 ng/mL の点は左下（偽陽性割合 0.01、感度 0.41）にあり、0.25 ng/mL の点は右上（偽陽性割合 0.41、感度 0.93）にあります。カットオフを下げるほど、曲線の上を右上へ進みます。点線の対角線は、検査の結果が菌血症と無関係なときの線で、曲線がこの線から左上へ離れているほど、2 つの山の重なりが小さいことを表します。

2 つの山の重なりが小さい検査ほど曲線は左上の角に近づき、重なりが完全なら曲線は対角線になります。曲線の下の面積（AUC）は、役に立つ検査なら 0.5 から 1 の値をとり、検査の識別能を 1 つの数で表します。ただし、診断オッズ比と同じく、AUC が同じでも曲線のどこを使うか（どの

カットオフを使うか）で臨床の意味は違います。曲線は連続した線ですが、実際に使うのは 1 つのカットオフの 1 点です。

感度と特異度はカットオフを介して逆向きに動きます。メタ解析で集める研究は、それぞれ別のカットオフを使っていることが多く、研究ごとの感度と特異度は 1 本の ROC 曲線の上のあちこちに散らばります。研究どうしで感度が違って見えても、検査の性能が違うのではなく、カットオフが違うだけのことがあります。これを閾値効果と呼び、10.1 節（p. 107）の出発点になります。

発展 分布と ROC 曲線を R で描く

図 9.2 は R の dnorm() で描けます。dnorm(log(x), m, s) は、PCT が x のところの山の高さを返します。横軸は対数目盛にするので、plot() に log = "x" を指定します。

```
# 対数をとった PCT が正規分布に従う仮想の集団
m1 <- log(1.5); s1 <- 1.2    # 菌血症の人
m0 <- log(0.2); s0 <- 1.0    # 菌血症でない人
x  <- exp(seq(log(0.01), log(50), length.out = 500))

plot(x, dnorm(log(x), m0, s0), type = "l", log = "x",
     xlab = "PCT（ng/mL、対数目盛）", ylab = "分布")
lines(x, dnorm(log(x), m1, s1), col = "red")
cuts <- c(0.25, 0.5, 1, 2)   # 4 つのカットオフ
abline(v = cuts, lty = 3)
```

pnorm() は、分布の左側の面積を返します。pnorm(log(k), m, s) は、PCT がカットオフ k 未満の人の割合です。

```
# 菌血症の人でカットオフ以上の割合
sens <- 1 - pnorm(log(cuts), m1, s1)
# 菌血症でない人でカットオフ未満の割合
spec <- pnorm(log(cuts), m0, s0)
data.frame(cuts, sens = round(sens, 2), spec = round(spec, 2))
```

```
  cuts sens spec
1 0.25 0.93 0.59
2 0.50 0.82 0.82
3 1.00 0.63 0.95
4 2.00 0.41 0.99
```

図 9.3 の ROC 曲線は、カットオフを細かく動かして同じ計算を繰り返し、偽陽性割合と感度を線で結んだものです。

```
cc  <- exp(seq(log(0.005), log(200), length.out = 400))
fpr <- 1 - pnorm(log(cc), m0, s0)   # 偽陽性割合
tpr <- 1 - pnorm(log(cc), m1, s1)   # 感度
plot(fpr, tpr, type = "l", xlim = c(0, 1), ylim = c(0, 1),
     xlab = "1 − 特異度（偽陽性割合）", ylab = "感度")
abline(0, 1, lty = 3)               # 当て推量と同じ対角線
points(1 - spec, sens, pch = 19)    # 4 つのカットオフの点
text(1 - spec, sens, cuts, pos = 4)
```

9.6 分析性能と診断精度、基準範囲とカットオフ

検査技師にとって検査の性能といえば、まず併行精度や室間再現精度、正確さ、直線性、検出限界といった分析性能です。分析性能は「同じ検体を測ったら同じ値が出るか、真の値に近い値が出るか」を表します。これに対して、感度と特異度が表すのは診断精度で、「その値で病気のある人とない人を分けられるか」です。分析性能は診断精度の前提であり、精度の悪い測定では診断精度も下がりますが、分析性能が良くても、病気のある人とない人の値がもともと重なっていれば診断精度は上がりません。

PCT のメタ解析では、分析性能の違いが研究間のばらつきの原因になりえます。測定試薬や機器が違えば同じ検体でも値が少しずれ、同じ 0.5

ng/mL というカットオフでも実質的に違う位置で線を引いていることになります。検出限界付近の低いカットオフ（0.25 ng/mL など）を使う研究では、低濃度域の測定のばらつきがそのまま判定のばらつきになります。検体の種類（血清か血漿か）、採血のタイミング（発熱から何時間後か）も値を動かします。PCT は感染の初期には上がりきっていないことがあるので、受診直後の 1 回の採血か、6 時間後の再検かで、同じ患者でも陽性と陰性が入れ替わります。論文から研究の特徴を取り出すときに、測定法と採血の時点を必ず項目に入れておくのはこのためです（12.1 節（p. 127））。

基準範囲とカットオフの違いにも注意が要ります。基準範囲は、健康な人の測定値の分布の中央 95% を示すもので、病気を見分けるために決めた値ではありません。カットオフは、病気のある人とない人を分けるために、ある目的（見逃しを減らしたい、無駄な治療を減らしたい）に沿って選んだ値です。基準範囲の上限をそのままカットオフにした研究と、ROC 曲線を見て最も成績の良い点を選んだ研究とでは、カットオフの決め方の意味が違います。後者のように、集めたデータそのものを見てカットオフを選ぶと、その研究の中では精度が高めに出ます。これはバイアスのリスクの評価で問題になります（表 12.1、12.5 節（p. 131））。

9.7 報告と評価のための指針

診断精度に関わる指針には、似た名前のものがいくつかあり、役割が違います。

STARD 2015　個々の診断精度研究を報告するときの指針です（Bossuyt 2015）。研究を行う人が論文を書くときに使います。メタ解析の報告には使いません。

PRISMA-DTA　診断精度研究の系統的レビューとメタ解析を報告するときの指針です（McInnes 2018）。8.1 節（p. 86）で説明した PRISMA

2020 の診断精度版にあたり、第 15 章で使います。

QUADAS-2 と QUADAS-3　メタ解析に組み入れた個々の研究のバイアスのリスクと適用可能性を評価する道具です（Whiting 2011、Whiting 2026）。4.3 節（p. 37）の RoB 2 にあたり、12.4 節（p. 130）で使います。

STARD に沿って書かれた論文は、必要な情報が揃っていることが多く、2×2 表も作りやすくなります。とはいえ、STARD に準拠していることは研究の質が高いことを意味するわけではありません。報告が丁寧であることと、バイアスのリスクが低いことは別の問題で、後者は QUADAS で判定します。

9.8 この章のまとめ

検査のメタ解析で研究ごとに集めるのは 2×2 表の 4 つの数で、統合するのは感度と特異度です。的中割合は有病割合で変わるので統合せず、使う場面の有病割合を決めてから計算します。尤度比と診断オッズ比は感度と特異度から計算できる補助の指標です。感度と特異度はカットオフを介して逆向きに動き、研究ごとにカットオフや測定法が違えば、精度の見かけの差が生じます。次の第 10 章では、この性質のために、介入のメタ解析の方法をそのまま当てはめられない理由を説明します。

第 10 章

検査のメタ解析はどこが違うのか

この章で分かること

検査の研究は感度と特異度という 2 つの結果を持ち、カットオフや対象の違いによって 2 つが連動して動きます。そのため、感度と特異度を別々に平均する方法は勧められず、両者を同時に扱う二変量モデルか HSROC モデルを使います。要約点を出すか SROC 曲線を出すかはカットオフがそろっているかで決まり、異質性と小規模研究効果の調べ方も、介入のメタ解析とは違います。二変量モデルの仕組み、HSROC モデル、異質性と小規模研究効果の細部は発展の節に置いてあり、初読では飛ばせます。

10.1 2 つの結果が連動して動く

第 1 部の介入のメタ解析では、試験ごとにリスク比を 1 つ計算し、その重み付き平均を求めました。検査の研究では、研究ごとに感度と特異度の 2 つの数があります。2 つを別々に扱ってよいなら、第 1 部の方法を 2 回使えば済みますが、そうはいきません。

9.5 節（p. 100）で見たように、同じ検査でもカットオフを下げれば感度

が上がって特異度が下がり、上げれば逆になります。メタ解析に集めた研究が別々のカットオフを使っていると、研究ごとの感度と特異度は 1 本の ROC 曲線に沿って散らばります。カットオフを明示していなくても、測定試薬の違いや、判定する人の基準の厳しさの違いが、実質的にカットオフをずらすことがあります。この現象を閾値効果と呼びます。

例題の架空の 10 研究（カットオフは 0.25 ng/mL が 2 研究、0.5 ng/mL が 6 研究、1 ng/mL が 2 研究）を、横軸に偽陽性割合、縦軸に感度をとった ROC 平面に置いたのが図 10.1 です。点の大きさは研究の人数を、色の濃さはカットオフを表します。カットオフ 0.25 ng/mL の 2 研究（Nguyen 2014、Tanaka 2023）は右上に寄り、感度は 0.80 以上ですが特異度は 0.71 と 0.54 にとどまります。カットオフ 1 ng/mL の Sato 2021 は特異度 0.91 で左側にあります。研究どうしの感度と特異度の違いの一部は、カットオフの違いで説明できそうです。

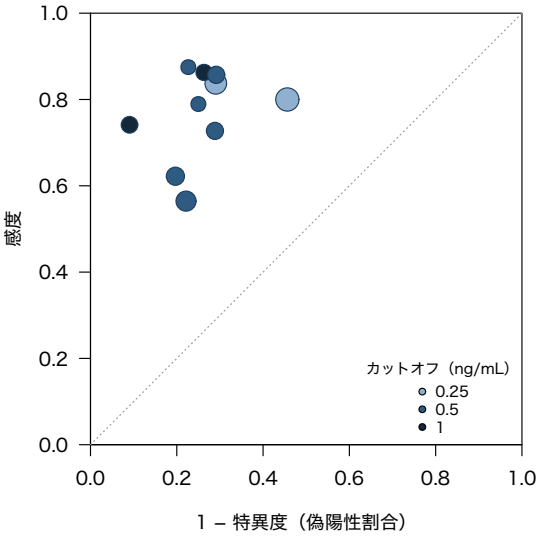


図 10.1　架空の PCT 研究 10 本を ROC 平面に置いた図。色が濃いほどカットオフが高い

同じ図には、カットオフでは説明できない散らばりも見えます。カット

オフ 0.5 ng/mL の 6 研究（Kato 2010、Lopez 2011、Mori 2013、Park 2016、Qureshi 2018、Rossi 2019）の感度は 0.56 から 0.88 までばらついています。対象患者の重症度、採血のタイミング、測定法の違い、それに偶然が重なった結果です。検査のメタ解析では、研究間のばらつきが大きいほうが普通で、それを前提にしたモデルが必要になります。

10.2 感度と特異度を別々に統合すると何が起きるか

最も素朴な方法は、感度だけを集めてランダム効果モデルで統合し、特異度だけを集めて別に統合することです。ランダム効果モデルは 5.4 節（p. 46）で説明しました。カットオフ 0.5 ng/mL の 6 研究では、感度 0.746、特異度 0.757 になります。実データの AUDIT-C（14 研究）でも、別々に統合した感度 0.930、特異度 0.783 と、二変量モデルの感度 0.925、特異度 0.782 は近い値になります。

点推定が近くても、別々に統合する方法には限界があります。AUDIT-C の二変量モデルは、感度と特異度の相関を − 0.818 と推定しました。別々に統合すると、この相関は分からないままです。1 つ目に、相関を無視しているので、2 つを組み合わせた点の不確かさを正しく表せません。信頼区間を 2 本別々に描くと長方形の範囲になりますが、実際の不確かさは傾いた楕円の形をしています。2 つ目に、予測領域や SROC 曲線のように、感度と特異度の関係にもとづく図が描けません。3 つ目に、閾値効果が強いデータでは、別々に平均した点が研究の散らばる帯から外れた位置に来ることがあり、そのような感度と特異度の組み合わせを示す研究はどこにもない、ということが起きます。点推定が近いことと、二変量モデルが要らないことは同じではありません。

発展 古い検査のメタ解析では、診断オッズ比だけを統合する方法や、Moses と Littenberg の方法で SROC 曲線を引く方法も使われてきました。後者は、研究ごとの診断オッズ比の対数を、感度と偽陽性割合から作った閾値の代わりの量に回帰させて曲線を描きます。簡便ですが、研究間のばらつきを組み込まない固定効果の方法です。Cochrane DTA ハンドブックは、次に説明する二変量モデルと HSROC モデルが、これらの方法に取って代わったと述べています（Macaskill 2023、9.4）。古い論文を読むときは、どの方法で統合したかをまず確かめてください。

10.3 感度と特異度を logit の目盛りに直す

二変量モデルは、感度と特異度を割合のまま扱わず、logit という目盛りに直して扱います。割合 p の logit は log(p ÷ (1 − p)) で、オッズ（5.1.4 節（p. 44））の対数です。0 から 1 の範囲に閉じた割合を、端のない目盛りに広げます。第 1 部でリスク比の対数をとって統合したのと同じ発想です（→ 5.1.2 節（p. 43））。表 10.1 に、いくつかの割合の logit を示します。

割合 p	オッズ	logit
0.50	1	0
0.75	3	1.10
0.90	9	2.20
0.95	19	2.94
0.99	99	4.60

表 10.1　割合とその logit。R の qlogis() で計算した

割合の差が同じ 0.04 でも、0.50 と 0.54 では logit の差は約 0.16、0.95 と 0.99 では約 1.65 になります。logit の目盛りを使う理由は 2 つあります。1 つ目は、割合のまま平均や区間を考えると、端（0 や 1 の近く）で区間が 0〜1 をはみ出すことがあるからです。2 つ目は、端では割合の差が小さく見えても意味が大きいからです。特異度 0.95 と 0.99 は、偽陽性が 100 人に 5 人か 1 人かという 5 倍の違いにあたります。R の plogis() は logit から元の割合に戻し、plogis(2.94) は約 0.95 を返します。

10.4
二変量モデルの考え方

二変量モデルは、感度と特異度を一緒に扱うモデルです（Reitsma 2005）。研究ごとに真の感度と真の特異度が違うと考え、その散らばりを logit の目盛りで表します。この散らばりは、第 1 部のランダム効果モデルの研究間分散 τ^2 に当たります（→ 5.4 節（p. 46））。感度と特異度を別々でなく同時に扱うので、2 つの間の相関（感度の高い研究ほど特異度が低くなる傾向）も推定できます。結果は、要約点（平均の感度と特異度）と、そのまわりの楕円（信頼領域と予測領域）で示します。楕円の傾きが相関に、楕円の大きさが研究間のばらつきに当たります。

相関は、− 1 なら研究の点が完全に一直線に並び、0 なら感度と特異度に関係がないことを表します。研究が少ないと相関がうまく推定できず、− 1 や 1 に張り付くことがあります。そのときは相関を 0 と置いた簡単なモデルに切り替えます（13.4 節（p. 150））。

発展 二変量モデルの仕組み

二変量モデルは、感度と特異度を 2 つの階で同時に扱います。図 10.2 にその構造を示します。

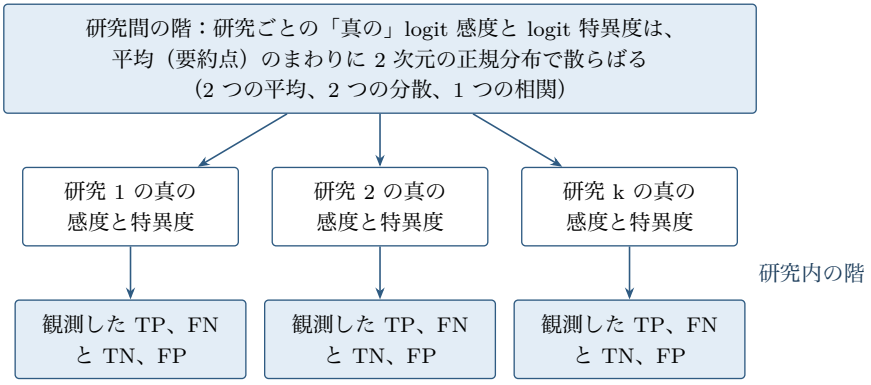


図 10.2　二変量モデルの 2 つの階

下の階（研究内の階）は、各研究の中で起きる偶然の誤差を表します。ある研究の真の感度が 0.75 でも、菌血症の患者 45 人のうち陽性になる人数は偶然で上下し、ちょうど 34 人になるとは限りません。人数の少ない研究ほど、観測した感度は真の値から大きく外れやすくなります。

上の階（研究間の階）は、研究ごとに真の感度と特異度そのものが違うことを表します。カットオフ、対象患者、測定法の違いによって、研究 1 の真の感度と研究 2 の真の感度は異なります。二変量モデルでは、感度と特異度を logit の目盛りに直したうえで、その組が 2 次元の正規分布に従って散らばると考えます。

2 次元の正規分布は、5 つの数で決まります。logit 感度の平均と logit 特異度の平均（この 2 つを元の目盛りに戻したものが要約点です）、それぞれの研究間のばらつき（分散）、そして 2 つの相関です。閾値効果があると、感度が高い研究ほど特異度が低くなるので、logit 感度と logit 特異度の相関は負になります。言い換えると、感度と偽陽性割合の相関は正になります。AUDIT-C では、この相関は − 0.818 と推定されました。一方、例題のカットオフ 0.5 ng/mL の 6 研究では、13.3 節（p. 148）で見るように相関が − 1 の境界に張り付き、推定できませんでした。研究が少ないと、相

関はこのように決まりにくくなります。

研究内の階の扱い方には 2 通りがあります。Reitsma らの元の方法は、研究ごとの logit 感度と logit 偽陽性割合を正規分布で近似し、その分散を人数から計算して与えます。この近似は、人数の少ない研究や、感度や特異度が 1 に近い研究で悪くなり、0 の升目があれば 0.5 を足す補正も要ります。Chu と Cole（2006）が示した方法は、研究内の人数を二項分布のまま扱う一般化線形混合モデルで、0 の升目がある研究でも補正なしに扱えます。Cochrane DTA ハンドブックの第 10 章はこの理由から後者を勧めており、正規近似の方法を Cochrane レビューの解析には勧めていません。R ではそれぞれ mada パッケージの reitsma() と lme4 パッケージの glmer() で当てはめられ、例題では結果はほとんど同じになります（発展の 13.7 節 (p. 155)）。

10.5 発展 HSROC モデルとの関係

もう 1 つの代表的な方法が、Rutter と Gatsonis（2001）の HSROC モデルです。こちらは、各研究が「陽性と判定する基準の厳しさ（閾値）」と「病気のある人とない人を分ける力（精度）」の 2 つの性質を持ち、その 2 つが研究ごとにばらつくと考えます。閾値の違いは研究を 1 本の曲線の上で動かし、精度の違いは曲線そのものを左上へ寄せたり対角線へ寄せたりします。加えて、閾値が動いたときに精度がどう変わるかを表す形のパラメータがあり、曲線が左右対称かどうかを決めます。

二変量モデルと HSROC モデルは、出発点の考え方は違いますが、共変量を入れない場合には数学的に同じモデルで、片方のパラメータからもう片方のパラメータを計算できます（Harbord 2007）。違いは、結果として何を前面に出すかにあります。二変量モデルは要約点（平均の感度と特異度）とその信頼領域を自然に出し、HSROC モデルは SROC 曲線を自然に出し

ます。

10.6 要約点と SROC 曲線のどちらを出すか

SROC 曲線は、ROC 平面（図 10.1）に研究を点で置き、その点の並びに沿って引いた曲線です。カットオフが動いたときに感度と特異度がどう入れ替わるかを、1 本の線で示します。

Cochrane DTA ハンドブックは、要約点と SROC 曲線のどちらを出すかを研究のカットオフで決めるよう整理しています（Macaskill 2023、9.3.1）。組み入れた研究が共通のカットオフを使っているなら、要約点が臨床で意味を持つので、二変量モデルで要約点を推定します。研究が複数のカットオフにまたがり、どのカットオフにも複数の研究があるときは、カットオフごとに同じ解析を繰り返してかまいません。

カットオフが混ざった研究から要約の感度と特異度を出すことは、避けるべきとされています。ハンドブックは、その値が臨床では解釈できず、一般化もできないからだと述べています。例題の PCT には 0.25、0.5、1 ng/mL の研究が混ざっています。これらを平均した感度と特異度は、どのカットオフの値でもなく、PCT を何 ng/mL で陽性としたときの値なのかを答えられません。

カットオフが混ざった全研究には、SROC 曲線を引きます。曲線は、カットオフが動いたときに感度と特異度がどう入れ替わるかの関係を示し、特定のカットオフの値を主張しません。共通のカットオフの研究の要約点と、全研究の SROC 曲線は、両方を示してもかまいません。例題でも両方を出します。要約点はカットオフ 0.5 ng/mL の 6 研究から、SROC 曲線は全 10 研究から出します（13.5 節（p. 151）、13.8 節（p. 156））。カットオフの違いが感度と特異度をどれだけ動かすかは、カットオフを共変量にして調べます（14.2 節（p. 163））。

10.7
異質性をどう見るか

第 1 部では、異質性を Q、I^2、τ^2 で表しました（→ 6.1 節（p. 58））。検査のメタ解析では、このうち I^2 を使うことは勧められていません。Cochrane DTA ハンドブックは、感度と特異度それぞれについての等しさの検定と I^2 の推定を、推奨しないと明記しています（Macaskill 2023、9.3.2）。感度と特異度を別々に計算した I^2 は、2 つの相関と閾値効果を無視しているからです。

> 発展 そのほかの理由もあります。診断精度研究の感度や特異度は、研究ごとの差が標本誤差よりはるかに大きいことが多く、I^2 はしばしば 90% を超えるので、研究どうしを見比べる情報になりません。例えば Wacker らの PCT のメタ解析（2013）では I^2 は 96% でした。さらに、二変量モデルに対応する I^2 の定義はいくつか提案されていますが、まだ定まっていません。例題のカットオフ 0.5 ng/mL の 6 研究を mada で解析すると、提案された方法によって 0% から 63.7% まで違う値が出ます。madad() が出力する等しさの検定（13.1 節（p. 141））も同じ理由で、出力には出ますが判断には使いません。

代わりに使うのは、ROC 平面に研究を置いた図と、二変量モデルが推定する研究間の標準偏差、そして 95% 予測領域です。予測領域は、次の研究がどこに来そうかを示す楕円で、第 1 部の予測区間（6.3 節（p. 62））を 2 次元に広げたものです。予測領域が広ければ、要約点がどれだけ確かに推定されていても、実際の現場での精度は大きくばらつくと読みます。ただし予測領域は、研究間の分布が 2 次元の正規分布に従うという仮定に頼っています。研究数が少ないと、この仮定のもとでの推定が不安定で、領域は実際より広くも狭くも出ます（Macaskill 2023、9.3.2、Deeks 2019）。形と大きさは目安として読みます。図を見て、閾値効果で説明できる散らば

り（曲線に沿った散らばり）と、説明できない散らばり（曲線から離れる散らばり）を区別し、後者の原因を共変量で探します（14.1 節（p. 161））。

10.8
小規模研究効果の調べ方

検査のメタ解析では Egger 検定を使わず、調べるなら Deeks の検定を使います（15.2 節（p. 184）の GRADE でもこの検定を使います）。Egger 検定は 7.3 節（p. 74）で説明しました。理由と Deeks の検定の中身は、発展の 10.8.1 節（p. 116）に書きました。研究が少ないと検出力は低く、有意でなくても偏りがないとは言えません。

発展 Egger 検定を使えない理由と Deeks の検定

第 1 部ではファネルプロットと Egger 検定で小規模研究効果を調べました（→ 7.2 節（p. 73））。検査のメタ解析では、Egger 検定を診断オッズ比にそのまま当てはめると、出版バイアスがなくても非対称と判定されやすいことが知られています（Deeks 2005）。診断オッズ比の標準誤差は、2×2 表の 4 つの数から計算され、診断オッズ比の大きさそのものとも結びついているためです。

Deeks らはこの問題を避ける検定を提案しました。縦軸に診断オッズ比の対数、横軸に「有効な標本の大きさ」の平方根の逆数をとって研究を置き、両者の関係を回帰で調べます。有効な標本の大きさは、病気のある人の数とない人の数から計算する量で、標準誤差の代わりに研究の大きさを表します。Cochrane DTA ハンドブックはこの方法を紹介しています。ただし研究数が少ないと検出力が低く、また検査の研究がどのような理由で未発表になるかは介入の試験ほど分かっていないので、検定の結果は慎重に読みます。例題の 10 研究では、この検定で偏りがないと判断できるだけ

の情報はありません。

一方で、小さい研究ほど精度が高く出るという現象は、検査のメタ解析でも報告されています。Tang らの PCT のメタ解析（2007）では、Sackett と Haynes の分類で phase 3 とされた 4 研究で、標本サイズが小さい研究ほど精度が高く、大きい研究では帰無に近づく関係が見られました（メタ回帰の係数 -0.592、$p = 0.017$）。検定の有意性よりも、こうした傾向が見えたときに、小さい研究の設計に偏りがないかを QUADAS で確かめることのほうが役に立ちます。

10.9 この章のまとめ

検査のメタ解析では、感度と特異度を別々に統合せず、logit の目盛りに直したうえで、両者の相関と研究間のばらつきを同時に扱う二変量モデルか HSROC モデルを使います。共通のカットオフの研究なら二変量モデルで要約点を出し、カットオフが混ざった研究から要約点を出すことは避け、全研究には SROC 曲線を示します。両方を示してもかまいません。異質性は等しさの検定や I^2 ではなく、ROC 平面の図と予測領域で見ます。予測領域は正規分布の仮定に頼るので、研究が少ないときは目安にとどめます。小規模研究効果は Egger 検定ではなく Deeks の検定で調べ、結果は慎重に読みます。次の第 11 章では、こうした解析に入る前の工程として、問いの立て方と文献の選別を、架空の PCT の抄録で練習します。

第 11 章

検査のレビューの問いと文献の選別

この章で分かること

検査のレビューの問いは、対象、対象検査、参照基準、標的疾患の 4 つと、検査を使う場面と役割で決まります。検索では研究デザインの絞り込み（フィルター）をかけず、広く拾ってから人の目で選別します。架空の PCT の抄録 7 件で、組み入れるかどうかの判断を練習します。不完全な参照基準を扱う潜在クラスモデルの紹介は、発展の囲みに置いてあり、初読では飛ばせます。

11.1 問いを立てる

介入のメタ解析の問いを PICO（対象、介入、比較、アウトカム）で立てたように、検査のメタ解析の問いは次の要素で組み立てます（→ 2.1 節 (p. 21)）。

対象　どんな人に検査を行うのかを決めます。例題では、発熱して救急外来を受診した成人、または ICU で発熱した成人です。

対象検査　精度を知りたい検査とカットオフです。例題では血清または血漿の PCT で、カットオフは研究ごとに異なってよいとします。

参照基準　正解を決める方法です。例題では血液培養で、汚染菌と判断された陽性は陰性として扱います。

標的疾患　見分けたい状態です。例題では菌血症です。

この 4 つに加えて、検査を臨床のどの場面で、どんな役割で使うのかを決めておきます。役割には、既存の検査の置き換え（今の検査の代わりに使う）、トリアージ（後の検査を受ける人を絞り込むために先に使う）、追加（今の検査に上乗せする）があります。例えば PCT を「血液培養を採るかどうかを決めるトリアージ」として使うなら、見逃し（偽陰性）を少なくすることが求められ、感度を重く見ます。「抗菌薬を始めるかどうかの決め手」として使うなら、偽陽性による不要な投与も問題になります。役割によって、結果のどの数字を重く見るかと、どの研究がその問いに合っているかが変わります。

例題の参照基準の血液培養は、完全な正解ではありません。採血の量、採るセットの数、抗菌薬を投与した後かどうかで、菌血症のある人が陽性になる割合が変わります。菌血症があっても培養が陰性になった人は、2×2 表では菌血症なしに数えられ、PCT が高ければ偽陽性になるので、PCT の特異度は低く見えることがあります。

> 発展 不完全な参照基準を扱う方法として潜在クラスモデルがあり、Cochrane DTA ハンドブックの 9.5.1 に書かれていますが、本書では扱いません。

レビューでは、参照基準の限界を抽出フォームに記録し（12.1 節 (p. 127)）、考察で述べます。

例題の問いを 1 文で書くと、「発熱した成人（救急外来または ICU）で、PCT は血液培養で確認された菌血症をどれだけ正しく見分けるか」になります。この問いは、2.4 節（p. 24）で説明したようにプロトコルに書

き、PROSPERO に登録してから検索を始めます。プロトコルには、カットオフが複数報告されている研究からどの値を取るか、判定不能の結果をどう扱うかといった、データ抽出の規則も先に書いておきます（12.3 節 (p. 129)）。

11.2 検索の組み立て

検索の考え方は 3.2 節（p. 28）と同じで、概念ごとに同義語を OR でつなぎ、概念どうしを AND でつなぎます。検査のレビューで使う概念は、多くの場合「対象検査」と「標的疾患」の 2 つだけです。PubMed での検索式の例を示します。

```
("Procalcitonin"[Mesh] OR procalcitonin[tiab] OR PCT[tiab])
AND
("Bacteremia"[Mesh] OR bacteremia[tiab] OR bacteraemia[tiab]
 OR "bloodstream infection"[tiab] OR "blood culture"[tiab])
```

この式は R のコードではなく、PubMed の検索欄に入れる文字列です。介入の RCT を探すときは「ランダム化比較試験」に絞り込む検索フィルターを付けることがありますが、診断精度研究ではこのような研究デザインのフィルターを付けません。診断精度研究は、論文の題や抄録に「感度」「特異度」と書かれていないことが多く、索引語（MeSH）の付け方もそろっていないので、フィルターを付けると必要な研究を取りこぼします。Cochrane DTA ハンドブックも、フィルターだけで絞り込むことを勧めていません。その代わり、選別する抄録の数は増えます。

データベースは PubMed（MEDLINE）、Embase、Cochrane Library を基本にし、日本の研究を拾うなら医学中央雑誌も加えます。検査の研究は学会抄録や企業の技術資料として発表されることもあるので、灰色文献をどこまで探すかもプロトコルに書いておきます。検索式とその実行日は、

PRISMA-DTA に従って報告するため、データベースごとに記録します。

11.3 抄録の選別の手順

検索で集めた記録は、まず文献管理ソフトで重複を取り除きます。そのうえで、2 人のレビュー著者が独立に、題と抄録だけを読んで、組み入れ基準を満たす可能性があるかを判定します。判定は 3 通りで、「明らかに満たさない」なら除外し、「満たす」または「分からない」なら本文を取り寄せて確認します。抄録の段階では、迷ったら残すのが原則です。抄録に書かれていないことは本文に書かれていることが多く、抄録の段階で除外した研究は二度と見直されないからです。詳しくは 3.3 節（p. 29）を読み直してください。

2 人の判定が食い違ったら、話し合って決め、決まらなければ 3 人目が判定します。本番の前に 50 件ほどを 2 人で試しに判定し、判定の基準をそろえておくと、食い違いが減ります。2 人の判定の一致の度合いを κ 係数で報告することもあります。

11.4 抄録の選別の演習

架空の検索で見つかった抄録のうち 7 件を、短く要約して示します。どれも架空のもので、実在の論文ではありません。組み入れ基準は、先の問いの 4 要素を満たし、2×2 表が作れることとします。読者も判定してから、次の節の答えと見比べてください。第 1 部の 3.4 節（p. 30）と同じ形式の演習です。

抄録 A（Lopez 2011）　スペインの救急外来で、発熱した成人 482 人を連

続して登録した。受診時に PCT を測定し、全員に血液培養を行った。血液培養陽性は 62 人だった。カットオフ 0.5 ng/mL での感度と特異度を報告した。

抄録 B（Mori 2013） 日本の ICU で、新たに発熱した成人 178 人を前向きに登録し、発熱時の PCT と血液培養を比べた。血液培養陽性は 38 人で、カットオフ 0.5 ng/mL での診断精度を示した。

抄録 C 血液培養で菌血症と確定した入院患者 60 人と、健康診断を受けた健康な成人 60 人の PCT を比べた。カットオフ 0.5 ng/mL で感度 0.92、特異度 0.98 だった。

抄録 D 救急外来の発熱患者 640 人で、PCT と CRP の菌血症に対する AUC を比べた。PCT の AUC は 0.79、CRP は 0.66 だった。感度と特異度は抄録に書かれていない。

抄録 E 小児救急外来を受診した 3 か月から 15 歳の発熱児 410 人で、PCT による重症細菌感染症の診断精度を調べた。

抄録 F ICU の成人 230 人で、主治医が臨床経過から判断した「敗血症」の有無を正解として、PCT の診断精度を調べた。

抄録 G 下気道感染症の外来患者を、PCT の値に基づいて抗菌薬を処方する群と通常診療の群にランダムに割り付け、抗菌薬の処方日数を比べた。

11.5 演習の答えと判定の理由

判定と理由を表 11.1 にまとめます。

抄録	判定	理由
A	本文へ	対象、検査、参照基準、標的疾患がすべて合う
B	本文へ	ICU の発熱患者で、問いの範囲に入る
C	除外	症例対照デザインで、対照が健康な人
D	本文へ	抄録には 2×2 がないが、本文で作れる可能性がある
E	除外	対象が小児で、問いの対象（成人）と違う
F	除外	参照基準が主治医の臨床判断で、標的疾患も敗血症
G	除外	精度ではなく、検査を使った治療方針の効果を調べた RCT

表 11.1　架空の抄録 7 件の判定

抄録 A と B は迷わず残します。抄録 D は、抄録に感度と特異度が書かれていないので除外したくなりますが、本文の表や補足資料に複数のカットオフでの成績が載っていることがあります。2×2 表が作れるかどうかは本文を見ないと分からないので、本文へ進めます。本文を見ても作れなければ、その時点で「2×2 表が作れない」という理由で除外し、理由を記録します。

抄録 C は、感度 0.92、特異度 0.98 と、ほかの研究よりずっと良い成績を示しています。この成績の良さは、研究の設計から生まれたものです。対照群が健康診断を受けた健康な人なので、PCT はほとんど上がっておらず、特異度は高く出ます。症例群も、入院してから菌血症と確定した、病状のはっきりした患者なので、PCT は高く、感度も高く出ます。実際に PCT を使う場面で見分けたいのは、同じように発熱して受診した人の中の、菌血症の人とそうでない人です。発熱していて PCT がそこそこ上がっているけれども菌血症ではない人（ウイルス感染症や非感染性の炎症）が対照にいないので、見分けにくい部分が研究から抜け落ちています。

このように、研究に含まれる患者の病状の幅（スペクトラム）が実際の使い方と違うことで精度が偏ることを、スペクトラムバイアスと呼びます。症例対照デザインの診断精度研究は精度を高めに見積もりやすく（表 12.1、12.5 節（p. 131））、QUADAS-2（12.4 節（p. 130））でも、患者選択の領域

の信号質問「症例対照デザインを避けたか」に「いいえ」と答えることになり、バイアスのリスクは高いと判定されやすくなります。

症例対照デザインの研究を組み入れ基準で除外するか、組み入れたうえで患者選択を高と判定するかは、プロトコルで事前に決めます。例題では、連続登録またはランダム登録のコホートを組み入れ基準にして、抄録 C のような研究は除外としました。

抄録 E は、対象が小児なので除外します。小児と成人では、PCT の基準範囲も、菌血症の起因菌や頻度も違うので、同じ問いには入れません。小児を含めるかどうかはプロトコルで決めておくことで、データを見てから決めることではありません。

抄録 F は、参照基準が主治医の判断で、標的疾患も菌血症ではなく敗血症なので、問いに合いません。さらに、主治医が PCT の値を知ったうえで敗血症かどうかを判断していれば、正解の決め方が検査の結果に左右されます。参照基準を判定する人が対象検査の結果を知っていることによる偏りを、診断レビューバイアスと呼びます（表 12.1）。QUADAS-2 では参照基準の領域で問います。これとは別に、対象検査の結果そのものが参照基準の一部になっている場合を、取り込みバイアス（incorporation bias）と呼びます。たとえば、診断基準に血清クレアチニンの上昇が含まれる急性腎障害を、血清クレアチニンで見分けられるかを調べる研究では、正解の決め方に検査の値が入っています。PCT の値を診断の基準に含めて敗血症と判定した研究も同じです。抄録 F の記載だけでは、主治医が PCT の値を知っていたのか、診断の根拠に PCT が入っていたのかは分からないので、本文で確かめます。どちらの場合も、PCT と正解が実際より一致して見え、精度は高めに出る恐れがあります。

抄録 G は、PCT の精度ではなく、PCT を使った診療方針の効果を調べた RCT です。これは介入のメタ解析の対象で、検査の精度のレビューには入れません。

11.6
フロー図

選別の結果は、PRISMA-DTA に沿ったフロー図で報告します。PRISMA 2020 の書式に合わせ、研究の数と報告の数を分けて数えます（フロー図の見方は 3.5 節（p. 32）で、重複した報告を試験単位にまとめる作業は 3.3 節（p. 29）で説明しました）。同じ研究について複数の報告（本論文、続報、学会抄録）があるとき、報告は別々に数え、研究は 1 つと数えます。架空の例を図 11.1 に示します。

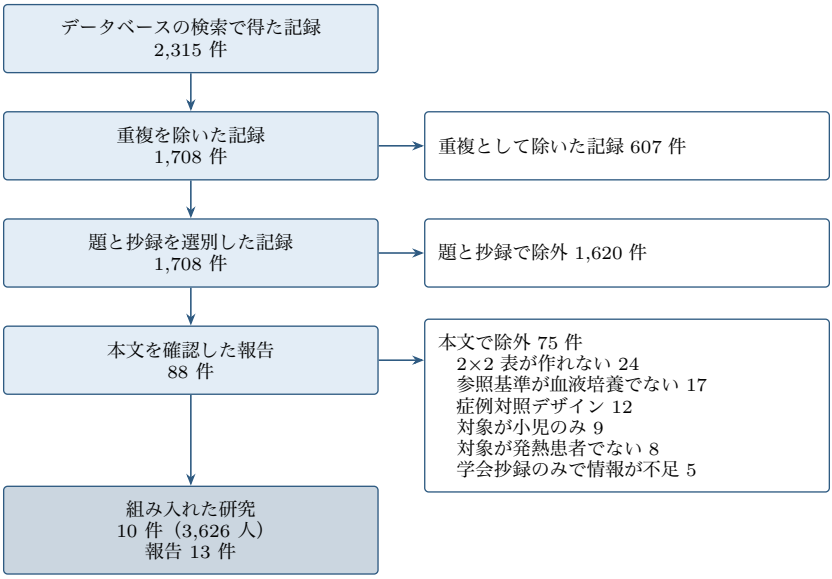


図 11.1　架空の PCT のレビューのフロー図（数は例）

除外の理由は、本文を確認した段階では件数とともに報告します。抄録の段階の除外は件数だけでかまいません。組み入れた研究には、研究の数と人数に加えて、その研究にまとめた報告の数も書きます。例題の 10 研究

の合計は 3,626 人で、そのうち血液培養が陽性だったのは 556 人です。

同じ研究の重複報告は、除外の理由には数えず、報告を研究にまとめる作業として扱います。同じ患者集団が、学会抄録、本論文、別の解析を加えた続報として何度も発表されることがあります。同じ患者を 2 回数えると、その研究の重みが不当に大きくなります。著者名、施設、登録期間、人数を照らし合わせて、同じ集団かどうかを判断し、1 つの研究にまとめます。解析に使うデータは、情報が最も多い報告から取ります。例題では、本文を確認した 88 件の報告のうち 75 件を除外し、残った 13 件の報告が 10 研究に対応しました。3 件の報告が、ほかの報告と同じ研究のものだったためです。

11.7 この章のまとめ

検査のレビューの問いは、対象、対象検査、参照基準、標的疾患と、検査を使う場面と役割で立てます。検索ではデザインのフィルターをかけず、2 人が独立に抄録を選別し、迷った記録は本文まで残します。症例対照デザイン、参照基準が問いと違う研究、検査の結果を見て正解を決めた研究は、精度を偏らせるので除外するか、バイアスのリスクが高いと判定します。次の第 12 章では、残した論文の本文から 2×2 表を取り出し、QUADAS-2 でバイアスのリスクを評価します。

第 12 章

2×2 表を取り出し、バイアスのリスクを評価する

この章で分かること

本文から取り出すデータの中心は 2×2 表の 4 つの数で、感度と特異度しか書かれていなくても、人数が分かれば表を復元できます。取り出した研究ごとに、QUADAS-2 の 4 つの領域でバイアスのリスクと適用可能性を判定します。検査の研究に特有のバイアスのうち初めに押さえる 4 つと、検査技師が論文の方法の節で確かめる点を整理し、最後に CSV を R に読み込みます。実証研究の紹介と、2026 年に公表された改訂版の QUADAS-3 の変更点は、発展の印をつけて載せました。

12.1 抽出フォームの項目

データ抽出は、4.1 節（p. 34）と同じく 2 人が独立に行い、結果を突き合わせます。抽出の前に、何をどの形で記録するかを抽出フォームとして決め、2〜3 本の論文で試して直しておきます。検査のレビューで記録する項目は、おおむね次のとおりです。

研究の特徴　著者、発表年、国、施設、登録期間、研究デザイン（前向きか後ろ向きか、連続登録か）を記録します。

対象　場面（救急外来か ICU か）、組み入れ基準と除外基準、年齢、重症度の指標、抗菌薬がすでに投与されていたかを記録します。

対象検査　測定試薬と機器（測定原理と製造元）、検体の種類（血清か血漿か）、採血の時点（受診時か、発熱から何時間後か）、採血から測定までの時間と保存条件、カットオフとその決め方（事前に決めたか、データを見て決めたか）を記録します。

参照基準　血液培養のセット数、汚染菌の判断の仕方、培養の結果を判定した人が PCT の値を知っていたかを記録します。

結果　カットオフごとの TP、FP、FN、TN と、判定不能や検体不良で解析から外れた人数を記録します。

検査技師が抽出に加わるとき、対象検査の項目はとくに丁寧に記録してください。9.6 節（p. 104）で説明したように、測定試薬や採血の時点の違いは研究間のばらつきの原因になりえます。論文の方法の節で測定法が「PCT を測定した」としか書かれていなければ、「記載なし」と記録し、空欄にしません。空欄は「確認していない」のか「書かれていない」のかが区別できないからです。

12.2
本文から 2×2 表を作る

論文に 2×2 表がそのまま載っていることは、むしろ少数です。2×2 表の意味は 9.1 節（p. 95）、介入の試験での作り方は 4.2 節（p. 35）で説明しました。多くは感度と特異度、あるいは陽性的中割合と陰性的中割合が、人数と一緒に書かれています。架空の Lopez 2011 の結果の段落が、次のように書かれていたとします。

演習の素材（架空）

登録した 482 人のうち、血液培養が陽性だったのは 62 人（12.9%）だった。PCT の中央値は、培養陽性群で 1.2 ng/mL、陰性群で 0.21 ng/mL だった。カットオフを 0.5 ng/mL としたときの感度は 56.5%、特異度は 77.9% だった。

この段落から 2×2 表を復元します。病気のある人は 62 人なので、真陽性は 62 × 0.565 で 35.03、四捨五入して 35 人です。偽陰性は残りの 62 − 35 で 27 人になります。病気のない人は 482 − 62 で 420 人なので、真陰性は 420 × 0.779 で 327.18、四捨五入して 327 人、偽陽性は 420 − 327 で 93 人です。復元した表から感度を計算し直すと 35 ÷ 62 で 0.5645、特異度は 327 ÷ 420 で 0.7786 となり、論文の 56.5% と 77.9% に一致します。

計算し直して元の値に戻ることを、毎回確かめてください。論文の割合は丸めて書かれているので、人数に掛けた値が 2 つの整数の中間近くに来て、四捨五入の向きを決めかねることがあります。そのときは、その前後の整数で感度を計算し直し、論文の値に一致するほうを選びます。どちらでも一致する場合や、どちらでも一致しない場合は、抽出した 2 人で判断を記録し、必要なら著者に問い合わせます。陽性的中割合と陰性的中割合しか書かれていなくても、陽性になった人数と陰性になった人数が分かれば、同じように表を復元できます。

12.3
抽出で迷う場面

2×2 表を作る段階で、判断に迷う場面がいくつかあります。どう扱うかは、データを見る前にプロトコルで決めておきます。研究の結果を見てから扱いを選ぶと、選んだ人の期待に沿った方向へ結果が偏るからです。

複数のカットオフ　1 本の論文が 0.25、0.5、1.0 ng/mL のそれぞれで成績を報告していることがあります。同じ患者から 3 つの 2×2 表を取る

と、同じ人を 3 回数えることになるので、1 研究から 1 つを選びます。例題では「0.5 ng/mL があればそれを、なければ著者が主とした値を取る」という規則にしました。

判定不能の結果　検体の溶血や量の不足で測定できなかった人は、2×2 表のどこにも入りません。何人が外れたかを記録し、多ければ 12.4 節（p. 130）で説明するフローとタイミングの領域で考慮します。

1 人の複数のエピソード　同じ患者が入院中に何度も発熱し、そのたびに PCT と血液培養を測っていることがあります。エピソードを単位に数えると、同じ人の結果が互いに似ているため、独立した観測として扱えません。患者を単位にした表があればそれを取り、なければその旨を記録します。

全員が参照基準を受けていない　主治医が必要と判断した人だけに血液培養を採った研究では、PCT が低くて培養を採らなかった人が表から抜けます。この偏りを部分的検証バイアスと呼びます。

12.4 QUADAS-2 の 4 つの領域

組み入れた研究ごとに、バイアスのリスクを評価します。現在のレビューで最も広く使われているのは QUADAS-2 です（Whiting 2011）。RCT で使う RoB 2 と同じく、領域ごとに判定する道具です（→ 4.3 節（p. 37））。QUADAS-2 は研究を 4 つの領域に分け、領域ごとに「バイアスのリスク」を判定し、最初の 3 つの領域では「適用可能性の懸念」も判定します。バイアスのリスクは、研究の結果が真の精度から系統的にずれている恐れを表し、適用可能性の懸念は、研究の対象や検査の方法がレビューの問いとずれている恐れを表します。

患者選択　対象者を連続して、またはランダムに登録したか、症例対照デ

ザインを避けたか、不適切な除外をしていないかを問います。

対象検査　対象検査の結果を、参照基準の結果を知らずに判定したか、カットオフを事前に決めていたかを問います。

参照基準　参照基準が標的疾患を正しく判定できる方法か、参照基準の結果を、対象検査の結果を知らずに判定したかを問います。

フローとタイミング　対象検査と参照基準の間隔は適切か、全員が参照基準を受けたか、全員が同じ参照基準を受けたか、全員が解析に含まれたかを問います。

それぞれの問いはシグナリング質問と呼ばれ、「はい」「いいえ」「不明」で答えます。すべて「はい」なら、その領域のバイアスのリスクは低いと判定します。1 つでも「いいえ」があれば、バイアスが生じる可能性を検討し、その影響が大きいと判断すれば高いと判定します。情報が足りなければ「不明」とします。判定は機械的な点数ではなく、レビュー著者の判断で、判断の理由を一文ずつ記録しておきます。

12.5 検査の研究に特有のバイアス

診断精度研究のバイアスは、介入の RCT のバイアスとは別の名前で呼ばれます。QUADAS-2 のシグナリング質問は、これらのバイアスを防げているかを問う形になっています。表 12.1 に、バイアスの名前、何が起きるか、精度が動く向き、対応する QUADAS-2 の領域を並べます。初めて読むときは、上段の 4 つ（スペクトラムバイアス、部分的検証バイアス、診断レビューバイアス、データを見てから決めたカットオフ）を押さえれば十分です。

バイアス	何が起きるか	精度の動き	領域
初めに押さえる 4 つ			
スペクトラムバイアス	重症例と健康者のように、実際の使い方とかけ離れた集団で測る（症例対照デザイン）	感度も特異度も高く出る	患者選択
部分的検証バイアス	一部の人だけが参照基準を受ける。検査陽性の人ほど受けやすい	感度が高く、特異度が低く出やすい	フローとタイミング
診断レビューバイアス	参照基準の判定者が、対象検査の結果を知っている	高く出る方向に動くことが多い	参照基準
データを見てから決めたカットオフ	最適なカットオフを同じデータで選ぶ	高く出ると考えられるが、実証は乏しい	対象検査
そのほか			
不適切な除外	判定の難しい患者や、境界域の値の患者を解析から除く	高く出ると考えられる	患者選択
差異的検証バイアス	検査の結果によって、別の参照基準を使う	高く出る方向に動くことが多い	フローとタイミング
取り込みバイアス	対象検査の結果が参照基準の一部になっている	高く出ると考えられるが、実証は乏しい	参照基準
検査レビューバイアス	対象検査の判定者が、参照基準の結果を知っている	向きは場合による。目視など判定に主観が入る検査で問題になる	対象検査
対象検査と参照基準の時間差	両者の間に病状が変わる（治療の開始、自然経過）	向きは場合による	フローとタイミング
判定不能の結果を除く	測定できなかった検体や不良検体を解析から除く	向きは場合による	フローとタイミング

表 12.1　検査の研究に特有のバイアス

症例対照デザインの研究は、精度を高く見積もりやすいことが実証研究で示されています。一部の人だけに参照基準を行った研究も、精度が偏りやすくなります。

発展 精度が動く向きのうち、実証研究で確かめられているものは限られます。Lijmer らは、診断精度研究のメタ解析で扱われた 184 の研究（218 の検査の評価）を調べ、研究の設計の欠点と診断オッズ比（9.4 節（p. 98））の関係を回帰モデルで推定しました（Lijmer 1999）。結果は相対診断オッズ比で示されています。これは、ある欠点をもつ研究の診断オッズ比を、その欠点のない研究の診断オッズ比で割った値で、

1 を超えると精度を高く見積もっていることを表します。病気のある集団と別の対照群を比べた研究（症例対照デザイン）は、臨床の集団で調べた研究より診断精度を高く見積もり、相対診断オッズ比は 3.0（95% 信頼区間 2.0〜4.5）でした。検査の陽性と陰性で別々の参照基準を使った研究も高く見積もり、相対診断オッズ比は 2.2（1.5〜3.3）でした。参照基準を、対象検査の結果を知ったうえで判定した研究も、相対診断オッズ比は 1.3（1.0〜1.9）と高めでした。症例対照デザインで感度も特異度も高く出るのは、病気のある側には見分けやすい重症例が、ない側には明らかに健康な人が集まるためです。

Whiting らの系統的レビューは、研究の結果に影響する要因を、証拠の厚さで分けて報告しています（Whiting 2004）。最も証拠が多かったのは、対象者の特徴、有病割合と重症度、部分的検証バイアス、臨床情報によるレビューバイアス、測定者と測定機器によるばらつきです。対象者の選び方の偏り、参照基準がない、または不適切なこと、差異的検証バイアス、レビューバイアスは、証拠が限られていました。取り込みバイアス、治療パラドックス、閾値の恣意的な選択、脱落については、証拠が見つかりませんでした。表で「実証は乏しい」と書いた取り込みバイアスとデータを見てから決めたカットオフは、この最後の群にあたります。理屈の上では精度が高く出ますが、どれだけ動くかは測られていません。

Rutjes らは、31 件のメタ解析に含まれる 487 研究を使って、15 の研究の特徴と診断精度の関係を調べました（Rutjes 2006）。連続登録でない研究は相対診断オッズ比 1.5（1.0〜2.1）、後ろ向きにデータを集めた研究は 1.6（1.1〜2.2）と、高い精度を報告していました。重症例と健康な対照を組み合わせた研究の推定値は 4.9 ですが、区間は 0.6〜37.3 と広く、確かなことは言えません。この研究の結論は、設計の欠点が精度の推定値に影響しうるが、その大きさは状況によって違う、というものです。表の精度の動きに「場合による」や「実証は乏しい」

と書いた項目があるのは、このためです。

12.6 検査技師の目で読む対象検査

対象検査の領域と、その適用可能性の懸念は、検査技師が最も詳しく判断できる部分です。QUADAS-2 のシグナリング質問は、検体の取り扱いや測定条件を直接には問いません。そこで、レビューの問いに合わせて、次の点を論文の方法の節で確かめ、対象検査の領域か適用可能性の懸念に書き込みます。

検体の取り扱い　採血から遠心分離までの時間、測定までの時間、保存温度（冷蔵か凍結か）、凍結保存の期間、溶血や乳びの検体の扱いを、方法の節の「検体採取」や「測定」の項で探します。保存した検体を後でまとめて測定した研究は、実際の診療で採血してすぐ測る使い方と条件が違うので、適用可能性の懸念に記録します。何も書かれていなければ「記載なし」とし、判定の理由には「検体の取り扱いの記載がない」と書きます。

測定試薬と機器　測定原理、製造元、機器の名前、試薬のロットや世代、校正の方法を確かめます。同じ PCT でも試薬が違えば同じ検体で値が少しずれ、カットオフ 0.5 ng/mL の実質的な位置が研究ごとに変わります。レビューの問いが日常検査で使われている自動分析装置を想定していれば、研究用の手法や普及していない試薬を使った研究は、適用可能性の懸念を高とするか、試薬の違いを研究の特徴として記録して 14.1 節（p. 161）の共変量の解析で調べます。

測定者の盲検化　測定者が血液培養の結果や臨床の経過を知っていたかを、方法の節か、解析に関する記述で確かめます。自動分析装置が出す数値は測定者の判断が入る余地が小さいので、盲検化が書かれていなく

ても、バイアスのリスクは小さいと考えられます。目視で判定する迅速キットや、波形を人が解釈する検査では、参照基準の結果を知ったうえでの判定が結果を動かしえます。検査の種類によって重みが違うので、判定の理由に検査の種類を書きます。

カットオフの決め方　方法の節に、カットオフを研究開始前に決めたと明記されているかを確かめます。製造元の添付文書の値や先行研究の値を使っていれば、事前に決めたと判定できます。結果の節で ROC 曲線を描いて最適な点を選んでいれば、データを見て選んだことになり、対象検査の領域は高と判定します。

測定に関わる情報は、本文の方法の節に書かれていないことが多く、補足資料や、研究を計画したときのプロトコル論文にある場合があります。それでも見つからなければ、著者に問い合わせるか、不明と判定します。「PCT を測定した」とだけ書かれた論文を、測定が適切だったと推測して低と判定することは避けます。

12.7 QUADAS-2 の演習

架空の 10 研究について、架空の本文の情報から判定した例を図 12.1 に示します。4.3 節（p. 37）の図 4.1 と同じ形式で、列が領域、行が研究、円の記号が判定です。

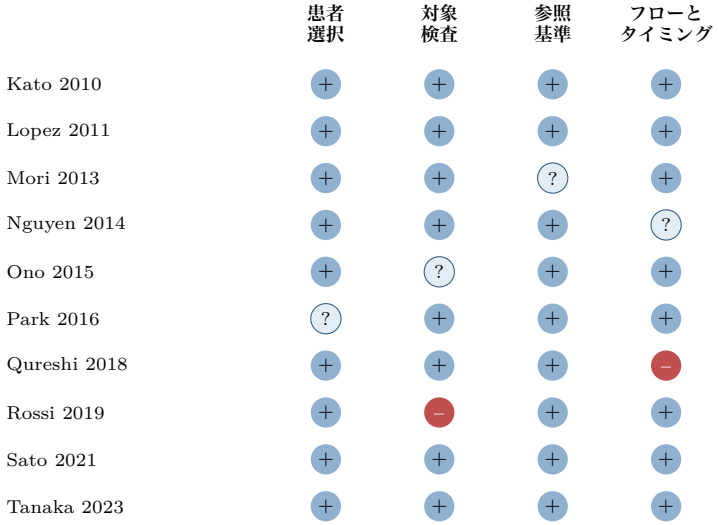


図 12.1　架空の 10 研究のバイアスのリスクの判定（QUADAS-2）。＋ 低、？ 不明、－ 高

Kato 2010、Lopez 2011、Sato 2021、Tanaka 2023 は、4 つの領域のどれにも懸念がなく、すべて低と判定します。例えば Tanaka 2023 は、救急外来の発熱患者を連続して登録し、カットオフ 0.25 ng/mL を研究開始前の計画書に書いていました。血液培養は全員に採られ、微生物検査の担当者は PCT の値を知らずに判定し、PCT の測定者は培養の結果を知らずに測定していました。

不明の判定は、判定に必要な情報が書かれていない場合につけます。Park 2016 は、患者の登録方法について「研究に同意した患者」としか書かれておらず、連続登録かどうかが分かりません。夜間や休日に受診した重症の患者が抜けていれば、スペクトラムが偏る可能性があります。情報不足なので、患者選択の領域は不明とします。Mori 2013 は、血液培養の陽性と陰性を判定した人が PCT の値を知っていたかどうかの記載がありません。知っていれば診断レビューバイアスが生じうるので、参照基準の領域は不明とします。Nguyen 2014 は、PCT の採血と血液培養の採取の間隔が書かれていません。間隔が長ければ、その間に抗菌薬が始まるなどして菌

血症の状態が変わりうるので、フローとタイミングの領域は不明とします。Ono 2015 は、カットオフ 1.0 ng/mL を事前に決めていたのか、結果を見てから選んだのかの記載がありません。対象検査の領域は不明とします。

高の判定は、バイアスが生じる設計であることが分かっている場合につけます。Rossi 2019 は、集めたデータで ROC 曲線を描き、感度と特異度の和が最大になる点としてカットオフ 0.5 ng/mL を選んでいました。データを見てカットオフを選ぶと、その研究の偶然のばらつきに合う位置が選ばれるので、同じカットオフを別の患者に使ったときより精度が高めに出ます。対象検査の領域を高と判定します。

Qureshi 2018 は、ICU の発熱患者のうち、主治医が血液培養を依頼した患者だけを解析していました。PCT が低く、主治医が菌血症を疑わなかった患者は血液培養を採られず、表から抜けています。12.3 節（p. 129）で説明した部分的検証バイアスにあたり、フローとタイミングの領域を高と判定します。

12.8 判定の使い方

QUADAS-2 の判定を点数にして合計し、「質のスコア」として研究を並べることはしません。4 つの領域の偏りは、精度を高める方向にも低める方向にも働き、重みも違うので、足し合わせた数には意味がないからです。判定は領域ごとの表と図（図 12.1 のような信号機の図）で示します。

判定は、研究を解析から除くための関門ではありません。使い道は 3 つあります。1 つ目は、バイアスのリスクが高い研究を除いても結果が変わらないかを確かめる感度分析で、14.5 節（p. 170）で行います。2 つ目は、判定の違いを共変量やサブグループとして調べる解析です。例題は研究数が少ないので行いません。3 つ目は、結果の確実性を GRADE（7.8 節（p. 80））で評価するときの材料で、15.2 節（p. 184）で使います。

例題では、高と判定された Rossi 2019 と Qureshi 2018 が、どちらもカットオフ 0.5 ng/mL の研究で、主解析に入る 6 研究（Kato 2010、Lopez 2011、Mori 2013、Park 2016、Qureshi 2018、Rossi 2019）の中にあります。この 6 研究の要約点は感度 0.746、特異度 0.757 でした。高リスクの 2 研究を除いた 4 研究では、感度 0.709、特異度 0.781 でした（第 14 章）。部分的検証バイアスのある研究は感度が高く出やすいので、除いたときに感度が下がったことは予想と合っています。ただし、2 研究を除くと研究が 4 つに減り、区間も広がります。2 つの結果を並べて、除いても結論が変わらないかを見るために使い、どちらかを正しい結果として選ぶためには使いません。

適用可能性の懸念も同じ図や表に並べます。図 12.1 の演習では、10 研究の本文に対象の重症度や測定試薬の情報を設けていないので、適用可能性の懸念は載せていません。実際のレビューでは、適用可能性の列を加えます。例えば、ICU で術後の患者だけを対象にした研究は、バイアスのリスクが低くても、救急外来の発熱患者という問いには当てはまりにくいかもしれません。こうした研究が多いと、要約点がどの場面の精度を表しているのかがはっきりしなくなります。

12.9

発展 QUADAS-3 の変更点

2026 年 2 月に、QUADAS-2 の改訂版である QUADAS-3 が公表されました（Whiting 2026）。Cochrane DTA ハンドブック第 2 版（2023 年）と、これまでに発表されたレビューの大半は QUADAS-2 を使っているので、本書の演習は QUADAS-2 で行いました。これからレビューを始める人は、QUADAS-3 の原典を確認して、どちらを使うかをプロトコルに書いてください。

公表された論文によると、QUADAS-3 は次の 6 つの段階で評価を進めます。統合の問いを定める、その問いに対する理想的な検査精度試験を思い

描く、フロー図を描く、評価する精度の推定値を特定する、バイアスのリスクと適用可能性を評価する、全体の判定を下す、の順です。バイアスのリスクの領域は、参加者、対象検査、標的疾患、解析の 4 つで、最初の 3 つでは適用可能性も評価します。

QUADAS-2 からの主な変更点として、論文は次のものを挙げています。理想的な検査精度試験という考え方を取り入れ、それと比べて実際の研究がどうずれているかを見るようにしたこと、研究単位ではなく推定値単位で評価するようにしたこと、「フローとタイミング」の領域を新しい「解析」の領域に置き換えたこと、判定の理由を書く欄を設けたこと、全体の判定を正式に導入したことです。推定値単位の評価になったことで、1 本の研究が複数のカットオフや複数の対象集団の推定値を報告している場合に、それぞれを別に評価できます。

12.10 データを R に読み込む

抽出した 2×2 表は、1 研究 1 行の表にして CSV で保存します。R への読み込み方は 4.4 節（p. 40）と同じです。列は、研究名、場面、カットオフ、TP、FP、FN、TN とし、QUADAS-2 の判定も列（q_pat、q_idx、q_ref、q_flow）として加えておくと、14.5 節（p. 170）の感度分析にそのまま使えます。判定は「低」「不明」「高」の文字で入れ、例題の 10 研究は図 12.1 の判定を入れてあります。列の名前は TP、FP、FN、TN と大文字で付けておくと、第 13 章で使う mada パッケージが自動で読み取ります。

```
pct <- read.csv("data/pct_bact.csv",
                fileEncoding = "UTF-8")
names(pct)        # 列の名前を確かめる
nrow(pct)         # 研究の数（10）
```

```
[1] "study"   "setting" "cutoff"  "TP"      "FP"      "FN"      "TN"
```

```
 [8] "q_pat"   "q_idx"   "q_ref"   "q_flow"
[1] 10
```

読み込んだら、各研究の TP と FN の和（病気のある人の数）と、FP と TN の和（病気のない人の数）を計算し、論文の人数と一致するかを確かめます。例題では、Lopez 2011 の行で $35 + 27 = 62$ と $93 + 327 = 420$ になり、本文の人数と一致します。

12.11 この章のまとめ

本文から 2×2 表を作るときは、人数と割合から 4 つの数を復元し、感度と特異度を計算し直して論文の値に戻ることを確かめます。複数のカットオフ、判定不能、複数のエピソードの扱いは、データを見る前にプロトコルで決めます。QUADAS-2 では 4 つの領域ごとにバイアスのリスクと適用可能性を判定し、点数にして合計しません。測定法、検体の取り扱い、採血の時点は、検査技師の目で丁寧に記録します。検査の研究に特有のバイアスは表 12.1 で整理し、初めは上段の 4 つを押さえれば足ります。判定は研究を除くためではなく、感度分析と GRADE に使います。QUADAS-2 と、2026 年公表の改訂版 QUADAS-3 のどちらを使うかは、プロトコルに書きます。次の第 13 章では、読み込んだ 10 研究に二変量モデルを当てはめます。

第 13 章

R で二変量モデルを当てはめる

この章で分かること

架空の PCT の 10 研究を R に読み込み、研究ごとの感度と特異度を図で確かめます。カットオフ 0.5 ng/mL の 6 研究を取り出して、二項分布の二変量モデルを lme4 パッケージの glmer() で当てはめます。相関が境界に張り付いたら相関を 0 にしたモデルに単純化し、要約点と尤度比を出します。要約点と 2 つの領域の図の読み方を押さえ、全 10 研究には SROC 曲線だけを引きます。ROC 平面の描き方、十字プロット、reitsma() との比較、実データの AUDIT-C は、発展の印をつけて載せました。

13.1 データの準備と研究ごとの精度

12.10 節（p. 139）で作った CSV ファイルを読み込みます。read.csv() や library() の使い方は 5.5 節（p. 49）で説明しました。列は研究名、場面（救急外来か ICU か）、カットオフ（ng/mL）、そして 2×2 表の 4 つの数 TP、FP、FN、TN です。mada パッケージは、列名が TP、FP、FN、TN になっていれば、そのまま 2×2 表として読みます。

```
library(mada)    # 診断精度のメタ解析
library(lme4)    # 一般化線形混合モデル

pct <- read.csv("data/pct_bact.csv",
                fileEncoding = "UTF-8")
pct
```

最後の行で表を表示し、第 12 章の抽出結果と 1 行ずつ照合します。数を打ち間違えたまま解析しても、結果は正しくなりません。照合が済んだら、madad() で研究ごとの感度と特異度を計算します。correction.control = ”single” は、2×2 表に 0 のセルがある研究だけ 0.5 を足して計算する設定です。この例には 0 のセルがないので、補正は働きません。全 10 研究は 3,626 人で、菌血症の人は 556 人です。

```
d <- madad(pct, correction.control = "single")
print(d, digits = 2)
```

```
Diagnostic accuracies
      sens 2.5% 97.5% spec 2.5% 97.5%
 [1,] 0.62 0.48  0.75 0.80 0.76  0.84
 [2,] 0.56 0.44  0.68 0.78 0.74  0.82
 [3,] 0.79 0.64  0.89 0.75 0.67  0.81
  ...
[10,] 0.80 0.71  0.87 0.54 0.51  0.58
Test for equality of sensitivities:
X-squared = 30.514, df = 9, p-value = 0.00036
Test for equality of specificities:
X-squared = 154.9735, df = 9, p-value = <2e-16
```

行番号はデータの並び順で、1 行目が Kato 2010、10 行目が Tanaka 2023 です。感度は 0.56 から 0.88、特異度は 0.54 から 0.91 まで散らばっています。その下の 2 つの検定は「すべての研究で感度（特異度）が等しい」という仮説の検定で、どちらも強く否定されています。この検定は出力に出ますが、判断には使いません。Cochrane DTA ハンドブックは、感度と特異度それぞれの等しさの検定を推奨していません（10.7 節（p. 115）、

Macaskill 2023）。研究間で精度がばらつくことは、次に描く図で見えます。

出力の最後には、感度と偽陽性割合の研究単位の相関（0.32）も表示されます。研究を点として並べただけの素朴な値なので、研究ごとの標本の大きさの違いを考慮していません。相関はあとで二変量モデルが推定し直します。

対のフォレストプロット

感度と特異度を左右に並べたフォレストプロットを図 13.1 に示します。研究はカットオフの低い順に並べました。カットオフが 0.25 ng/mL の 2 研究（Nguyen 2014、Tanaka 2023）は感度が高く特異度が低く、カットオフが 1 ng/mL の Sato 2021 は特異度が 0.91 と最も高くなっています。介入のメタ解析と違い、この図の下に統合値の菱形を置くことはしません。感度と特異度を別々に統合すると、2 つの値の関係が失われるからです（→ 10.2 節（p. 109））。

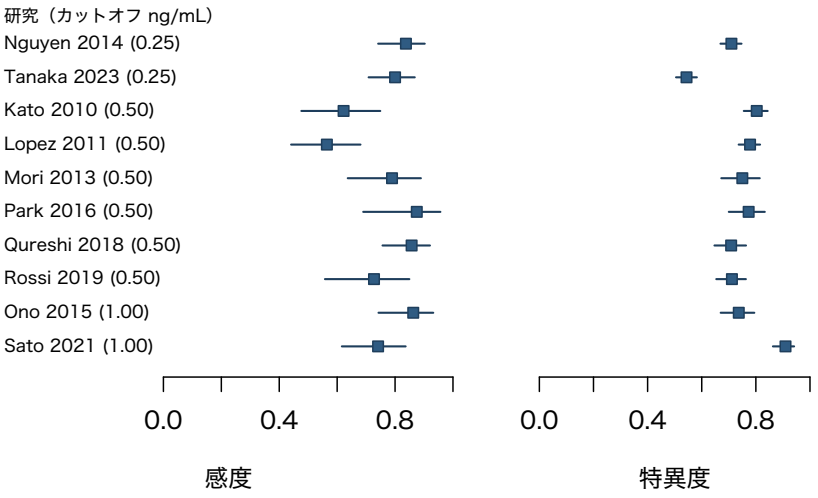


図 13.1　研究ごとの感度と特異度（架空の PCT データ）。括弧内はカットオフ（ng/mL）、横線は 95% 信頼区間

mada の forest() に madad() の結果を渡すと、感度と特異度のフォレストプロットがそれぞれ描けます。

```
forest(d, type = "sens")   # 感度のフォレストプロット
forest(d, type = "spec")   # 特異度のフォレストプロット
```

上の 2 行で描くと、感度と特異度は別々の図になります。図 13.1 は、この 2 つを左右に並べ、研究名とカットオフを左に添えて描いたものです。

横軸は感度（左）または特異度（右）で、0 から 1 の範囲です。四角が研究ごとの推定値、横線が 95% 信頼区間です。人数の少ない研究ほど線が長くなります。左の感度の列では、病気のある人が 24 人の Park 2016 は 0.88（0.69〜0.96）と線が長く、95 人の Tanaka 2023 は 0.80（0.71〜0.87）と短くなっています。右の特異度の列では、 Tanaka 2023 の 0.54（0.51〜0.58）から Sato 2021 の 0.91（0.86〜0.94）まで開いていて、この 2 研究の区間は重なっていません。区間が重ならない研究の組があるのは、偶然のばらつきだけでは説明しにくい違いが研究の間にあることを示唆します。

発展 ROC 平面に研究を置く

次に、各研究を ROC 平面に 1 つの点として置きます（図 13.2）。横軸は偽陽性割合（1 − 特異度）、縦軸は感度です。点の大きさは研究の人数に比例させ、色はカットオフで分けました。左上に寄るほど精度の高い検査で、対角線上の点は当て推量と変わりません。

感度は TP ÷（TP + FN）、偽陽性割合は FP ÷（FP + TN）で計算できます。

```
fpr_i <- pct$FP / (pct$FP + pct$TN)   # 偽陽性割合
sen_i <- pct$TP / (pct$TP + pct$FN)   # 感度
n <- with(pct, TP + FP + FN + TN)     # 研究の人数
pal <- c("#8FB0CE", "#2F5B82", "#14283C")
plot(NA, xlim = c(0, 1), ylim = c(0, 1),
     xlab = "1 − 特異度（偽陽性割合）", ylab = "感度")
abline(0, 1, lty = 3)                 # 当て推量の対角線
```

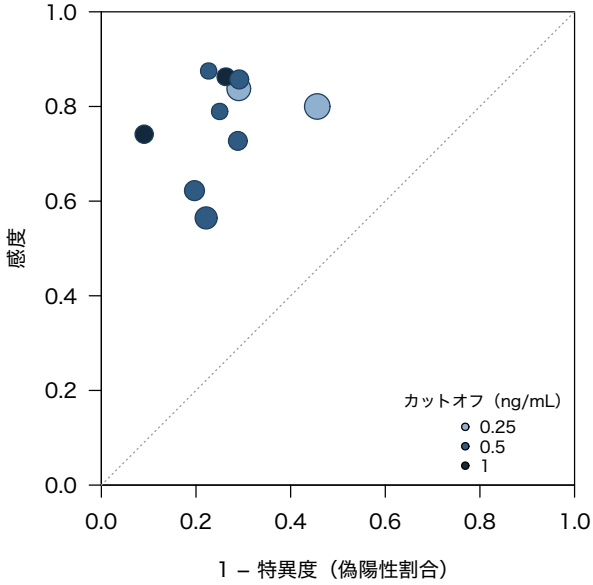


図 13.2　ROC 平面上の 10 研究。色が濃いほどカットオフが高い

```
points(fpr_i, sen_i, pch = 21,
       cex = 0.8 + 2 * sqrt(n / max(n)),
       bg = pal[match(pct$cutoff, c(0.25, 0.5, 1))])
```

最後の bg の指定で、カットオフの値を 3 色のどれかに対応させています。

カットオフ 0.25 ng/mL の 2 研究（薄い点）は偽陽性割合が 0.29 と 0.46 で右寄りにあり、カットオフ 1 ng/mL の Sato 2021（濃い点）は偽陽性割合 0.09 で左端にあります。カットオフを下げると陽性と判定する人が増え、感度と偽陽性割合が一緒に上がるためで、これが閾値効果です（→ 10.1 節（p. 107））。ただし点の散らばりはカットオフだけでは説明しきれません。同じ 1 ng/mL の Ono 2015 は偽陽性割合が 0.26 で 0.5 ng/mL の研究と同じあたりにあり、0.5 ng/mL の 6 研究だけでも感度は 0.56 から 0.88 まで開いています。

発展 十字プロット

図 13.2 の点には、信頼区間がありません。研究ごとの不確かさを同じ平面に描き加えたものが、図 13.3 の十字プロットです。mada の crosshair() で描けます。

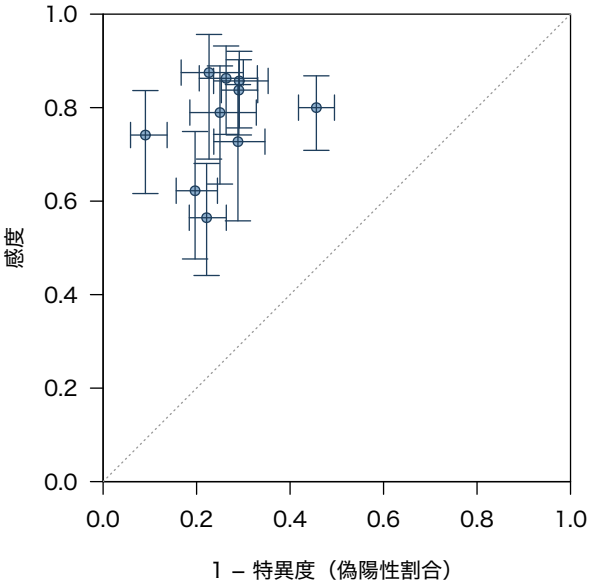


図 13.3　十字プロット。各研究の感度と偽陽性割合を点で示し、縦線が感度、横線が偽陽性割合の 95% 信頼区間

```
crosshair(pct, xlim = c(0, 1), ylim = c(0, 1))
abline(0, 1, lty = 3)
```

軸は図 13.2 と同じで、十字の中心が 1 つの研究の推定値です。縦線の長さが感度の不確かさ、横線の長さが偽陽性割合の不確かさを表します。人数の少ない研究は十字が大きくなります。図 13.2 では点の大きさで人数を表しましたが、十字プロットでは線の長さで不確かさそのものを見せます。

線が表すのは研究の中の不確かさ（標本の大きさによる偶然のばらつき）で、研究どうしの違いではありません。研究間のばらつきは、十字の中心がどれだけ散らばっているかで見ます。この例では、10 研究のうち 9 研究の偽陽性割合が 0.09 から 0.29 の間に入る一方、偽陽性割合が約 0.46 の Tanaka 2023 は、短い線のまま右端に離れています。また、十字の線が重なっていても、研究どうしに違いがないとは言えません。感度と偽陽性割合の両方の線が重なる組は多くありますが、先に見た等しさの検定は、感度も特異度も研究間で等しくないことを示していました。

13.2 カットオフ 0.5 ng/mL の 6 研究を取り出す

10 研究のカットオフは、0.25 ng/mL が 2 研究（Nguyen 2014、Tanaka 2023）、0.5 ng/mL が 6 研究（Kato 2010、Lopez 2011、Mori 2013、Park 2016、Qureshi 2018、Rossi 2019）、1 ng/mL が 2 研究（Ono 2015、Sato 2021）です。カットオフが混ざった研究から要約の感度と特異度を出すことは、どのカットオフの値でもなく臨床で解釈できないので避けます（10.6 節（p. 114）、Macaskill 2023、9.3.1）。要約点は、研究がもっとも多いカットオフ 0.5 ng/mL の 6 研究だけから出します。

```
pct5 <- subset(pct, cutoff == 0.5)
nrow(pct5)                                  # 6 研究
sum(with(pct5, TP + FP + FN + TN))          # 1782 人
sum(pct5$TP + pct5$FN)                      # 菌血症 272 人
```

元の pct は残したままで、全 10 研究は後で SROC 曲線とカットオフを共変量にした解析（14.2 節（p. 163））に使います。カットオフ 0.25 と 1 ng/mL は 2 研究ずつなので、それぞれの要約点は出しません。

13.3 glmer() で二変量モデルを当てはめる

二変量モデルは、logit 感度と logit 特異度の組が研究ごとに 2 次元の正規分布からばらつく、と考えるモデルです。logit は 10.3 節（p. 110）、二変量モデルの考え方は 10.4 節（p. 111）、研究ごとのずれをランダム効果で表す考え方は 5.4 節（p. 46）で説明しました。研究内のばらつきは二項分布のまま扱います（Chu 2006）。この方法は 0 のセルがある研究でも補正なしに扱え、Cochrane の DTA ハンドブック第 10 章も、R では lme4 パッケージの glmer() で当てはめる例を示しています。glmer() は一般化線形混合モデル（研究内は二項分布、研究間は正規分布という 2 段のモデル）を当てはめる関数です。

感度は病気のある人から、特異度は病気のない人から計算する別々のデータです。1 つの式で両方を扱うために、1 研究を「感度の行」と「特異度の行」の 2 行に分けた縦長のデータを作ります。to_long() がこの縦長のデータを作る関数です。sens の行では y が真陽性の数、n が疾患ありの人数、spec の行では y が真陰性の数、n が疾患なしの人数になります。

```
to_long <- function(d) rbind(
  data.frame(study = d$study, sens = 1, spec = 0,
             y = d$TP, n = d$TP + d$FN),
  data.frame(study = d$study, sens = 0, spec = 1,
             y = d$TN, n = d$TN + d$FP))
long5 <- to_long(pct5)
g2 <- glmer(cbind(y, n - y) ~ 0 + sens + spec +
              (0 + sens + spec | study),
            data = long5, family = binomial)
summary(g2)
```

式を部品に分けると、表 13.1 のとおりです。初めは式を写して実行できれば十分で、意味は結果を読んだあとで戻って確かめれば足ります。

部品	意味
cbind(y, n − y)	正しく判定された人数 y と、誤って判定された人数 n − y の組。sens の行は真陽性と偽陰性、spec の行は真陰性と偽陽性
~	左が説明される結果、右がそれを説明する項
0 + sens + spec	切片を置かず、logit 感度と logit 特異度を別々の平均として推定する
(0 + sens + spec | study)	研究ごとのずれを、感度と特異度の両方について推定する。2 つのずれの相関も推定する
family = binomial	人数を二項分布で扱う

表 13.1　glmer() の式の部品

実行すると、glmer() の時点で boundary (singular) fit という警告が出て、summary() の末尾にも同じ表示が出ます。エラーではなく、推定が止まったわけでもありません。相関や標準偏差が、取りうる範囲の端（相関なら − 1 か 1、標準偏差なら 0）に張り付いた、という知らせです。

出力で見る場所は 2 つです。Random effects の Std.Dev. と Corr は、logit の尺度での研究間の標準偏差と、感度と特異度のずれの相関です。Variance は Std.Dev. を 2 乗した値で、同じ情報の別の表し方です。Fixed effects の Estimate は、logit 感度（sens）と logit 特異度（spec）の平均です。

```
Random effects:
 Groups Name Variance Std.Dev. Corr
 study  sens 0.25253  0.5025
        spec 0.01978  0.1407   -1.00
Fixed effects:
     Estimate Std. Error z value
sens  1.06422    0.25174   4.228
spec  1.11447    0.08379  13.301
boundary (singular) fit: see help('isSingular')
```

Corr の欄で、感度と特異度の相関が − 1.00 になっています。相関は − 1 から 1 までしかとれないので、これ以上は動けない端に張り付いた状態です。研究が 6 本と少なく、2 つのばらつきと相関を同時に決めるだけの情報が足りないときに、このような推定になります。端に張り付いた推定

では、標準誤差と信頼区間の計算が不安定になり、要約点の値も不安定になります。この結果から出した感度 0.743 と特異度 0.753 は、参考にとどめ、報告には使いません。

13.4 相関を 0 にしたモデルに単純化する

Cochrane の DTA ハンドブックは、二変量モデルが収束しない、相関が ±1 に張り付く、分散が 0 になるといったときは、モデルを単純化するよう勧めています（Macaskill 2023、9.4.8、Takwoingi 2023、10.6.2）。単純化するかどうかは、研究の本数ではなく推定の様子で決めます。典型的な単純化が、感度と特異度の相関を 0 にするモデルです（相関の意味は 10.4 節 (p. 111) で説明しました）。式の上では、2 つのランダム効果を別々の括弧に分けます。

```
g <- glmer(cbind(y, n - y) ~ 0 + sens + spec +
             (0 + sens | study) + (0 + spec | study),
           data = long5, family = binomial)
summary(g)
```

「(0 + sens | study) + (0 + spec | study)」は、感度と特異度が研究ごとに別々にばらつき、その間の相関は考えないという式です。今度は singular の警告は出ません。

```
Random effects:
 Groups  Name Variance Std.Dev.
 study   sens 0.26801  0.5177
 study.1 spec 0.01841  0.1357
Fixed effects:
     Estimate Std. Error z value
sens   1.0773     0.2615    4.12
spec   1.1353     0.0832   13.64
```

研究間の標準偏差は、logit 感度が 0.518、logit 特異度が 0.136 です。感度は研究によって大きくばらつき、特異度はあまりばらつきません。6 研究では、相関を推定するだけの情報がありません。相関を 0 と置くのは、感度と特異度の研究ごとのずれを別々に推定するという簡単化で、要約点への影響は小さいことが多いとされます（ハンドブック 10.6.2、Takwoingi 2023）。代わりに、相関を使って精度を高める利点は失い、感度と特異度が一緒に動く関係は要約点の不確かさに入りません。この制約は報告に書きます。以降の要約点は、このモデルのものを使います。

> 発展 glmer() は、ランダム効果が 2 つ以上あると、数値積分の点（求積点）を増やせず、ラプラス近似で推定します（Macaskill 2023、10.2.3）。研究が少ないときの推定が不安定になりやすい一因です。

R を使わない場合

R を使わずに二変量モデルを当てはめたいときは、無料の Web ツール MetaDTA が使えます。MetaDTA は内部で glmer() を使っていて、2×2 表の CSV ファイルを読み込ませれば要約点と SROC 曲線が出ます。

13.5 要約点と尤度比

推定値を逆 logit で戻して、要約点とその 95% 信頼区間を出します。信頼区間は logit の尺度で正規近似し、戻します。

```
b <- fixef(g)
V <- as.matrix(vcov(g))
se_b <- sqrt(diag(V))
plogis(cbind(est = b, lower = b - 1.96 * se_b,
             upper = b + 1.96 * se_b))
```

```
           est     lower     upper
sens 0.7459900 0.6375786 0.8305890
```

```
spec 0.7568185 0.7255653 0.7855644
```

カットオフ 0.5 ng/mL の PCT の、要約の感度は 0.746（95% 信頼区間 0.638〜0.831）、特異度は 0.757（0.726〜0.786）です。特異度の区間が狭いのは、特異度のばらつきが小さく、疾患のない人の数も多いからです。

R のメモ

logit は、割合 p を log(p / (1 − p)) に変える変換です。0 から 1 の値を、負の無限大から正の無限大までの値に広げます。R では qlogis() で logit に、plogis() で元の割合に戻せます。たとえば plogis(1.0773) は 0.746 になり、上の出力の感度と一致します。詳しくは 10.3 節（p. 110）を読み直してください。

要約点から、陽性尤度比、陰性尤度比、診断オッズ比を計算します（→ 9.4 節（p. 98））。

```
se <- unname(plogis(b["sens"]))
sp <- unname(plogis(b["spec"]))
c(LRpos = se / (1 - sp), LRneg = (1 - se) / sp,
  DOR = (se / (1 - se)) / ((1 - sp) / sp))
```

```
    LRpos     LRneg       DOR
3.0676260 0.3356287 9.1399395
```

陽性尤度比は 3.07、陰性尤度比は 0.34、診断オッズ比は 9.1 でした。陽性尤度比 3.07 は、PCT が陽性の人が菌血症である見込み（オッズ）が、検査前の 3.07 倍になるという意味です。陰性尤度比 0.34 は、陰性なら見込みが 3 分の 1 ほどになるという意味です。どちらも、検査の結果だけで菌血症を確定したり否定したりできる大きさではありません（15.1 節（p. 177）で 1000 人あたりの数にします）。

尤度比を研究ごとに計算して別々に統合する方法は勧められていません。統合した陽性尤度比と陰性尤度比の組が、ありえない感度と特異度の組に対応してしまうことがあるからです（Zwinderman 2008、Macaskill 2023、9.3.1）。要約点から計算する、という順序を守ります。要約の尤度比の信頼

区間は、この冊子では計算しません。

13.6
要約点と 2 つの領域を図にする

要約点と、その不確かさを表す領域を図 13.4 に示します。赤い菱形が要約点（感度 0.746、偽陽性割合 0.243）、濃い楕円が 95% 信頼領域、淡い大きな楕円が 95% 予測領域、丸がカットオフ 0.5 ng/mL の 6 研究です。

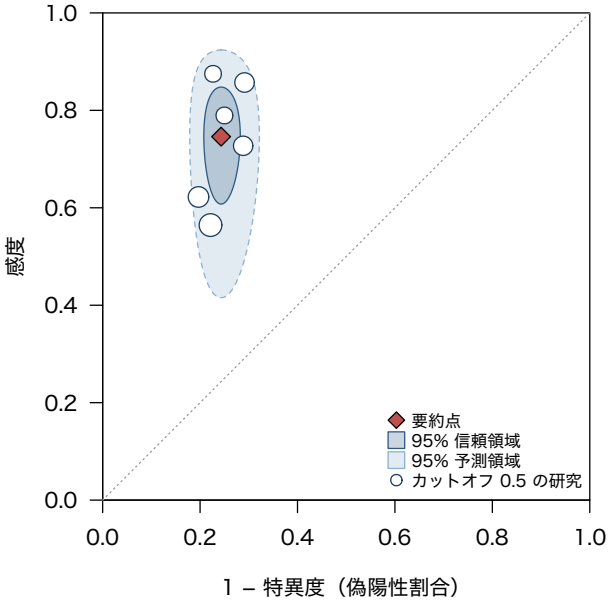


図 13.4　カットオフ 0.5 ng/mL の 6 研究の要約点、95% 信頼領域、95% 予測領域

信頼領域は、要約点（感度と特異度の平均）がどこにあるかの不確かさを表します。研究を増やせば小さくなります。予測領域は、これから新しく行う研究の感度と特異度がどのあたりに来そうかを表し、研究間のばら

つきそのものを含むので、研究を増やしても小さくなりません。介入のメタ解析の信頼区間と予測区間の関係（6.3 節（p. 62））を 2 次元にしたものです。

図 13.4 の信頼領域は小さく、感度の方向にやや長い形です。予測領域は縦に細長く、感度の方向に広く、偽陽性割合の方向には狭くなっています。感度の研究間標準偏差が 0.518、特異度が 0.136 と、感度のほうがはるかにばらつくためです。ある病院で PCT をカットオフ 0.5 ng/mL で導入したとき、その病院の特異度は要約点の近くに収まりそうですが、感度は要約点から大きく外れてもおかしくない、という意味です。要約点だけを報告すると、この広がりが読み手に伝わりません。

予測領域は、研究間の分布が 2 次元の正規分布に従うという仮定に頼っています。研究数が少ないと、領域は実際より広くも狭くも出ます（10.7 節（p. 115）、Macaskill 2023、9.3.2）。6 研究の図 13.4 は、形と大きさを目安として読みます。

発展 図 13.4 を描くコード

楕円は、logit の尺度で要約点のまわりに作り、ROC 平面に戻して描きます。信頼領域は要約点の推定値の分散から、予測領域は研究間のばらつきを足した分散から作ります。ellipse_roc() は、楕円の点を計算する関数です。中身は読まなくてかまいません。

```
ellipse_roc <- function(mu, S, n = 200) {
  r <- sqrt(qchisq(0.95, 2))
  th <- seq(0, 2 * pi, length.out = n)
  e <- t(mu + r * t(chol(S)) %*% rbind(cos(th), sin(th)))
  data.frame(fpr = plogis(e[, 2]), sens = plogis(e[, 1]))
}
```

この関数を使って、要約点と 2 つの領域を描きます。

```
vc <- VarCorr(g)
S_btw <- diag(c(attr(vc[[1]], "stddev")^2,
```

```
                attr(vc[[2]], "stddev")^2))
mu <- c(b["sens"], -b["spec"])  # logit 感度、logit 偽陽性割合
V_m <- matrix(c(V[1, 1], -V[1, 2], -V[1, 2], V[2, 2]), 2)
conf <- ellipse_roc(mu, V_m)            # 信頼領域
pred <- ellipse_roc(mu, S_btw + V_m)    # 予測領域
plot(NA, xlim = c(0, 1), ylim = c(0, 1),
     xlab = "1 − 特異度（偽陽性割合）", ylab = "感度")
abline(0, 1, lty = 3)
polygon(pred$fpr, pred$sens, border = "grey50", lty = 2)
polygon(conf$fpr, conf$sens)
points(fpr(pct5), sens(pct5), pch = 21)
points(1 - sp, se, pch = 23, bg = "red")
```

13.7 発展 mada の reitsma() との比較

同じ 6 研究を mada の reitsma() で解析することもできます。研究内を正規近似する方法で、参考として示します。

```
summary(reitsma(pct5))
```

```
sensitivity          0.737  0.624  0.826
false pos. rate      0.248  0.217  0.282
Variance components:
      Std. Dev tsens  tfpr
tsens    0.543 1.000     .
tfpr     0.159 1.000 1.000
```

要約の感度は 0.737（0.624〜0.826）、偽陽性割合は 0.248（0.217〜0.282）で、glmer() の結果とほとんど変わりません。一方、研究間の相関の行は 1.000 で、境界に張り付いたことは reitsma() でも同じです（偽陽性割合で表すので、符号は glmer() と逆になります）。reitsma() は相関を 0 に固定する指定ができないので、単純化したモデルは glmer() で当てはめます。

Cochrane の DTA ハンドブック第 10 章は、研究内のばらつきに二項分布を使うことを勧め、正規近似の mada は Cochrane レビューには推奨しないとしています（Takwoingi 2023、10.2.3）。理由として、疾患ありと疾患なしの人数が十分に多いという近似の前提が崩れると推定が偏ることと、0 のセルに補正を足す必要があることを挙げています。二変量モデルの 2 つの階と、研究内の扱い方の違いは発展の 10.4.1 節（p. 111）で説明しました。本書でも glmer() を主解析とし、reitsma() は SROC 曲線を引くときや、結果を確かめるときに使います。

13.8 全 10 研究の SROC 曲線

カットオフが混ざった全 10 研究には、SROC 曲線だけを引きます（→ 10.6 節（p. 114））。mada の reitsma() は、研究内を正規近似する二変量モデルを当てはめる関数です。reitsma() で全 10 研究にモデルを当てはめ、sroc() で曲線の座標を取り出して描きます。

```
fit_all <- reitsma(pct)
plot(NA, xlim = c(0, 1), ylim = c(0, 1),
     xlab = "1 − 特異度（偽陽性割合）", ylab = "感度")
abline(0, 1, lty = 3)
lines(sroc(fit_all), lwd = 2)       # 曲線だけを描く
points(fpr(pct), sens(pct), pch = 21)
```

summary(fit_all) の出力には要約点（感度と偽陽性割合）も表示されますが、カットオフが混ざっているので使いません。曲線だけを使います。

図 13.5 の曲線は、カットオフを動かしたときに感度と偽陽性割合がどう入れ替わるかの平均的な関係を表します。点は研究ごとの感度と偽陽性割合で、曲線のまわりに散らばっています。

曲線は左下から右上まで引かれていますが、データがあるのは偽陽性割

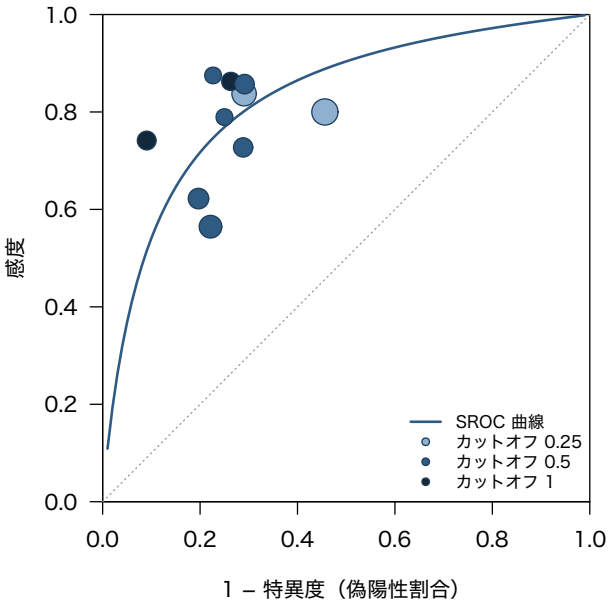


図 13.5　全 10 研究の SROC 曲線。要約点は描かない。点の色はカットオフ

合がおよそ 0.09 から 0.46 の範囲だけです。その外側の曲線は、モデルの形をそのまま延ばした線にすぎません。たとえば「偽陽性割合 0.05 なら感度はいくつか」を曲線から読むと、データのない場所の値を読むことになります。曲線は観測された点の範囲の中だけで読みます。

summary(fit_all) の末尾には AUC（0.824）も表示されます。AUC は SROC 曲線の下の面積で、参考値として扱います。観測された点の範囲の外に延ばした曲線の部分も面積に入るため、データが支えていない領域の値を含み、特定のカットオフでの感度と特異度も表さないからです。mada は観測された偽陽性割合の範囲に限った部分 AUC（0.755）も出します。報告には、曲線そのものと、要約点を出せる場合はその点を示します。

13.9

発展 実データの AUDIT-C で再現する

mada パッケージには、AUDIT-C（飲酒の問題を見つけるための 3 問の質問票）の 14 研究のデータが AuditC として入っています（Kriston 2008）。このデータは研究ごとの 2×2 表だけを持ち、カットオフの情報は含みません。二変量モデルの手順を実データでたどる例として、14 研究をそのまま統合します。

```
data("AuditC")
ac <- as.data.frame(AuditC)
ac$study <- seq_len(nrow(ac))
ga <- glmer(cbind(y, n - y) ~ 0 + sens + spec +
              (0 + sens + spec | study),
            data = to_long(ac), family = binomial)
summary(ga)
plogis(fixef(ga))
```

14 研究では、相関が境界に張り付くことなく推定でき、singular の警告も出ません。

```
Random effects:
 Groups Name Variance Std.Dev. Corr
 study  sens 2.5959   1.6112
        spec 0.3812   0.6174   -0.82
```

感度と特異度の相関は − 0.82 で、閾値効果の向きに強く負です。要約の感度は 0.925（95% 信頼区間 0.834〜0.968）、特異度は 0.782（0.720〜0.833）でした。感度と特異度を別々に統合すると感度 0.930、特異度 0.783 になり、点推定はほとんど変わりません。二変量モデルの利点は、この相関を推定して信頼領域や SROC 曲線に反映できる点にあります。

同じデータを reitsma() で解析すると、感度は 0.891（0.808〜0.941）、偽

陽性割合は 0.220（0.167〜0.285）、AUC は 0.887 でした。図 13.6 に SROC 曲線と信頼領域を示します。

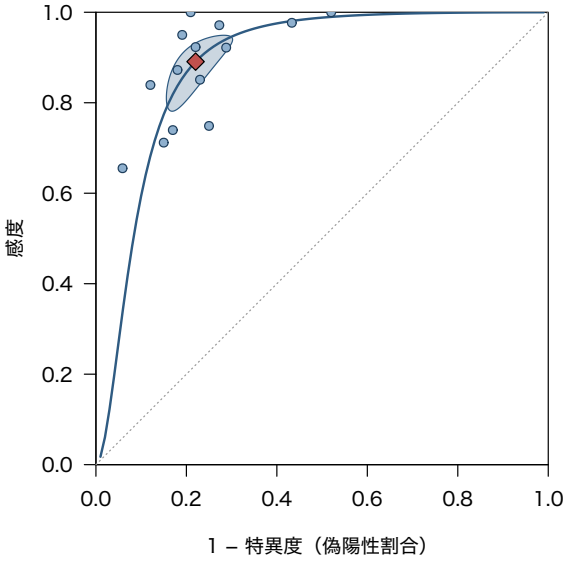


図 13.6　AUDIT-C の 14 研究の SROC 曲線と 95% 信頼領域

```
fa <- reitsma(AuditC)
plot(fa, extrapolate = TRUE)
points(fpr(AuditC), sens(AuditC))   # 14 研究の点
```

図の読み方は PCT の図 13.4 と同じです。要約点が感度 0.89、偽陽性割合 0.22 の位置にあり、研究の点は感度の方向に広く散らばっています。95% 信頼領域は小さく見えますが、予測領域を描いていないので、新しい研究の値がどこに来るかは、この図からは分かりません。

このデータには感度が 1.00 に近い研究があり、2×2 表に 0 のセルが 2 つあります。reitsma() は 0 のセルに 0.5 を足して計算しました。glmer() の感度は reitsma() より 0.03 ほど高くなっています。0.5 を足す補正が、感度が 1 に近い研究の値を引き下げたためと考えられます。PCT の 6 研究

で両者が近く、AUDIT-C で食い違ったのは、0 のセルがあり感度が 1 に近いという、近似の前提が崩れる条件に AUDIT-C が当たるためと考えられます。

13.10 この章のまとめ

検査のメタ解析では、研究ごとの感度と特異度を表と図で確かめてから、要約点を出す研究の範囲を決めます。例題では、カットオフが混ざった全 10 研究から要約点を出さず、共通のカットオフ 0.5 ng/mL の 6 研究から二項分布の二変量モデルで要約点を推定しました。glmer() の式は、写して実行できれば初めは十分です。見る場所は、Random effects の Std.Dev. と Corr、Fixed effects の Estimate です。相関が -1 の境界に張り付いたので、相関を 0 にしたモデルに単純化し、要約の感度 0.746、特異度 0.757、陽性尤度比 3.07、陰性尤度比 0.34 を得ました。全 10 研究には SROC 曲線だけを引き、観測範囲の中で読みます。予測領域は感度の方向に広く、研究数が少ないので目安にとどめます。第 14 章（p. 161）では、全 10 研究にカットオフを共変量として入れ、ばらつきの原因を探します。

第 14 章

ばらつきの原因を探す

この章で分かること

13.5 節（p. 151）で出した主解析は、カットオフ 0.5 ng/mL の 6 研究から感度 0.746、特異度 0.757 の要約点を出しました。それでも感度は研究によって 0.56 から 0.88 まで開いています。ばらつきの原因の候補を挙げたうえで、全 10 研究にカットオフを共変量として入れて調べ、バイアスのリスクが高い研究を除いた感度分析も行います。場面をカットオフで調整して比べる解析、検査どうしの比較、同じ PCT を扱った 2 本のメタ解析（Tang 2007、Wacker 2013）の読み比べは、発展の印をつけて載せました。

14.1 ばらつきの原因の候補

診断精度の研究が互いに違う結果を出す理由は、2×2 表の作られ方をさかのぼると整理できます。誰を対象にしたか、検査をどう測ったか、正解（参照基準）をどう決めたか、の 3 つです。

対象　救急外来の発熱患者と ICU の重症患者では、菌血症の人も菌血症で

ない人も、病態が違います。ICU には菌血症でなくても手術や外傷で炎症の強い患者が多く、PCT が上がる理由が菌血症以外にもあります。重症度、年齢、腎機能、併存疾患も研究ごとに違います。

対象検査　測定試薬と機器、検体の種類（血清か血漿か）、採血の時点、カットオフが研究ごとに違います。

参照基準　血液培養を何セット採ったか、汚染菌と判断した陽性をどう扱ったか、抗菌薬投与後の培養を含めたかで、「菌血症あり」の人が入れ替わります。

対象検査の違いには、検査技師が最も具体的に気づける点があります。PCT の測定試薬は複数あり、同じ検体を測っても試薬によって値がそろわないことがあります。その場合、論文に同じ「0.5 ng/mL」と書かれていても、指している濃度が研究ごとに少しずつ違います。分析性能（測定値の精度や正確さ）の差が、臨床的な診断精度（感度と特異度）の差として現れることがあります（→ 9.6 節（p. 104））。

測定試薬の違いを共変量にした例は、Cochrane の DTA ハンドブックにもあります。関節リウマチの診断に使う抗 CCP 抗体の測定試薬の世代の違いで、感度と特異度が違うかを二変量モデルで調べています（第 9 章と第 10 章）。

採血の時点も、診断精度に関わります。PCT は細菌感染が始まってから数時間かけて上昇するので、発熱した直後に採った検体では、菌血症の人でもまだ値が低いことがあります。来院時の 1 回だけを測った研究と、24 時間以内の最高値を使った研究では、感度が違うと予想されます。

挙げた候補は、データを見てから探すものではありません。2.5 節（p. 25）で述べたとおり、どの特徴でばらつきを調べるかはプロトコルの段階で決め、データ抽出の表にその列を用意しておきます。データを見てから都合のよい共変量を探すと、偶然の差を原因と取り違えます。

14.2
カットオフを共変量にする

二変量モデルに共変量を入れると、共変量の値ごとに要約点が動くモデルになります。介入のメタ解析のメタ回帰（短い説明は 6.4 節（p. 64)、係数の読み方は発展の 6.5 節（p. 67)）に当たる方法で、検査では感度と偽陽性割合の 2 つの値が同時に動きます。mada の reitsma() では、formula 引数に共変量を書きます。左辺の cbind(tsens, tfpr) は「logit 感度と logit 偽陽性割合の両方」を意味する決まった書き方です。

カットオフは連続した値なので、対数をとって共変量にします（→ 5.1.2 節（p. 43))。0.25、0.5、1 ng/mL は、対数をとると等間隔になります（底を 2 にすると − 2、− 1、0。R の log() は自然対数で、− 1.39、− 0.69、0)。つまり、カットオフを 2 倍にするごとに同じだけ効果が動く、と置いたことになります。図 14.1 の横軸で 3 つのカットオフが等間隔に並ぶのは、このためです。この解析にはカットオフの混ざった全 10 研究を使います。目的は、カットオフを動かしたときに感度と偽陽性割合がどう動くかを調べることで、10 研究から 1 つの要約点を出すことではありません。カットオフの混ざった研究から要約の感度と特異度を出すことは、臨床で解釈できず、他の場面にも一般化できないとして、Cochrane の DTA ハンドブックが避けるよう求めています（Macaskill 2023)。

```
pct$lcut <- log(pct$cutoff)
fit_cut <- reitsma(pct,
  formula = cbind(tsens, tfpr) ~ lcut)
summary(fit_cut)
```

```
                 Estimate Std. Error      z Pr(>|z|)
tsens.(Intercept)    1.174      0.366  3.210    0.001
tsens.lcut          -0.064      0.434 -0.147    0.883
tfpr.(Intercept)    -1.639      0.237 -6.925    0.000
tfpr.lcut           -0.774      0.280 -2.770    0.006
```

tsens の行が logit 感度、tfpr の行が logit 偽陽性割合です。偽陽性割合（1 − 特異度）を使うのは、ROC 平面の横軸に合わせる mada の決まりです。切片は log(カットオフ) が 0 のとき、つまり基準にしたカットオフ 1 ng/mL のときの logit 値です。lcut の行は、log(カットオフ) に掛かる係数です。

tfpr の lcut の係数 -0.774 は、カットオフが 2 倍になると logit 偽陽性割合が $-0.774 \times \log(2) \approx -0.54$ 動く、という意味です。$p = 0.006$ で、カットオフを上げると偽陽性割合が下がることがはっきり示されました。logit 感度の係数は -0.064 でほぼ 0 に近く、$p = 0.88$ です。このデータでは、カットオフを動かして動くのは主に偽陽性割合のほうでした。

係数から、カットオフごとの感度と特異度を計算します。観察されたカットオフは 0.25、0.5、1 ng/mL の 3 通りなので、その範囲だけを求めます。

```
cf <- coef(fit_cut)      # 係数の表（行は切片と lcut）
lc <- log(c(0.25, 0.5, 1))
sens <- plogis(cf["(Intercept)", "tsens"] +
               cf["lcut", "tsens"] * lc)
spec <- 1 - plogis(cf["(Intercept)", "tfpr"] +
                   cf["lcut", "tfpr"] * lc)
round(data.frame(cutoff = c(0.25, 0.5, 1), sens, spec), 2)
```

```
  cutoff sens spec
1   0.25 0.78 0.64
2   0.50 0.77 0.75
3   1.00 0.76 0.84
```

カットオフを 0.25 から 1 に上げると、特異度は 0.64 から 0.84 まで上がり、感度は 0.78 から 0.76 へとほとんど動きません。閾値効果として予想される向きですが、感度の変化は小さく、偶然のばらつきと区別できません。この当てはめを図にしたものが図 14.1 です。

```
cx <- seq(log(0.2), log(1.3), length.out = 100)
n  <- with(pct, TP + FP + FN + TN)
```

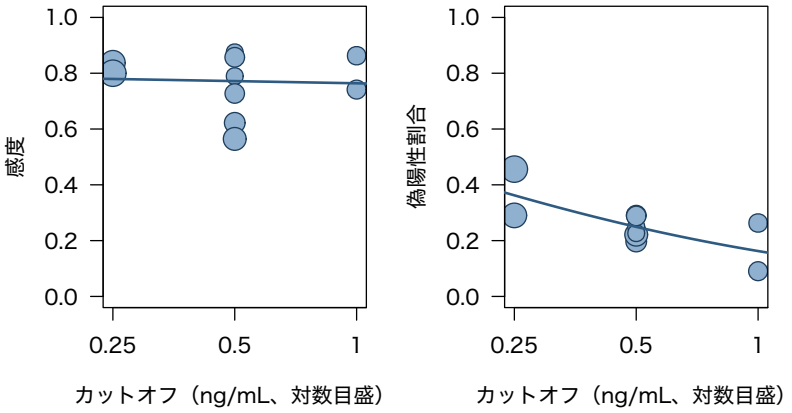


図 14.1　カットオフと感度（左）、偽陽性割合（右）。円の大きさは研究の人数、線は log(カットオフ) を共変量にした二変量モデルの当てはめ

```
par(mfrow = c(1, 2))

plot(pct$cutoff, pct$TP / (pct$TP + pct$FN), log = "x",
     ylim = c(0, 1), pch = 21, cex = 0.8 + 2 * sqrt(n / max(n)),
     xlab = "カットオフ（ng/mL、対数目盛）", ylab = "感度")
lines(exp(cx), plogis(cf["(Intercept)", "tsens"] +
                      cf["lcut", "tsens"] * cx))

plot(pct$cutoff, pct$FP / (pct$FP + pct$TN), log = "x",
     ylim = c(0, 1), pch = 21, cex = 0.8 + 2 * sqrt(n / max(n)),
     xlab = "カットオフ（ng/mL、対数目盛）", ylab = "偽陽性割合")
lines(exp(cx), plogis(cf["(Intercept)", "tfpr"] +
                      cf["lcut", "tfpr"] * cx))
```

線の式は、logit 感度 = 切片 + 係数 × log(カットオフ) です。cx は log(カットオフ) の値の並びで、plogis() で割合に戻してから、exp(cx) をカットオフの位置として線を引いています。

横軸は対数目盛のカットオフで、0.25、0.5、1 ng/mL が等間隔に並びます。右の偽陽性割合は、カットオフを上げるにつれて線が下がり、点の並

びと合っています。左の感度の線はほぼ水平です。0.5 ng/mL の 6 研究だけでも感度は 0.56 から 0.88 まで開いていて、カットオフでは説明できない研究間の差が残ることが分かります。線は研究間のばらつきを含めた二変量モデルから出したもので、点の単純な回帰線ではありません。

場面で精度が違うかを見たいときは、まずカットオフをそろえた研究どうしで比べます。カットオフが場面と結びついていると、場面の差とカットオフの差が区別できないからです。この例で場面とカットオフを同時にモデルに入れる解析は、次の節に発展として載せました。

14.3 発展 場面をカットオフで調整して比べる

救急外来の研究と ICU の研究では、対象の病態が違います。場面を共変量に加えるときは、カットオフも同時にモデルに入れます。カットオフが場面と結びついていると、場面だけを入れたモデルでは、場面の差とカットオフの差が区別できないからです。この例の場面とカットオフの組み合わせを表 14.1 に示します。

	0.25	0.5	1.0
救急外来	2	4	0
ICU	0	2	2

表 14.1　場面とカットオフ（ng/mL）ごとの研究数

救急外来の 6 研究は 0.25 と 0.5 ng/mL、ICU の 4 研究は 0.5 と 1 ng/mL を使っています。0.5 ng/mL では両方の場面の研究がそろっているので、カットオフを調整したうえで場面を比べる足がかりがあります。

```
fit_set <- reitsma(pct,
  formula = cbind(tsens, tfpr) ~ setting + lcut)
```

```
summary(fit_set)
```

```
                     Estimate Std. Error      z Pr(>|z|)
tsens.(Intercept)       1.225      0.277  4.427    0.000
tsens.setting救急外来  -0.994      0.403 -2.463    0.014
tsens.lcut             -0.800      0.427 -1.873    0.061
tfpr.(Intercept)       -1.623      0.251 -6.479    0.000
tfpr.setting救急外来   -0.202      0.346 -0.585    0.559
tfpr.lcut              -0.924      0.381 -2.423    0.015
```

場面の列は文字なので、R は文字の並び順で先に来る値（この例では ICU）を基準にし、もう一方の値（救急外来）との差を推定します。出力は次のように読みます。

tsens.setting 救急外来　同じカットオフで比べると、救急外来の研究では logit 感度が 0.994 低いという推定で、p = 0.014 でした。

tfpr.setting 救急外来　救急外来の研究で logit 偽陽性割合が 0.202 低いという推定ですが、p = 0.56 で、差ははっきりしません。

tsens.lcut と tfpr.lcut　カットオフの係数です。偽陽性割合の − 0.924（p = 0.015）は、カットオフを上げると偽陽性割合が下がることを示します。感度の − 0.800 は p = 0.061 で、場面を調整すると感度もカットオフとともに下がる向きに出ました。カットオフだけを入れたモデルでは − 0.064 だったので、場面を入れたことで推定が大きく変わっています。

カットオフが 0.5 ng/mL の研究について、係数から感度と特異度を計算します。救急外来の列の係数は、ICU との差を表します。

```
cs <- coef(fit_set)
f <- function(par, e) cs["(Intercept)", par] +
  e * cs["setting救急外来", par] + cs["lcut", par] * log(0.5)
round(rbind(
  ICU = c(sens = plogis(f("tsens", 0)),
          spec = 1 - plogis(f("tfpr", 0))),
  救急外来 = c(sens = plogis(f("tsens", 1)),
```

```
    spec = 1 - plogis(f("tfpr", 1)))), 2)
```

```
         sens spec
ICU      0.86 0.73
救急外来 0.69 0.77
```

ICU の感度は 0.86、特異度は 0.73、救急外来の感度は 0.69、特異度は 0.77 です。調整すると、場面による違いは偽陽性割合ではなく感度に現れました。カットオフを調整する前の見え方（救急外来で特異度が低い）とは異なります。

この結果から、救急外来では PCT の感度が低い、と結論することはできません。理由は 3 つあります。カットオフを調整したうえで場面を直接比べられるのは、両方の場面の研究がそろう 0.5 ng/mL の 6 研究（救急外来 4、ICU 2）だけで、共変量を 2 つ入れると推定が不安定になります。感度の係数は、場面を入れるかどうかで − 0.064 から − 0.800 まで動いており、モデルの選び方に結果が左右されています。ICU の高い感度には、14.5 節（p. 170）で見る高リスクの研究（部分的検証の Qureshi 2018）も含まれています。

共変量の解析は、研究の間の比較です。介入のメタ解析のサブグループ解析（6.4 節（p. 64））と同じく、ランダム化されていない観察研究の比較なので、ほかの特徴との交絡を避けられません。記載されていない特徴（重症度の分布、測定試薬）も研究ごとに違っています。研究数が少ないときに共変量をいくつも試すと、偶然の差を拾う危険も増えます。結果は「差の原因の候補が見つかった」として報告し、原因と断定しない書き方にします。

14.4
同じカットオフの研究だけでまとめる

本書は、13.2 節（p. 147）のとおり主解析をカットオフ 0.5 ng/mL の 6 研究（Kato 2010、Lopez 2011、Mori 2013、Park 2016、Qureshi 2018、Rossi 2019）にしました。臨床でよく使われるカットオフで、研究数が最も多いためです。どのカットオフを主解析にするかは、プロトコルで先に決めておきます。カットオフが混ざったデータの扱いには 3 つの方針があり（10.6 節（p. 114）、Macaskill 2023、9.3.1）、全 10 研究は、要約点ではなく SROC 曲線と共変量の解析に使いました。

同じカットオフの研究だけで統合する　臨床で使うカットオフについて、要約点を出します。研究数が減るのが欠点で、本書の主解析はこの方法です。

SROC 曲線を示す　HSROC モデル、または二変量モデルから導いた SROC 曲線で、カットオフを動かしたときの感度と特異度の関係を示します。個々のカットオフの値は分かりません。

複数のカットオフを同時に扱う方法　Steinhauser らの方法などがあります。本書では使いません。

発展　複数のカットオフを同時に扱う方法は、1 つの研究が複数のカットオフで報告しているデータをすべて使い、カットオフごとの感度と特異度を推定する手法です。Steinhauser らの方法（Steinhauser 2016）と、Jones らがカットオフへの依存を定量化する方法（Jones 2019）があります。Cochrane の DTA ハンドブック第 10 章は、前者を R の diagmeta パッケージで実行する例を載せています（10.7.1）。検査値が連続量であることを前提にしたモデルで、本書では名前の紹介にとどめます。

6 研究の要約点は、感度 0.746（0.638〜0.831）、特異度 0.757（0.726〜0.786）でした。要約点はこの 6 研究のカットオフ 0.5 ng/mL に対応する値で、0.25 や 1 ng/mL の値ではありません。全 10 研究から引いた SROC 曲線は、カットオフを変えたときの感度と特異度の関係を示す図として使い、曲線上の 1 点を要約点として報告することはしません。

14.5 バイアスのリスクで分ける

12.7 節（p. 135）の QUADAS-2 の判定では、カットオフ 0.5 ng/mL の 6 研究のうち 2 研究が高リスクでした。Rossi 2019 は対象検査の領域で、データを見てからカットオフを決めていました。Qureshi 2018 はフローとタイミングの領域で、参照基準による検証が一部の患者にしか行われていませんでした（部分的検証）。高リスクの研究を除いても結果が変わらないかを確かめるのが、バイアスのリスクによる感度分析です（感度分析の考え方は 7.6 節（p. 77）、判定の使い方は 12.8 節（p. 137）で説明しました）。

判定の列は、データの q_pat、q_idx、q_ref、q_flow（患者選択、対象検査、参照基準、フローとタイミング）に入れてあります。4 つの領域のどれかが高の研究を除き、残った 4 研究に主解析と同じ、相関を 0 にしたモデルを当てはめます。to_long() は 13.3 節（p. 148）で定義した関数です。

```
pct5 <- subset(pct, cutoff == 0.5)        # 主解析の 6 研究
low <- subset(pct5, q_pat != "高" & q_idx != "高" &
                    q_ref != "高" & q_flow != "高")
fit_ind <- function(d)                    # 相関を 0 にしたモデル（第
↪  13 章の g と同じ式）
  glmer(cbind(y, n - y) ~ 0 + sens + spec +
          (0 + sens | study) + (0 + spec | study),
        data = to_long(d), family = binomial)
g_low <- fit_ind(low)
```

最後に、感度と特異度を逆 logit で戻し、研究間の標準偏差を取り出します。

```
b <- fixef(g_low)
se <- sqrt(diag(as.matrix(vcov(g_low))))
plogis(b["sens"] + c(0, -1.96, 1.96) * se["sens"])
plogis(b["spec"] + c(0, -1.96, 1.96) * se["spec"])
sapply(VarCorr(g_low), attr, "stddev")   # 研究間の標準偏差を取り出す
```

```
[1] 0.709 0.573 0.815
[1] 0.781 0.755 0.806
  study.sens study.1.spec
       0.488        0.000
```

上の 2 行は、推定値、95% 信頼区間の下限、上限の順です。残った 4 研究（Kato、Lopez、Mori、Park）の要約点は、感度 0.709（0.573〜0.815）、特異度 0.781（0.755〜0.806）でした。6 研究の要約点（感度 0.746、特異度 0.757）と比べると、感度は下がり、特異度は上がっています。2 つの要約点を ROC 平面に置いたものが図 14.2 です。

動いた向きは、2 つの高リスクの理由と整合します。データを見てカットオフを決めると、そのデータでの精度が高く出ます。部分的検証では、検査が陽性の人ほど参照基準で確かめられやすいので、感度が高く、特異度が低く出ます。Qureshi 2018 は感度 0.86 で、6 研究のなかで Park 2016（0.88）に次いで高く、特異度は 0.71 で最も低い側にあります。部分的検証で予想される向きです。Rossi 2019 は感度 0.73、特異度 0.71 で、個々の点からは偏りの向きを読み取れません。

高リスクの研究を除くと感度は下がり、特異度は上がりました。感度が高く見えていた分が取れたという向きですが、確かな結論とは言えません。2 つの要約点の信頼区間は大きく重なっており、図 14.2 でも 2 つの楕円は重なっています。4 研究では推定が不安定です。特異度の研究間の標準偏差は 0.000 と推定され、モデルが境界に張り付きました（出力に「boundary (singular) fit」の警告が出ます）。4 研究の特異度のばらつきが

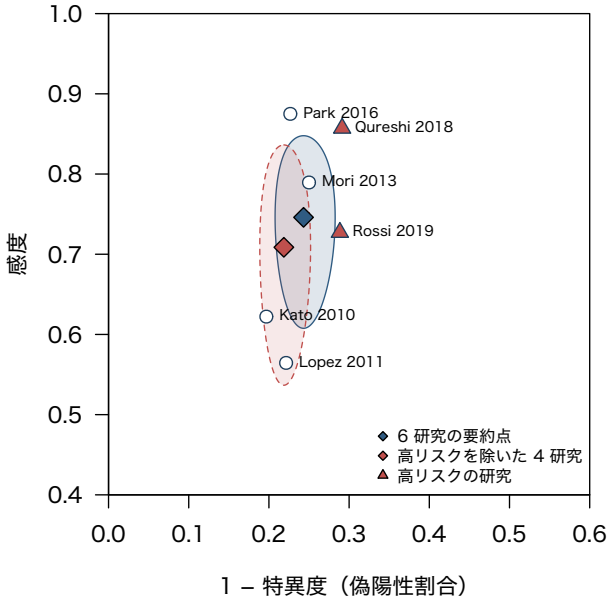


図 14.2　カットオフ 0.5 ng/mL の 6 研究。三角が高リスクの研究（Qureshi 2018、Rossi 2019）。青の菱形と楕円は 6 研究の要約点と 95% 信頼領域、赤の菱形と破線の楕円は高リスクを除いた 4 研究の要約点と 95% 信頼領域

二項分布の誤差だけで説明できる範囲と推定されたということで、本当にばらつきがないことを示すものではありません。特異度の信頼区間は、研究間のばらつきを含まない分だけ狭く出ていると考えます。

mada の reitsma() で同じ 4 研究を推定すると、感度 0.706（0.546〜0.827）、偽陽性割合 0.222（0.196〜0.251）で、感度の向きは同じです。報告では、主解析を 6 研究の結果とし、感度分析で高リスクの研究を除いた結果と、境界に張り付いたことを並べて書きます。

14.6
発展 検査どうしを比べる

PCT と CRP のどちらが菌血症を見分けるのに優れているか、という問いもよく立てられます。比べ方は 2 通りあり、信頼できる程度が違います。

直接比較　同じ患者で PCT と CRP の両方を測った研究だけを使う方法です。患者、参照基準、場面がそろっているので、差は検査の違いによるものと考えやすくなります。

間接比較　PCT の研究と CRP の研究を別々に集め、それぞれの要約点を比べる方法です。研究の対象や参照基準が違うので、差が検査の違いによるのか研究の違いによるのかを区別できません。

Cochrane の DTA ハンドブックは、比較精度のレビューでは直接比較の研究を優先するよう述べています（9.4.7）。間接比較には、検査の違いと研究の違いが混ざる問題があるためです。比較精度の研究のバイアスのリスクは、QUADAS-2 に比較の観点を加えた QUADAS-C で評価します（Yang 2021）。

二変量モデルでは、検査の種類を共変量として入れて比べます。このとき、同じ患者で両方を測った研究は、1 つの研究から 2 組の 2×2 表が出ます。2 組は同じ患者から作られているので互いに独立ではなく、ふつうの二変量モデルはこの依存を無視します。また、検査ごとに研究間のばらつきの大きさが違うことも多いので、Cochrane の DTA ハンドブック第 10 章は、検査ごとに研究間分散を別々に推定するモデルを示しています。直接比較の研究が十分にあれば、それだけで解析した結果を主に示し、間接比較を含めた結果は補助として扱います。

14.7

発展 2 本の Lancet Infect Dis 論文

PCT の診断精度については、同じ Lancet Infectious Diseases 誌に、結論の違う 2 本のメタ解析が載っています。どちらも、重症患者で敗血症と非感染性の全身性炎症反応症候群（SIRS）を見分けられるか、という問いを扱いました。本書の例題（菌血症）とは標的疾患が違いますが、同じ検査について要約値と結論が変わった実例です。

発展 Tang 2007

Tang らは ICU の重症患者を対象にした 18 研究を統合し、感度と特異度がともに 71%（95% 信頼区間 67〜76%）、SROC の AUC 0.78（0.73〜0.83）と報告しました。研究を Sackett と Haynes の分類で phase 2（14 研究）と phase 3（4 研究）に分けて調べ、phase 3 の研究では標本の大きさで結果が違い、小さい研究ほど精度が高く、大きい研究では差がない方向に近づいたとしています（メタ回帰の係数 -0.592、$p = 0.017$）。結論は「PCT は敗血症と非感染性 SIRS を確実には区別できない」というものでした。同誌の同じ年には、この論文への批判の投書が 3 通と、著者の返答が掲載されています。

発展 Wacker 2013

Wacker らは 7 つのデータベースを 2012 年 2 月まで検索し、3487 件から 30 研究、3244 人を組み入れました。二変量モデルで統合した感度は 0.77（0.72〜0.81）、特異度は 0.79（0.74〜0.84）、AUC は 0.85（0.81〜0.88）でした。I^2 は 96% で、対象、入院の区分、測定法、重症度、参照基準の記述と盲検化のいずれのサブグループでも、ばらつきを説明できませんでした。結論は「PCT は早期診断に役立つが、病歴、診察、微生物学的な評価と合

わせて解釈する」というものです。

発展 読み比べて分かること

2 本の要約値の差は、感度で 71% 対 77%、特異度で 71% 対 79%、AUC で 0.78 対 0.85 でした。2 本の間で、組み入れた研究の数（18 と 30）、検索した時期、組み入れの基準が違います。その違いのどれが結論を分けたのかは、抄録から読み取れる範囲では決められません。

どちらのレビューでも研究間のばらつきが大きく、Tang は小さい研究ほど精度が高く出る傾向を示し、Wacker では測定法を含むどの特徴でもばらつきを説明できませんでした。ばらつきが大きく原因が分からないときは、要約点の数値の差を比べるより、新しい現場で精度がどれだけ振れるか（予測領域の広さ）を見るほうが臨床の判断に役立ちます（→ 13.6 節 (p. 153)）。

14.8 既存のメタ解析を読むとき

既存のメタ解析を読むときは、要約点がどのカットオフの値なのかを、方法の節で確かめます。研究ごとにカットオフが違うのに 1 つの要約点を出していれば、本書が 13.2 節（p. 147）で避けた読み方になります。たとえば Wacker 2013 は 30 研究を二変量モデルで 1 組の感度と特異度にまとめていますが、抄録にはその要約点がどのカットオフに当たるかが書かれていません。

自分でレビューを行うときは、標的疾患と対照群（菌血症か敗血症か、比べる相手は誰か）、組み入れる研究デザイン、カットオフの扱い、ばらつきを調べる共変量（測定法、場面、採血の時点）、小規模研究効果の調べ方を、プロトコルで先に決めておきます。それらが書いてあれば、結論が先

行研究と違ったときに、どこで違ったのかを読者が追えます。

14.9 この章のまとめ

研究間のばらつきの原因は、対象、対象検査、参照基準の 3 つの方向から候補を挙げ、プロトコルで調べる共変量を決めておきます。共変量は二変量モデルに入れ、感度と偽陽性割合のそれぞれへの影響を読みます。PCT の全 10 研究では、カットオフを上げると偽陽性割合が下がりました。場面を比べるときは、まずカットオフをそろえた研究どうしで比べます。カットオフの混ざった研究から要約点は出さず、主解析は同じカットオフの研究だけで行います。高リスクの研究を除いた感度分析で、感度は下がり特異度は上がりましたが、区間は重なっており、4 研究の推定は不安定でした。既存のメタ解析を読むときは、要約点がどのカットオフの値かを確かめます。第 15 章（p. 177）では、主解析の要約点を 1000 人あたりの数に直し、確実性を評価して報告します。

第 15 章

結果を臨床の言葉にして報告する

この章で分かること

13.5 節（p. 151）の主解析、カットオフ 0.5 ng/mL の 6 研究の要約点（感度 0.746、特異度 0.757）を、1000 人に PCT を測ったときの人数に直します。そのうえで、GRADE で結果の確実性を判定し、PRISMA-DTA に沿って報告を書きます。最後に、結果の段落の例文を示します。図 15.1 を描くコードと、検査前確率と検査後確率の図は、発展の印をつけて載せました。

15.1 1000 人あたりの数にする

感度 0.746 と特異度 0.757 という数字を聞いても、検査を使う場面で何が起きるかはすぐには浮かびません。同じ要約点を「1000 人の発熱患者に PCT を測ったら、何人が正しく判定され、何人が誤って判定されるか」に直すと、検査の役割に照らして結果を判断できるようになります。

人数に直すには有病割合を決める必要があります。組み入れた 10 研究の有病割合は、救急外来の研究で 11〜14%、ICU の研究で 21〜23% でした。そこで、研究の有病割合を見やすい数に丸めて、救急外来を想定した

10%、ICU を想定した 25% の 2 つの場面を置きます。計算は単純で、1000 人のうち菌血症の人数に感度を掛ければ真陽性、菌血症でない人数に特異度を掛ければ真陰性になり、残りがそれぞれ偽陰性と偽陽性です。括弧内は、感度と特異度の 95% 信頼区間の端から計算した範囲です。1000 人あたりで示す考え方は、介入のメタ解析の結果の要約表（7.9 節（p. 83））と同じです。

1000 人あたり	有病割合 10%（救急外来）	有病割合 25%（ICU）
菌血症の人	100	250
真陽性	75（64〜83）	187（159〜208）
偽陰性	25（17〜36）	63（42〜91）
菌血症でない人	900	750
真陰性	681（653〜707）	568（544〜589）
偽陽性	219（193〜247）	182（161〜206）
陽性的中割合	0.25	0.51
陰性的中割合	0.964	0.899

表 15.1　カットオフ 0.5 ng/mL の 6 研究の要約点（感度 0.746、特異度 0.757）を 1000 人に用いたときの人数

同じ人数を、1 人を 1 つの点にして並べると、誤りの多さを目で見られます。有病割合 10% の 1000 人の場合を図 15.1 に示します。

点の数は、表 15.1 と同じ計算で求めます。13.4 節（p. 150）の主解析の glmer() の結果 g（相関を 0 にしたモデル）から、感度と特異度を取り出します。

```
se <- plogis(fixef(g)[["sens"]])          # 感度 0.746
sp <- plogis(fixef(g)[["spec"]])          # 特異度 0.757
tp <- round(100 * se); fn <- 100 - tp     # 菌血症の 100 人
tn <- round(900 * sp); fp <- 900 - tn     # 菌血症でない 900 人
c(TP = tp, FN = fn, FP = fp, TN = tn)
```

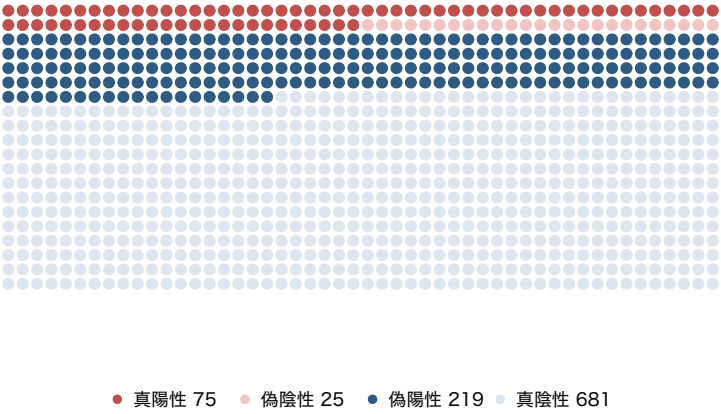


図 15.1　有病割合 10% の 1000 人を 1 人 1 点で並べた図（カットオフ 0.5 ng/mL の 6 研究の要約点、感度 0.746、特異度 0.757）

```
TP  FN  FP  TN
75  25 219 681
```

点 1 つが 1 人で、濃い赤が真陽性（75 人）、薄い赤が偽陰性（25 人）、濃い青が偽陽性（219 人）、薄い青が真陰性（681 人）です。赤の系統の 100 人が菌血症の人、青の系統の 900 人が菌血症でない人にあたります。PCT が陽性になるのは濃い赤と濃い青を合わせた 294 人で、そのうち菌血症は 75 人です。濃い青の点の多さが、陽性的中割合が 0.25 にとどまる理由を示しています。見落とされる薄い赤の点は 25 個で、数は少ないものの、除外に使う場合はこの 25 人が問題になります。有病割合を 25% にすると、赤の系統が 250 点に増え、青の系統が 750 点に減るので、同じ図でも濃い赤と濃い青の比が変わります。

陽性的中割合は、検査が陽性になった人のうち本当に菌血症である人の割合で、一般には陽性的中率とも呼ばれます。救急外来の場面では 75 ÷

294 で 0.25 です。ICU の場面では有病割合が高いので、同じ感度と特異度でも陽性的中割合は 0.51 に上がります。9.3 節（p. 97）で述べたとおり、感度と特異度が同じでも、的中割合は有病割合によって変わります。

発展 図 15.1 を描くコード

rep() に人数を渡して、真陽性、偽陰性、偽陽性、真陰性の順に 1000 個のラベルを作り、50 列 20 行の格子に左上から順に置いています。

```
lab <- rep(c("TP", "FN", "FP", "TN"), c(tp, fn, fp, tn))
col <- c(TP = "red", FN = "pink", FP = "blue", TN = "lightblue")
x <- rep(1:50, times = 20)     # 50 列
y <- rep(20:1, each = 50)      # 20 行
plot(x, y, pch = 19, col = col[lab], asp = 1,
     axes = FALSE, xlab = "", ylab = "")
```

有病割合と的中割合

表 15.1 は有病割合 10% と 25% の 2 点だけを示しました。有病割合を連続的に動かしたときの陽性的中割合と陰性的中割合を、図 15.2 に示します。感度と特異度は主解析の要約点の値に固定しています。

的中割合は、1000 人の表の計算を式にしたものです。真陽性は感度 × 有病割合、偽陽性は（1 − 特異度）×（1 − 有病割合）に比例するので、陽性的中割合はその 2 つの比で決まります。

```
prev <- seq(0.01, 0.6, by = 0.005)     # 有病割合
ppv <- se * prev /
  (se * prev + (1 - sp) * (1 - prev))  # 陽性的中割合
npv <- sp * (1 - prev) /
  (sp * (1 - prev) + (1 - se) * prev)  # 陰性的中割合
plot(100 * prev, ppv, type = "l", col = "red", ylim = c(0, 1),
     xlab = "有病割合（%）", ylab = "的中割合")
lines(100 * prev, npv, col = "blue")
abline(v = c(10, 25), lty = 3)
```

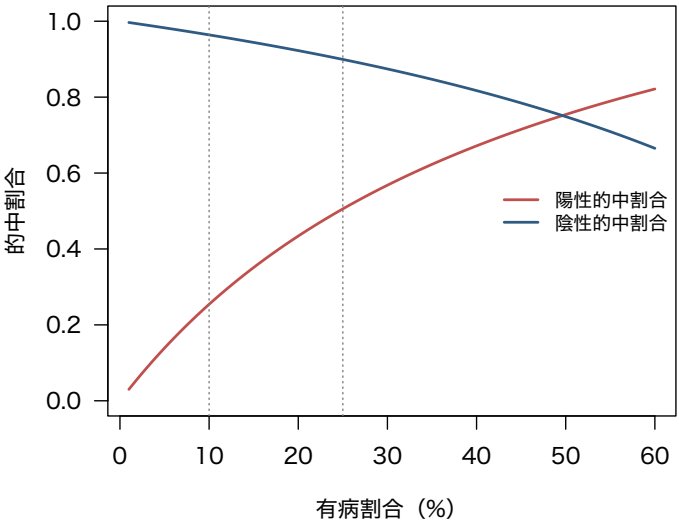


図 15.2　有病割合と的中割合の関係（カットオフ 0.5 ng/mL の 6 研究の要約点、感度 0.746、特異度 0.757 に固定）。縦の点線は有病割合 10% と 25%

横軸は検査を受ける集団の有病割合、縦軸は的中割合で、赤が陽性的中割合、青が陰性的中割合です。有病割合が上がると、赤の曲線は右上がりに上昇し、青の曲線は下がります。有病割合 10% では陽性的中割合が 0.25、陰性的中割合が 0.964、25% では陽性的中割合が 0.51、陰性的中割合が 0.899 で、表 15.1 と一致します。同じ PCT でも、救急外来と ICU のように有病割合が違う場面では、陽性の意味が違います。

曲線は感度と特異度が有病割合によらず一定という前提で引いています。場面によって感度が変わる可能性もあるので、曲線は、検査を使う場面の有病割合を決めたうえで、その場面で推定した感度と特異度を使って描き直すのが原則です。

発展 検査前確率と検査後確率

9.4 節（p. 98）で、検査前の確率に尤度比を掛けると検査後の確率になることを、Kato 2010 の値で計算しました。要約点から求めた尤度比（陽性 3.07、陰性 0.34）を使い、検査前の確率ごとに検査後の確率を描いたものが図 15.3 です。

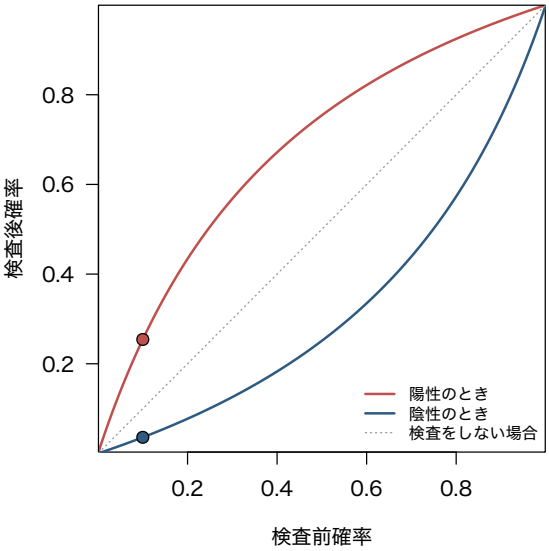


図 15.3　検査前確率と検査後確率（カットオフ 0.5 ng/mL の 6 研究の要約点から求めた陽性尤度比 3.07、陰性尤度比 0.34）。点は検査前確率 10% の場合

```
lrp <- se / (1 - sp)          # 陽性尤度比
lrn <- (1 - se) / sp          # 陰性尤度比
post <- function(p, lr) {     # 検査前確率 p から検査後確率を求める
  odds <- p / (1 - p) * lr
  odds / (1 + odds)
}
p0 <- seq(0.001, 0.999, length.out = 300)
plot(p0, post(p0, lrp), type = "l", col = "red",
     xlab = "検査前確率", ylab = "検査後確率")
```

```
lines(p0, post(p0, lrn), col = "blue")
abline(0, 1, lty = 3)        # 検査をしない場合
round(post(0.10, c(lrp, lrn)), 3)
```

```
[1] 0.254 0.036
```

post() は、確率をオッズに直して尤度比を掛け、確率に戻す関数です。

横軸は、検査を行う前に、その患者が菌血症である見込みです。縦軸は検査の結果が分かった後の見込みです。点線の対角線は検査をしない場合で、検査前と検査後が同じ値になります。赤の曲線は PCT が陽性のとき、青の曲線は陰性のときの検査後確率です。検査前確率が 10% のとき、陽性なら 0.254、陰性なら 0.036 になります。10% は表 15.1 の救急外来の有病割合と同じなので、0.254 は陽性的中割合 0.25 に、0.036 は 1 − 陰性的中割合 0.964 に一致します。

赤と青の曲線が対角線から離れている幅が、この検査で見込みが動く大きさを表します。この検査の尤度比では、陽性でも検査前確率 10% の人の見込みは 3 割に届かず、陰性でも 0.036 が残ります。検査前確率は患者ごとに違い、診察の所見や経過で変わるので、図 15.3 の曲線は、個々の患者の検査前確率を推定したうえで読みます。

■ 検査の役割から誤りの重さを決める

表 15.1 の誤りのどちらを重く見るかは、PCT をどの役割で使うかで決まります。

除外に使う場合　PCT が陰性なら血液培養や抗菌薬を見送る、という使い方です。問題になるのは偽陰性で、救急外来の場面では 1000 人あたり 25 人（17〜36 人）の菌血症を見落とします。陰性的中割合 0.964 は高く見えますが、見落とされた 25 人は治療が遅れる人たちです。この数を許容できるかは、臨床の判断です。

確定に使う場合　PCT が陽性なら菌血症として扱う、という使い方です。

問題になるのは偽陽性で、救急外来の場面では 1000 人あたり 219 人（193〜247 人）が不要な精査や抗菌薬の対象になります。

追加の検査として使う場合　診察とほかの検査で判断がつかない人にだけ PCT を加える、という使い方です。この場合、関わる患者の有病割合は表 15.1 のどちらとも違う可能性があり、その集団の精度データが必要になります。

表 15.1 の人数から言えるのは、PCT 単独では菌血症を除外することも確定することもできない、ということです。要約点が示す精度の水準と、13.6 節（p. 153）で見た予測領域の広さの両方が、その判断の根拠になります。

15.2 GRADE で確実性を判定する

GRADE は 7.8 節（p. 80）で介入のメタ解析に当てはめました。検査の精度にも同じ枠組みを使いますが、いくつか違いがあります。研究デザインとバイアスのリスク、非直接性の扱いは Schünemann らの GRADE guidelines 21 part 1、非一貫性、不精確さ、出版バイアスの扱いと結果の要約表の作り方は part 2 にまとまっています（Schünemann 2020a、2020b）。

■ 検査の GRADE で違うところ

1 つめは出発点です。検査の精度の研究は、対象を連続して登録し、全員に対象検査と参照基準を行う横断研究であれば、確実性「高」から始めます。介入で RCT から始めるのと同じ位置づけです。症例対照デザインのような研究は、バイアスのリスクの領域で下げます。

2 つめは、判定の単位です。感度に関わる真陽性と偽陰性、特異度に関わる真陰性と偽陽性について、それぞれ確実性を判定します。感度の研究

は菌血症の人だけ、特異度の研究は菌血症でない人だけから推定されるので、ばらつきや不精確さの程度が両者で違うからです。

3 つめは、非直接性の考え方です。検査の精度は、患者にとっての結果（死亡、入院期間、抗菌薬の使用量）を直接示すものではありません。検査の結果に基づいて治療が変わり、その治療が患者の結果を変える、という一連の流れを前提にしています。

検査の精度と患者の転帰

検査の精度が高いことは、その検査を使うと患者の転帰が良くなることを意味しません。検査の結果が診療を変え、その変更が転帰を改善して初めて、患者に利益が生じます。精度の研究が示すのは、検査が病気のある人とない人を見分けられるかどうかまでです。検査の結果を使った診療と使わない診療を比べ、死亡や入院期間のような患者の転帰を調べるのは、検査と治療を組にした無作為化試験の役割です。そうした試験がないレビューでは、精度の結果を患者の利益として読まず、結果の要約表に注記を付けます。

5 つの領域

確実性を下げる領域は、介入と同じく 5 つあります。

バイアスのリスク　QUADAS-2（または QUADAS-3）の判定から決めます（判定の使い方は 12.8 節（p. 137））。高リスクの研究が要約点の多くを占めていれば下げます。

非直接性　研究の対象、対象検査、参照基準が、レビューの問いとずれていないかを見ます。測定試薬が国内で使われているものと違う、血液培養のセット数が少なく参照基準が不完全である、といったずれがここに入ります。

非一貫性　研究間のばらつきが大きく、その原因が説明できないときに下

げます。I^2 は検査のメタ解析では使いにくいので（10.7 節（p. 115））、研究ごとの感度と特異度の散らばりと、予測領域の広さで判断します。

不精確さ　信頼区間の幅を、1000 人あたりの人数で評価します。偽陰性が 17 人の場合と 36 人の場合とで、臨床の判断が変わるかどうかを考えます。

出版バイアス　診断精度の研究では、試験登録が普及しておらず、小規模研究効果を調べる検定の検出力も低いので、評価は難しくなります。介入の Egger 検定は使わず、Deeks の方法を使います（10.8 節（p. 116）、Deeks 2005）。

PCT の例での判定

主解析のカットオフ 0.5 ng/mL の 6 研究について、架空の PCT のレビューで判定した例を表 15.2 に示します。判定の理由は、レビューの著者が 1 つずつ書き残します。ここでの判定は説明のための架空のものです。

領域	感度（真陽性と偽陰性）	特異度（真陰性と偽陽性）
バイアスのリスク	1 段階下げる	1 段階下げる
非直接性	下げない	下げない
非一貫性	1 段階下げる	下げない
不精確さ	下げない	下げない
出版バイアス	下げない	下げない
確実性	低	中

表 15.2　カットオフ 0.5 ng/mL の 6 研究の要約点についての GRADE の判定（架空の例）

判定の根拠を領域ごとに書きます。

バイアスのリスク　6 研究のうち 2 研究（Rossi 2019 と Qureshi 2018）が QUADAS-2 で高リスクでした。Rossi 2019 はデータを見てカットオ

フを決めており、Qureshi 2018 は一部の患者にしか参照基準を行っていません。この 2 研究を除いた 4 研究の要約点は感度 0.709（0.573〜0.815）、特異度 0.781（0.755〜0.806）で、感度は下がり、特異度は上がりました（14.5 節（p. 170））。感度、特異度とも 1 段階下げました。

非直接性　対象の場面（救急外来と ICU）、対象検査（PCT）、参照基準（血液培養）は、レビューの問いと合っているので、下げませんでした。患者の転帰への影響は精度の研究からは分からないので、結果の要約表に注記します。

非一貫性　6 研究の感度は 0.56 から 0.88 まで散らばり、研究間の標準偏差は logit 感度で 0.518 でした。カットオフはそろえてあり、場面とカットオフを調べても原因を一つに決められなかったので（14.2 節（p. 163））、感度は 1 段階下げました。特異度は 0.71 から 0.80 の範囲に収まり、logit 特異度の研究間の標準偏差は 0.136 と小さいので、下げませんでした。

不精確さ　6 研究で、感度の信頼区間は 0.638 から 0.831 と、特異度の 0.726 から 0.786 より広く開いています。有病割合 10% の救急外来の場面で、偽陰性は 17〜36 人、偽陽性は 193〜247 人の範囲にあります。どちらの端でも「PCT 単独では除外も確定もできない」という判断は変わらないので、下げませんでした。

出版バイアス　6 研究では、小規模研究効果を調べる Deeks の検定で出版バイアスを確かめることが難しいと記載したうえで、未発表の研究がある証拠もないので、下げませんでした。

> 発展 Deeks の検定は、診断オッズ比に研究間の異質性があるときに検出力がとくに低く、有意でなくても出版バイアスがないとは言えません（Cochrane の DTA ハンドブック 9.5.3）。6 研究の診断オッズ比は 4.56 から 23.88 まで開いています。

この判定では、感度の確実性は「低」、特異度は「中」です。感度と特異度を別々に判定したために、2 つの確実性が分かれました。

表 15.1 と表 15.2 を合わせたものが、結果の要約表（Summary of findings 表）の中身になります。PCT の例なら、真陽性、偽陰性、真陰性、偽陽性の 4 行それぞれに、1000 人あたりの人数（有病割合 10% と 25%）、研究数と人数（6 研究、1,782 人で、菌血症 272 人と菌血症でない 1,510 人）、確実性を並べます。

15.3 PRISMA-DTA に沿って報告する

診断精度のメタ解析の報告指針は PRISMA-DTA です（McInnes 2018）。介入のレビューの PRISMA を、診断精度のレビューに合わせて項目を変えたり加えたりしたもので、多くの雑誌が投稿時にチェックリストの提出を求めます。学会発表や論文の抄録については、抄録版の PRISMA-DTA for Abstracts があります（Cohen 2021）。8.1 節（p. 86）で見た PRISMA 2020 と共通する項目が多く、検査のレビューで書き落としやすいのは、論文の部分ごとに次の点です。

題と抄録　題で診断精度のレビューであることが分かるようにします。抄録には、対象検査、参照基準、標的疾患、要約の感度と特異度を書きます。

序論　対象検査を臨床のどの役割（置き換え、トリアージ、追加）で使うことを想定しているかを書きます。

方法　対象、対象検査、参照基準、標的疾患を定義します。カットオフの扱い（どのカットオフを主解析にするか、複数あるときにどれを取ったか）、バイアスのリスクの評価方法（QUADAS-2 など）、統計手法（二変量モデル、HSROC モデル、使ったソフトウェアとパッケージ）、ばらつきを調べる共変量を、事前に決めたものとして書きます。

結果　研究ごとの 2×2 表、感度と特異度と信頼区間を表かフォレストプロットで示します。SROC 曲線、要約点、信頼領域、予測領域を図で

示します。QUADAS-2 の判定を研究ごと、領域ごとに示します。

考察　結果を臨床の言葉（1000 人あたりの人数）で述べ、ばらつきとバイアスのリスクがどの程度結論を弱めるかを書きます。

研究ごとの 2×2 表は、読者がメタ解析をやり直すための最低限のデータです。本文の表に収まらなければ、補足資料に載せます。解析に使った R のコードも、補足資料かリポジトリで公開しておくと、読者が結果を確かめられます。

15.4 結果の段落の例文

架空の PCT のレビューについて、結果の段落を書くと次のようになります。数値は本書の例題のものです。

例文

検索で得た 2,315 件から、10 研究（3,626 人、うち菌血症 556 人）を組み入れた。6 研究が救急外来、4 研究が ICU の患者を対象とし、PCT のカットオフは 0.25、0.5、1 ng/mL であった。カットオフが混ざるため、主解析は研究数の最も多いカットオフ 0.5 ng/mL の 6 研究（1,782 人、うち菌血症 272 人）とし、二項分布の二変量モデルで要約した。研究間の相関が − 1 の境界に張り付いたため、相関を 0 にしたモデルに単純化した。要約の感度は 0.746（95% 信頼区間 0.638〜0.831）、特異度は 0.757（0.726〜0.786）であった。6 研究の感度は 0.56 から 0.88、特異度は 0.71 から 0.80 の範囲にあった。全 10 研究は SROC 曲線とカットオフの共変量の解析に使い、カットオフが高いほど偽陽性割合が低かった（logit 偽陽性割合の係数 − 0.77、p = 0.006）。バイアスのリスクが高い 2 研究（Rossi 2019、Qureshi 2018）を除いた 4 研究では、感度 0.709（0.573〜0.815）、特異度 0.781（0.755〜0.806）で、特異度の研究間の標準偏差は 0 と推定された。有病割合 10% の 1000 人に用いると、菌血症 100 人の

> うち 25 人（17〜36 人）が偽陰性、菌血症でない 900 人のうち 219 人（193〜247 人）が偽陽性になると推定された。確実性は、感度を「低」、特異度を「中」と判定した。

例文はである調で書きました。論文の本文は、雑誌の慣習に合わせて文体を選びます。数値の示し方は、主解析の対象と要約点、ばらつきの範囲、共変量の結果、感度分析、1000 人あたりの人数、確実性の順にすると、読者が結論の強さを一度に判断できます。

15.5 この章のまとめ

要約点は、検査を使う場面の有病割合を置いて 1000 人あたりの人数に直し、検査の役割から見て重い誤り（除外なら偽陰性、確定なら偽陽性）の数で判断します。精度が高いことと患者の転帰が良くなることは別の問いで、後者は検査と治療を組にした試験で調べます。確実性は GRADE で、感度と特異度を別々に判定し、その理由を書き残します。報告は PRISMA-DTA に沿い、研究ごとの 2×2 表と解析コードを公開します。第 2 部はここまでで、問いを立ててから報告するまでの工程を、検査のメタ解析で一通りたどりました。この先を学ぶには、Cochrane の DTA ハンドブックの第 9 章（考え方）と第 10 章（実行）が最も詳しい資料です（付録 C）。

付録

R の準備、コードの全文、用語集、参考文献を収めます。

付録 A

R の準備とコードの全文

この章で分かること

本書の解析は、R と 3 本のスクリプトで再現できます。R を初めて使う読者に向けて、入手、スクリプト一式のダウンロード、作業フォルダの作り方、パッケージのインストール、スクリプトの実行までを順に書き、続けてスクリプトの全文を載せます。スクリプトは本文の各章に分けて載せたコードを 1 本にまとめ直したもので、上から順に実行すれば、スクリプトに含まれる範囲の数値は本文と同じになります。

A.1 R と RStudio の入手

R は統計解析のための無料のソフトウェアで、CRAN（The Comprehensive R Archive Network）のウェブサイトから、Windows 用と macOS 用のインストーラを入手できます。macOS では、Apple シリコン（M1 以降）用と Intel 用でインストーラが分かれているので、使っている Mac に合うほうを選びます。

RStudio は R を使いやすくするための画面で、スクリプトの編集、実行、結果の表示、図の表示を 1 つの窓にまとめてくれます。R を先に入れ、次

に RStudio を入れます。RStudio は Posit 社のウェブサイトから無料版を入手できます。RStudio を起動すると、左上にスクリプト、左下にコンソール（R に命令を打ち込む場所）、右側に変数の一覧と図が表示されます。

A.2 スクリプト一式をダウンロードする

本書の PDF とスクリプトは、GitHub の次のページで公開しています。

https://github.com/ttoyama/meta-analysis-nyumon

ページの右上の緑の「Code」ボタンから「Download ZIP」を選び、ZIP を展開します。フォルダの中の meta-analysis-nyumon.Rproj をダブルクリックすると RStudio が開き、そのフォルダが作業フォルダになります。続けて 00_setup.R を開き、エディタの右上の「Source」を押します。このスクリプトは、足りないパッケージを入れ、data、fig、out のフォルダを作り、架空データの CSV を作ります。インターネットに直接つながらないときは、福井大学の学内 LAN とみなして大学のプロキシを設定してから続けます。Windows と macOS のどちらでも、同じ手順で動きます。

この手順で準備した読者は、次の「作業フォルダを作る」と「パッケージのインストール」の節を読み飛ばして、「スクリプトの実行」の節に進んでかまいません。

A.3 作業フォルダを作る

解析に使うファイルは 1 つのフォルダにまとめます。次の手順で作ります。

1. 好きな場所に「メタ解析入門」というフォルダを作ります。

2. RStudio のメニューの File から New Project を選び、Existing Directory で、手順 1 のフォルダを指定します。以後は、プロジェクトを開くだけで、作業フォルダがこのフォルダに設定されます。
3. そのフォルダの中に、data、fig、out の 3 つのフォルダを作ります。R のコンソールに `dir.create("data")` のように打っても作れます。
4. 以後のコードは、このフォルダを作業フォルダとして実行します。スクリプトのファイルは、このフォルダの直下に置きます。

3 つのフォルダの使い道は次のとおりです。

data CSV のデータを置きます。`bp_stroke.csv`（4.4 節（p. 40））と `pct_bact.csv`（12.10 節（p. 139））が入ります。

fig 図の PDF を置きます。

out 解析の出力を文字で保存します。

A.4 パッケージのインストール

R の機能の多くはパッケージという追加部品として配られています。本書では次の 5 つを使います。

meta 介入のメタ解析（第 1 部）を行います。フォレストプロットとファネルプロットもこのパッケージで描きます。

metafor メタ回帰と BCG ワクチンの実データ（6.5 節（p. 67））に使います。

mada 検査のメタ解析（第 2 部）を行います。二変量モデルの `reitsma()` と、SROC 曲線の図を担います。

lme4 一般化線形混合モデルの `glmer()` を提供します。13.3 節（p. 148）で二変量モデルを二項分布のまま当てはめるときに使います。

MASS　架空データを作るスクリプト（`010_make_data.R`）が、乱数の生成に使います。R に最初から入っていることが多いのですが、次の行に含めておけば確実です。

インストールはコンソールで 1 回だけ実行すれば済みます。途中で CRAN のミラー（配布元のサーバー）を聞かれたら、日本のものを選びます。

```
install.packages(c("meta", "metafor", "mada", "lme4", "MASS"))
```

インストールは一度行えばパッケージがコンピュータに保存されます。R を起動するたびに必要なのは、そのパッケージを使えるようにする `library()` での読み込みです。

```
library(meta)
library(mada)
library(lme4)
```

macOS では、インストールの途中で「gfortran が見つからない」という趣旨のエラーが出ることがあります。これは、パッケージをソースから組み立てようとして、組み立てに使う道具が手元にないときに起こります。多くの場合は、R を最新版に入れ直すか、インストールの途中で「ソースから組み立てるか」と聞かれたときに no と答えて、CRAN が用意した組み立て済み（バイナリ版）を使えば解決します。

A.5 スクリプトの実行

スクリプトの中の `"data/pct_bact.csv"` のような書き方は、作業フォルダからの相対的な位置です。作業フォルダがずれていると「ファイルが見つからない」というエラーになります。本文で最初に使う場面は 5.5 節（p. 49）で説明しています。現在の作業フォルダは `getwd()` で確かめられ

ます。プロジェクトを使わない場合は、`setwd()` にフォルダの場所を渡して作業フォルダを変えます。

スクリプトを開いたら、実行したい行にカーソルを置いて Ctrl と Enter（macOS では Command と Enter）を押すと、その行がコンソールに送られて実行されます。複数行を選んでから押せば、選んだ範囲がまとめて実行されます。全体を上から順に実行するには、右上の Source を押します。初めのうちは 1 行ずつ実行し、出力を確かめながら進むと、どの行が何をしているかが分かります。

次の節からスクリプトの全文を載せます。PDF からコードを写すと、全角の記号や改行が崩れることがあります。崩れたときは、エラーの出た行を見て直してください。前の「スクリプト一式をダウンロードする」の節で入手したファイルを使うほうが確実です。

R のメモ

R はエラーのときに英語で理由を表示します。よく出るのは次の 3 つです。`could not find function` は、関数の名前の綴りの誤りか、そのパッケージを `library()` で読み込んでいないことを示します。`cannot open file` は、作業フォルダかファイル名が違うことを示します。`object not found` は、その名前の変数をまだ作っていない（前の行を実行していない）ことを示します。

A.6 架空データの作成（010_make_data.R）

第 1 部の降圧薬 A の 10 試験と、第 2 部の PCT の 10 研究は、どちらもこのスクリプトで作った架空のデータです。乱数の種（`set.seed()` の値）を固定しているので、何度実行しても同じデータが `data` フォルダに書き出されます。PCT の 10 研究のカットオフは、0.25 ng/mL が 2 研究、0.5 ng/mL が 6 研究、1 ng/mL が 2 研究になります。QUADAS-2 の判定を入

れる 4 つの列（q_pat、q_idx、q_ref、q_flow）も、同じ CSV ファイルに入ります。第 13 章のコードを最初から実行するときは、先にこのスクリプトを実行して data フォルダに CSV ファイルを作ります。そのうえで、13.1 節（p. 141）の library() と read.csv() の行から、上の順に実行します。

```
# 010_make_data.R  架空データを作る
# 乱数の種を固定しているので、何度実行しても同じ値になる

set.seed(20261021)

# ---- 第 1 部: 降圧薬 A 対 プラセボ（脳卒中）----
k <- 10
study <- c("Aoki 2009", "Berger 2011", "Chen 2012",
           "Dubois 2014", "Endo 2015", "Fischer 2016",
           "Garcia 2018", "Hayashi 2019", "Ivanov 2021",
           "Jensen 2022")
n_per_arm <- c(150, 1200, 420, 2500, 90, 800, 1600,
               300, 3000, 650)
pop <- c("高齢者", "一般", "高齢者", "一般", "高齢者",
         "一般", "高齢者", "一般", "一般", "高齢者")
p_ctrl <- ifelse(pop == "高齢者", 0.10, 0.05) *
  runif(k, 0.8, 1.2)
log_rr <- rnorm(k, log(0.80), 0.12)
log_rr[5] <- log(0.40)  # 小さな試験の大きな効果
ev_c <- rbinom(k, n_per_arm, p_ctrl)
ev_t <- rbinom(k, n_per_arm,
               pmin(p_ctrl * exp(log_rr), 0.9))
rob <- c("懸念あり", "低", "懸念あり", "低", "高",
         "低", "低", "懸念あり", "低", "低")
bp <- data.frame(study, pop, rob, ev_t, n_t = n_per_arm,
                 ev_c, n_c = n_per_arm)
write.csv(bp, "data/bp_stroke.csv", row.names = FALSE,
          fileEncoding = "UTF-8")

# ---- 第 2 部: PCT による菌血症の診断 ----
k2 <- 10
study2 <- c("Kato 2010", "Lopez 2011", "Mori 2013",
            "Nguyen 2014", "Ono 2015", "Park 2016",
            "Qureshi 2018", "Rossi 2019", "Sato 2021",
            "Tanaka 2023")
```

```
setting <- c("救急外来", "救急外来", "ICU", "救急外来",
             "ICU", "救急外来", "ICU", "救急外来", "ICU",
             "救急外来")
cutoff <- c(0.5, 0.5, 2.0, 0.25, 1.0, 0.5, 2.0, 0.5,
            1.0, 0.25)
n_pos <- c(45, 62, 38, 80, 51, 24, 70, 33, 58, 95)
n_neg <- c(310, 420, 140, 520, 190, 150, 230, 260,
           210, 640)
# カットオフが高いほど感度が下がり、特異度が上がる
shift <- log(cutoff / 0.5)
mu_se <- qlogis(0.78) - 0.55 * shift
mu_sp <- qlogis(0.74) + 0.55 * shift
r <- -0.4 * 0.45 * 0.55
S <- matrix(c(0.45^2, r, r, 0.55^2), 2)
re <- MASS::mvrnorm(k2, c(0, 0), S)
se <- plogis(mu_se + re[, 1])
sp <- plogis(mu_sp + re[, 2])
TP <- rbinom(k2, n_pos, se); FN <- n_pos - TP
TN <- rbinom(k2, n_neg, sp); FP <- n_neg - TN
# Mori 2013 と Qureshi 2018 をカットオフ 0.5 の研究に
# して数を引き直す（要約点を 0.5 の 6 研究で出すため）
set.seed(20261022)
redo <- match(c("Mori 2013", "Qureshi 2018"), study2)
cutoff[redo] <- 0.5
se_r <- plogis(qlogis(0.78) + c(-0.15, 0.55) +
                 rnorm(2, 0, 0.2))
sp_r <- plogis(qlogis(0.74) + c(0.10, -0.20) +
                 rnorm(2, 0, 0.2))
TP[redo] <- rbinom(2, n_pos[redo], se_r)
FN[redo] <- n_pos[redo] - TP[redo]
TN[redo] <- rbinom(2, n_neg[redo], sp_r)
FP[redo] <- n_neg[redo] - TN[redo]
# QUADAS-2 の判定（第 12 章）：患者選択、対象検査、
# 参照基準、フローとタイミング
q_pat  <- c("低", "低", "低", "低", "低", "不明",
            "低", "低", "低", "低")
q_idx  <- c("低", "低", "低", "低", "不明", "低",
            "低", "高", "低", "低")
q_ref  <- c("低", "低", "不明", "低", "低", "低",
            "低", "低", "低", "低")
q_flow <- c("低", "低", "低", "不明", "低", "低",
            "高", "低", "低", "低")
pct <- data.frame(study = study2, setting, cutoff,
```

```
                  TP, FP, FN, TN,
                  q_pat, q_idx, q_ref, q_flow)
write.csv(pct, "data/pct_bact.csv", row.names = FALSE,
          fileEncoding = "UTF-8")
```

A.7
第 1 部の解析（100_part1.R）

付録 5（p. 42）から付録 7（p. 72）で示した解析を順に並べています。`update()` は、すでに作ったメタ解析の設定を一部だけ変えて計算し直す関数で、同じ指定を何度も書かずに済みます。最後の BCG ワクチンの実データは metafor と一緒に入る metadat パッケージに収められています。

```
# 100_part1.R  第 1 部の解析
library(meta)
library(metafor)

bp <- read.csv("data/bp_stroke.csv",
               fileEncoding = "UTF-8")

# 主解析：リスク比、ランダム効果（REML）、予測区間つき
m <- metabin(ev_t, n_t, ev_c, n_c, studlab = study,
             data = bp, sm = "RR", method = "Inverse",
             method.tau = "REML", prediction = TRUE)
summary(m)

update(m, method = "MH")               # MH 法（固定効果）
update(m, method.random.ci = "HK")     # Hartung-Knapp 調整
m_sub <- update(m, subgroup = pop)     # 対象集団別
m_sub
update(m, subgroup = rob)              # バイアスのリスク別
update(m, subset = rob != "高")        # 感度分析
metainf(m, pooled = "random")          # 1 試験ずつ除く
metabias(m, method.bias = "Egger", k.min = 10)
summary(m)                             # 固定効果とランダム効果の統合値を並べて
↪  比べる
```

```
# 図（PDF に保存する）
pdf("fig_forest.pdf", width = 7, height = 4.5)
forest(m, sortvar = TE)
dev.off()
pdf("fig_funnel.pdf", width = 5.5, height = 4.5)
funnel(m, common = FALSE)
dev.off()

# 絶対効果：対照群リスク 5% と 10% の 1000 人あたり
rr <- exp(c(m$TE.random, m$lower.random,
            m$upper.random))
1000 * 0.05 * (rr - 1)
1000 * 0.10 * (rr - 1)

# 実データ：BCG ワクチン（metadat::dat.bcg）
dat <- escalc(measure = "RR", ai = tpos, bi = tneg,
              ci = cpos, di = cneg, data = dat.bcg)
r0 <- rma(yi, vi, data = dat, method = "REML")
r0
predict(r0, transf = exp)
r1 <- rma(yi, vi, mods = ~ ablat, data = dat,
          method = "REML")              # 緯度でメタ回帰
r1
predict(r1, newmods = c(20, 40, 55), transf = exp)
```

A.8
第 2 部の解析（200_part2.R）

付録 13（p. 141）の解析と、付録 14（p. 161）のカットオフを共変量にしたモデルを順に並べています。全 10 研究の感度と特異度を計算し、カットオフ 0.5 ng/mL の 6 研究を取り出して、二項 GLMM の二変量モデルを `glmer()` で当てはめます。相関を推定するモデルは、相関が -1 の境界に張り付いて singular の警告が出ます。そこで相関を 0 にしたモデルに単純化し、そのモデルから要約点と 95% 信頼区間、陽性尤度比、陰性尤度比、診断オッズ比を計算します。同じ 6 研究を mada の `reitsma()` で解析する

行は、結果を確かめるための参考です。要約点と信頼領域、予測領域の図は、楕円を計算する関数 `ellipse_roc()` を定義して描きます。全 10 研究には SROC 曲線だけを引き、log(カットオフ) を共変量にしたモデルを当てはめます。最後に、実データの AUDIT-C を `reitsma()` と `glmer()` の両方で解析します。場面を加えたモデル（14.3 節（p. 166））、バイアスのリスクによる感度分析（14.5 節（p. 170））、1000 人あたりの人数の計算（15.1 節（p. 177））は、各節に載せたコードを実行します。

```
# 200_part2.R  第 2 部の解析（本用の短い版）
library(mada)
library(lme4)
library(meta)

pct <- read.csv("data/pct_bact.csv",
                fileEncoding = "UTF-8")

# 全 10 研究: 研究ごとの感度と特異度
d <- madad(pct, correction.control = "single")
print(d, digits = 2)

# 主解析: カットオフ 0.5 ng/mL の 6 研究
pct5 <- subset(pct, cutoff == 0.5)

# 二項 GLMM 用の縦長データ。1 研究を 2 行にする
to_long <- function(d) rbind(
  data.frame(study = d$study, sens = 1, spec = 0,
             y = d$TP, n = d$TP + d$FN),
  data.frame(study = d$study, sens = 0, spec = 1,
             y = d$TN, n = d$TN + d$FP))
long5 <- to_long(pct5)

# 二変量モデル（相関を推定する）
g2 <- glmer(cbind(y, n - y) ~ 0 + sens + spec +
              (0 + sens + spec | study),
            data = long5, family = binomial)
summary(g2)    # 相関が -1 になり、singular の警告が出る

# 相関を 0 にしたモデル（ハンドブック 10.6.2）
g <- glmer(cbind(y, n - y) ~ 0 + sens + spec +
             (0 + sens | study) + (0 + spec | study),
```

```
          data = long5, family = binomial)
summary(g)

# 要約点と 95% 信頼区間
b <- fixef(g)
V <- as.matrix(vcov(g))
se_b <- sqrt(diag(V))
plogis(cbind(est = b, lower = b - 1.96 * se_b,
             upper = b + 1.96 * se_b))

# 尤度比と診断オッズ比（要約点から導く）
se <- unname(plogis(b["sens"]))
sp <- unname(plogis(b["spec"]))
c(LRpos = se / (1 - sp), LRneg = (1 - se) / sp,
  DOR = (se / (1 - se)) / ((1 - sp) / sp))

# 参考：正規近似の二変量モデル（mada）
summary(reitsma(pct5))

# 要約点、95% 信頼領域、95% 予測領域の図
ellipse_roc <- function(mu, S, n = 200) {
  r <- sqrt(qchisq(0.95, 2))
  th <- seq(0, 2 * pi, length.out = n)
  e <- t(mu + r * t(chol(S)) %*% rbind(cos(th), sin(th)))
  data.frame(fpr = plogis(e[, 2]), sens = plogis(e[, 1]))
}
vc <- VarCorr(g)
S_btw <- diag(c(attr(vc[[1]], "stddev")^2,
                attr(vc[[2]], "stddev")^2))
mu <- c(b["sens"], -b["spec"])   # logit 感度、logit 偽陽性割合
V_m <- matrix(c(V[1, 1], -V[1, 2], -V[1, 2], V[2, 2]), 2)
conf <- ellipse_roc(mu, V_m)
pred <- ellipse_roc(mu, S_btw + V_m)
cairo_pdf("fig_summary05.pdf", width = 5, height = 5)
plot(NA, xlim = c(0, 1), ylim = c(0, 1),
     xlab = "1 - 特異度（偽陽性割合）", ylab = "感度")
abline(0, 1, lty = 3)
polygon(pred$fpr, pred$sens, border = "grey50", lty = 2)
polygon(conf$fpr, conf$sens, border = "black")
points(fpr(pct5), sens(pct5), pch = 21)
points(1 - sp, se, pch = 23, bg = "red", cex = 1.5)
dev.off()
```

```
# 全 10 研究: SROC 曲線（曲線だけを描き、要約点は使わない）
fit_all <- reitsma(pct)
summary(fit_all)
cairo_pdf("fig_sroc.pdf", width = 5, height = 5)
plot(NA, xlim = c(0, 1), ylim = c(0, 1),
     xlab = "1 - 特異度（偽陽性割合）", ylab = "感度")
abline(0, 1, lty = 3)
lines(sroc(fit_all), lwd = 2)
points(fpr(pct), sens(pct), pch = 21)
dev.off()

# 共変量: log(カットオフ)（第 14 章）
pct$lcut <- log(pct$cutoff)
summary(reitsma(pct,
  formula = cbind(tsens, tfpr) ~ lcut))

# 実データ: AUDIT-C
data("AuditC")
summary(reitsma(AuditC))
ac <- as.data.frame(AuditC)
ac$study <- seq_len(nrow(ac))
ga <- glmer(cbind(y, n - y) ~ 0 + sens + spec +
              (0 + sens + spec | study),
            data = to_long(ac), family = binomial)
summary(ga)
plogis(fixef(ga))
```

A.9 動かなかったときに確かめること

3 本のスクリプトは、R 4.5.3、meta 8.5-0、metafor 5.2-1、mada 0.5.12、lme4 2.0.6 の組み合わせで最後まで実行できることを確かめています。パッケージの版が変わると、出力の見た目や小数の末尾が変わることがあります。数値が本文と大きく違うときは、まず `010_make_data.R`（A.6 節 (p. 196)）を実行し直してデータを作り直し、次に `sessionInfo()` でパッケージの版を確かめます。本文と同じ数値が出ることを確かめてから自分

のデータに置き換えると、エラーの原因がデータにあるのかコードにあるのかを切り分けられます。ファイルが読み込めないときの確認は A.5 節（p. 195）と 5.5 節（p. 49）に、singular の警告が出るときの読み方は 13.3 節（p. 148）に書いてあります。

付録 B

用語集

この章で分かること

本文で使った用語を、英語の用語、日本語の用語、ギリシア文字と記号の 3 つの節に分けて並べます。英語の用語は ABC 順、日本語の用語は 50 音順です。各項目の末尾に、主に説明した節とそのページを示します。

B.1 英語の用語

見出し語の横の小さな字は、読み方の目安です。略語には、単語のように読むものと、1 文字ずつ読むものがあります。人名は原語に近い読みを当てたもので、日本語の文献では別の読み方をされることがあります。

A

AUC （エーユーシー） Area Under the Curve（曲線下面積）の略で、ROC 曲線や SROC 曲線の下の面積です。1 に近いほど、疾患のある人とない人を全体としてよく分けられることを示します。特定のカットオフ

での性能は表しません。(9.5 節（p. 100)、13.8 節（p. 156))

AUDIT-C （オーディット・シー） Alcohol Use Disorders Identification Test の短縮版で、飲酒の問題を見つけるための 3 問の質問票です。第 2 部で、14 本の研究からなる実データの例題に使います。(13.9 節（p. 158))

B

Baujat プロット （ボジャ） 各試験を、異質性（Q）への寄与を横軸、その試験を除いて統合し直したときの統合結果の動きを縦軸にとって、1 点として置く図です。異質性の原因を探すための図で、外れた試験を解析から除く根拠にはなりません。(6.2 節（p. 60))

BCG （ビーシージー） Bacille Calmette-Guérin の略で、結核を予防するワクチンです。第 1 部の実データの例題に、BCG ワクチンの 13 本のランダム化比較試験を使います。(6.5 節（p. 67))

C

CENTRAL （セントラル） Cochrane Central Register of Controlled Trials の略で、Cochrane が集めた比較試験の登録簿です。他のデータベースから抽出した試験や、学会抄録の試験も含まれます。(3.1 節（p. 27))

CI （シーアイ） confidence interval の略で、信頼区間のことです。(1.1 節（p. 13))

ClinicalTrials.gov （クリニカルトライアルズ・ドット・ガブ） 米国の試験登録のデータベースです。結果が論文にならなかった試験も見つかるので、出版バイアスを小さくするために検索します。(3.1 節（p. 27)、7.5 節（p. 77))

Cochrane （コクラン） 系統的レビューの作成を支援する国際的な組織です。介入のレビューの手引きである Cochrane ハンドブックと、検査の精度のレビューの手引きである Cochrane DTA ハンドブックを出して

おり、本書でたびたび引用します。(3.3 節（p. 29)、10.6 節（p. 114))

Core GRADE （コア・グレード） GRADE を簡略にして使いやすくした手引きです。本書では、非一貫性と不精確さの判断で引用します。(7.8 節（p. 80))

CRAN （クラン） The Comprehensive R Archive Network の略で、R 本体とパッケージの配布元です。(A.1 節（p. 192))

CRP （シーアールピー） C 反応性蛋白（C-reactive protein）です。第 2 部の例題で、PCT と精度を比べる検査として出てきます。(14.6 節（p. 173))

CSV （シーエスブイ） comma-separated values の略で、項目をカンマで区切って並べたテキストの形式です。取り出したデータを保存して R に読み込むために使います。(4.4 節（p. 40))

CV （シーブイ） coefficient of variation（変動係数）の略で、測定のぶれの相対的な大きさです。第 5 章では、CV の小さい測定ほど信用するという精度管理の感覚を、重みの付け方の説明に使います。(5.1.3 節（p. 43))

D

Deeks の検定 （ディークス） 検査のメタ解析で小規模研究効果を調べる検定です。有効な標本の大きさと診断オッズ比の関係を見ます。診断オッズ比に研究間の異質性があると検出力がとくに低く、有意でなくても出版バイアスがないとは言えません。(10.8 節（p. 116)、15.2.3 節（p. 185))

DerSimonian-Laird 法（DL 法） （ダーシモニアン・レアード） ランダム効果モデルで τ^2 を推定する、古くからの方法です。多くのソフトの既定値でしたが、試験数が少ないと τ^2 を小さく見積もりやすいことが知られています。(5.7.1 節（p. 52))

diagmeta （ダイアグメタ） 1 つの研究が複数のカットオフで報告した感度

と特異度をすべて使い、カットオフごとの感度と特異度と、カットオフをまたぐ曲線を推定する R のパッケージです。Steinhauser らの方法を実装しています。本書では名前の紹介にとどめます。(14.4 節 (p. 169))

DOR (ディーオーアール) diagnostic odds ratio の略で、診断オッズ比のことです。(9.4 節 (p. 98))

DTA (ディーティーエー) diagnostic test accuracy (診断精度) の略です。Cochrane DTA ハンドブックや PRISMA-DTA の名前に入っています。(9.7 節 (p. 105)、10.6 節 (p. 114))

E

Egger 検定 (エッガー) ファネルプロットの非対称を調べる回帰の検定です。介入のメタ解析で使い、試験数が少ないと検出力が低くなります。オッズ比のときは Harbord の検定や Peters の検定を使います。検査のメタ解析では使わず、Deeks の検定を使います。(7.3 節 (p. 74))

Embase (エンベース) Excerpta Medica dataBASE の略で、欧州の雑誌や、薬剤に関する雑誌の収録が厚い有料のデータベースです。MEDLINE と重複しない論文がかなり含まれます。(3.1 節 (p. 27))

F

FN (エフエヌ) false negative の略で、偽陰性です。2×2 表で、疾患があるのに検査が陰性になった人の数です。(9.1 節 (p. 95))

FP (エフピー) false positive の略で、偽陽性です。2×2 表で、疾患がないのに検査が陽性になった人の数です。(9.1 節 (p. 95))

G

GitHub （ギットハブ） プログラムやデータを公開するための Web サービスです。解析のコードを公開する場所の例として出てきます。（8.4 節（p. 90））

glmer （ジーエルエムイーアール） lme4 パッケージの関数で、一般化線形混合モデルを当てはめます。本書では、二変量モデルを二項分布のまま当てはめるために使います。MetaDTA も内部で使っています。（13.3 節（p. 148））

GLMM （ジーエルエムエム） generalized linear mixed model の略で、一般化線形混合モデルのことです。（13.3 節（p. 148））

GRADE （グレード） Grading of Recommendations, Assessment, Development and Evaluation の略で、エビデンスの確実性を判定し、推奨の強さを決める枠組みです。バイアスのリスク、非一貫性、非直接性、不精確さ、出版バイアスの 5 つの要因で確実性を下げます。（7.8 節（p. 80）、15.2 節（p. 184））

H

Harbord 検定、Peters 検定 （ハーボード、ピーターズ） 効果指標がオッズ比のときに、ファネルプロットの非対称を調べる検定です。Cochrane ハンドブックは、オッズ比では Egger 検定の代わりにこれらを使うよう勧めています。（7.3 節（p. 74））

HKSJ 法 （エイチケーエスジェイ） Hartung、Knapp、Sidik、Jonkman（ハルトゥング、クナップ、シディク、ヨンクマン）の名前をとった方法です。ランダム効果モデルの信頼区間を、研究間分散の推定の不確かさも含めて計算し直す方法で、Hartung-Knapp 調整とも呼ばれます。たいていは区間が広がりますが、試験が 2、3 本のときは広すぎ、τ^2 が 0 と推定されたときは狭すぎることがあるため、試験数が少ないとき

は通常の方法と比べる感度分析を勧められています。(5.7 節（p. 52)、5.7.1 節（p. 52))

HSROC モデル （エイチエスアールオーシー） hierarchical summary receiver operating characteristic の略で、Rutter と Gatsonis が提案した、検査の精度を曲線として要約する階層モデルです。共変量がなければ二変量モデルと同じモデルの別の表し方になります（Harbord 2007)。(10.5 節（p. 113))

I

I^2 （アイ二乗） 効果のばらつきのうち、偶然では説明できない部分が占める割合です。割合なので、ばらつきの大きさそのものは表しません。検査のメタ解析では値が大きくなりやすく、使いにくい指標です。(6.1 節（p. 58)、10.7 節（p. 115))

ICTRP （アイシーティーアールピー） International Clinical Trials Registry Platform の略で、WHO の試験登録のデータベースです。(3.1 節（p. 27))

ICU （アイシーユー） intensive care unit（集中治療室）の略です。第 2 部の例題で、救急外来の患者と ICU の重症患者とでは対象が違い、有病割合が違うことの例に出てきます。(9.3 節（p. 97)、14.1 節（p. 161))

ITT （アイティーティー） intention-to-treat の略です。割り付けた全員を、割り付けた群のまま解析する方法で、効果の推定には ITT 解析の数を使うのが原則です。(4.2 節（p. 35))

J

jRCT （ジェイアールシーティー） Japan Registry of Clinical Trials の略で、臨床研究の計画を登録する日本のデータベースです。(3.1 節（p. 27)、7.5 節（p. 77))

L

L'Abbé プロット （ラベ） 各試験の 2 つの群の発症割合そのものを、1 試験を 1 点として置く図です。横軸にプラセボ群、縦軸に介入群の発症割合をとります。(5.9 節（p. 55))

lme4 （エルエムイーフォー） 一般化線形混合モデルの glmer() を提供する R のパッケージです。(13.3 節（p. 148)、A.4 節（p. 194))

logit （ロジット） 割合 p を、p を 1 − p で割った値の対数に変換したものです。0 から 1 の範囲の割合を、数直線全体に広げます。二変量モデルは感度と特異度をこの尺度で扱います。(10.3 節（p. 110))

M

mada （マダ） 検査のメタ解析を行う R のパッケージです。二変量モデルの reitsma() と、SROC 曲線の図を担います。(13.1 節（p. 141)、A.4 節（p. 194))

Mantel-Haenszel 法（MH 法） （マンテル・ヘンツェル） 固定効果モデルの統合に使う方法です。事象の少ない試験が多いときに逆分散法より安定し、RevMan の既定値でもあります。meta パッケージの metabin では、method = ”MH” と指定すると使えます。ランダム効果モデルは逆分散法のままです。(5.6 節（p. 50))

MD （エムディー） mean difference の略で、平均差のことです。(5.2 節（p. 44))

MECIR （エムイーシーアイアール） Methodological Expectations of Cochrane Intervention Reviews の略で、Cochrane が介入のレビューに求める方法の基準です。(3.3 節（p. 29))

MEDLINE （メドライン） 米国国立医学図書館のデータベースで、PubMed から無料で使えます。医学の主要な雑誌はほぼ収録されています。(3.1 節（p. 27))

MeSH （メッシュ） Medical Subject Headings の略で、MEDLINE が論文に付けている統制語です。たとえば Hypertension という MeSH を指定すると、論文の中で high blood pressure と書かれていても拾えます。（3.2 節（p. 28））

meta （メタ） 介入のメタ解析を行う R のパッケージです。フォレストプロットとファネルプロットもこのパッケージで描きます。（5.6 節（p. 50）、A.4 節（p. 194））

metadat （メタダット） metafor と一緒に入る、メタ解析の例題データを収めた R のパッケージです。BCG ワクチンの実データ（dat.bcg）が入っています。（6.5 節（p. 67））

MetaDTA （メタディーティーエー） 診断精度のメタ解析を R のコードを書かずに行える、無料の Web ツールです。内部で glmer() を使い、2×2 表の CSV ファイルを読み込ませると要約点と SROC 曲線が出ます。Cochrane の DTA ハンドブックの執筆時点（2.0 版）では、共変量を入れる解析はできませんでした。（13.4 節（p. 150））

metafor （メタフォー） メタ回帰に使う R のパッケージです。（6.5 節（p. 67）、A.4 節（p. 194））

Moses-Littenberg 法 （モーゼス・リッテンバーグ） 研究ごとの診断オッズ比の対数を、感度と偽陽性割合から作った閾値の代わりの量に回帰させて、SROC 曲線を描く方法です。古い検査のメタ解析で使われてきました。簡便ですが、研究間のばらつきを組み込まない固定効果の方法で、二変量モデルと HSROC モデルが取って代わりました。（10.2 節（p. 109））

O

OR （オーアール） odds ratio の略で、オッズ比のことです。検索式では、どちらかの語を含む文献を拾う論理演算子の OR も出てきます。（3.2 節（p. 28）、5.2 節（p. 44））

OSF （オーエスエフ） Open Science Framework の略で、データや解析のコードを公開できる Web サービスです。(8.4 節（p. 90))

P

p 値 （ピーち） 差がないと仮定したときに、観察された差かそれ以上の差が、偶然だけで生じる確率です。論文には、点推定に信頼区間を添えて書き、p 値だけを書くことはしません。(6.1 節（p. 58)、8.3 節（p. 89))

Paule-Mandel 法 （ポール・マンデル） τ^2 の推定法の一つです。REML とともに、現在勧められることが多い方法です。(5.7.1 節（p. 52))

PCT （ピーシーティー） procalcitonin（プロカルシトニン）の略で、細菌感染で上がる血液の検査項目です。第 2 部の例題で、菌血症を見分ける対象検査に使います。(9.1 節（p. 95))

Peto 法 （ピート） 各試験で観察された事象数と、群の差がないと仮定したときに期待される事象数との差から、オッズ比を直接求める方法です。連続補正が要らないので、事象が 0 件の群があっても使えますが、オッズ比にしか使えません。事象がまれなときの方法の一つです。(5.6 節（p. 50))

PICO （ピコ） Patient（対象)、Intervention（介入)、Comparison（比較)、Outcome（アウトカム）の頭文字をとった、問いを書き下す型です。(2.1 節（p. 21))

PRISMA 2020 （プリズマ） Preferred Reporting Items for Systematic reviews and Meta-Analyses の略で、系統的レビューとメタ解析の報告指針です。27 項目のチェックリストとフロー図からなります。(8.1 節（p. 86)、3.5 節（p. 32))

PRISMA-DTA （プリズマ・ディーティーエー） 診断精度のレビューのための PRISMA の拡張版です。対象検査と参照基準、カットオフ、バイアスの評価、精度の統合方法の報告を求めます。(15.3 節（p. 188))

PRISMA-P （プリズマ・ピー） Preferred Reporting Items for Systematic review and Meta-Analysis Protocols の略で、レビューの計画書（プロトコル）に書く項目をまとめた書式です。(2.4 節（p. 24))

PRISMA-S （プリズマ・エス） 系統的レビューの文献検索の報告を詳しく書くための PRISMA 2020 の拡張版です。使った情報源、検索式、フィルターと制限、検索日などの書き方を定めています。(8.1 節（p. 86))

PROSPERO （プロスペロ） International Prospective Register of Systematic Reviews の略で、系統的レビューの計画書を登録する国際的なウェブサイトです。登録番号が付き、計画の内容と登録日が公開されます。(2.4 節（p. 24))

PubMed （パブメド） MEDLINE を無料で検索できる Web サービスです。(3.1 節（p. 27))

Q

Q 統計量 （キュー） 各試験の推定値が統合した値からどれだけ離れているかを、重みを付けて 2 乗して足した値です。試験の結果のばらつきが偶然だけなら、Q はおおよそ自由度（試験数 − 1）くらいの値になります。Q を使った異質性の検定があり、降圧薬 A では Q = 18.30、p 値は 0.032 でした。(6.1 節（p. 58))

QUADAS-2、QUADAS-3 （クワダス） Quality Assessment of Diagnostic Accuracy Studies の略で、診断精度研究のバイアスのリスクと適用可能性を評価する道具です。QUADAS-2 は 4 つの領域（患者選択、対象検査、参照基準、フローとタイミング）で判定します。2026 年に改訂版の QUADAS-3 が公表されました。(12.4 節（p. 130)、12.9 節（p. 138))

QUADAS-C （クワダス・シー） 検査どうしを比べる研究のバイアスのリスクを評価する道具です。QUADAS-2 と同じ 4 つの領域に、全員が両方の検査を受けたか、一方の検査の判定者が他方の結果を知らなかった

かといった、比較に特有の質問を加えています。(14.6 節（p. 173))

R

R （アール） 統計解析のための無料のソフトウェアです。CRAN から入手します。(A.1 節（p. 192))

R^2 （アール二乗） メタ回帰で、試験間の真の効果のばらつき τ^2 のうち、説明に使った変数で説明できた部分の割合です。第 6 章の例では、緯度で 76% を説明できました。(6.5 節（p. 67))

Rayyan （ライヤン） 題名と抄録の選別に使える、専用のツールの一つです。(3.3 節（p. 29))

RCT （アールシーティー） randomized controlled trial の略で、ランダム化比較試験です。参加者をくじ引きのような方法で 2 つの群に分け、一方に調べたい薬剤を、もう一方にプラセボを投与して、その後の経過を比べる研究です。(1.1 節（p. 13))

RD （アールディー） risk difference の略で、リスク差のことです。(5.2 節（p. 44))

Reitsma （ライツマ） 二変量モデルを 2005 年に提案した研究者の名前です。mada の reitsma() 関数の名前の由来でもあります。元の方法は、研究ごとの logit 感度と logit 偽陽性割合を正規分布で近似するので、人数の少ない研究では近似が悪くなります。(10.4 節（p. 111)、10.4.1 節（p. 111))

REML （アールイーエムエル、レムル） restricted maximum likelihood の略で、制限付き最尤法です。ランダム効果モデルの τ^2 の推定法の一つで、meta パッケージの既定値です。本書の例題でも使います。(5.7 節（p. 52))

RevMan （レブマン） Cochrane が系統的レビューの作成に使うソフトウェアです。(5.6 節（p. 50))

RoB 2 （ロブ・ツー） revised Cochrane risk-of-bias tool for randomized trials

の略で、ランダム化比較試験のバイアスのリスクを評価する道具です。5 つの領域を判定し、全体を「低」「懸念あり」「高」にまとめます。(4.3 節 (p. 37))

ROB-ME (ロブ・エムイー) Risk Of Bias due to Missing Evidence の略で、系統的レビューで、結果が欠けていること (研究の中の未報告の結果と、研究の間の未発表の試験) によるバイアスのリスクを評価する道具です。ファネルプロットや検定が調べる小規模研究効果とは別に、欠けた理由が結果に左右されていないかを構造的に判定します。(7.4 節 (p. 75))

ROBINS-I (ロビンス・アイ) Risk Of Bias In Non-randomised Studies of Interventions の略で、非ランダム化研究のバイアスのリスクを評価する道具です。交絡や対象者の選び方による偏りを、仮想的なランダム化試験と比べる形で判定します。(4.3 節 (p. 37))

ROC 曲線 (アールオーシー) receiver operating characteristic (受信者操作特性) の曲線で、カットオフを動かしたときの感度と偽陽性割合の組を、縦軸に感度、横軸に偽陽性割合をとって結んだものです。曲線の下の面積が AUC です。(9.5 節 (p. 100))

RR (アールアール) risk ratio の略で、リスク比のことです。(5.2 節 (p. 44))

RStudio (アールスタジオ) R を使いやすくするための画面で、スクリプトの編集、実行、結果の表示、図の表示を 1 つの窓にまとめます。(5.5 節 (p. 49)、A.1 節 (p. 192))

S

SD (エスディー) standard deviation の略で、標準偏差です。測定値のばらつきの大きさを表し、分散は SD を 2 乗した値です。(5.1.1 節 (p. 43))

SMD (エスエムディー) standardized mean difference の略で、標準化平均

差のことです。(5.2 節（p. 44))

SROC 曲線 （エスアールオーシー） summary ROC curve の略で、複数の研究の精度を、1 本の ROC 曲線として要約したものです。カットオフが混ざった研究も含めた全研究で曲線を描き、曲線上の 1 点を要約点として報告しません。観測された偽陽性割合の範囲の外まで延ばして読むこともしません。(10.6 節（p. 114)、13.8 節（p. 156))

STARD 2015 （スタード） Standards for Reporting of Diagnostic Accuracy の略で、個々の診断精度研究を報告するときの指針です（Bossuyt 2015)。研究を行う人が論文を書くときに使います。メタ解析の報告には使いません。(9.7 節（p. 105))

T

TN （ティーエヌ） true negative の略で、真陰性です。2×2 表で、疾患がなく検査も陰性になった人の数です。(9.1 節（p. 95))

TP （ティーピー） true positive の略で、真陽性です。2×2 表で、疾患があり検査も陽性になった人の数です。(9.1 節（p. 95))

trim and fill （トリムアンドフィル） ファネルプロットが左右対称になるように、欠けているとみなした研究を補って統合し直す方法です。論文ではよく見かけますが、強い仮定に立つため、現行の Cochrane ハンドブックでは扱っていません。補った値を補正後の効果として読まないようにします。(7.4 節（p. 75))

W

WHO （ダブリューエイチオー） World Health Organization（世界保健機関）の略です。試験登録の ICTRP を運営しています。(3.1 節（p. 27))

B.2
日本語の用語

日本語の用語は、読みの 50 音順に並べています。論文を読むときの手がかりとして、英語の綴りを添えたものがあります。

あ行

閾値効果（threshold effect）　研究ごとにカットオフや測り方が違うために、感度と特異度が逆向きに動く現象です。ROC 平面の上で、研究の点が右上から左下へ並ぶ形で現れます。（10.1 節（p. 107））

異質性（heterogeneity）　研究どうしの真の効果や真の精度が、偶然を超えて違っていることです。対象、介入や検査の方法、研究の質の違いが原因になります。（6.1 節（p. 58）、14.1 節（p. 161））

一般化線形混合モデル（generalized linear mixed model, GLMM）　研究内の数を二項分布のまま扱い、研究間のばらつきをランダム効果として加えるモデルです。検査のメタ解析では、二変量モデルをこの形で当てはめる方法を Cochrane のハンドブックが勧めています。R では lme4 パッケージの glmer で計算します。（13.3 節（p. 148））

陰性的中割合（negative predictive value）　検査が陰性になった人のうち、本当に疾患のない人の割合です。一般には陰性的中率とも呼ばれます。有病割合が高いほど下がります。（9.3 節（p. 97）、15.1.2 節（p. 180））

オッズ比（odds ratio, OR）　2 群のオッズの比です。事象が多いとリスク比から離れるので、解釈には注意が要ります。（5.2 節（p. 44））

か行

確実性（certainty of evidence）　推定値が真の値に近いと信頼できる程度です。GRADE で、高、中、低、非常に低の 4 段階に判定します。（7.8 節（p. 80）、15.2 節（p. 184））

カットオフ（cutoff）　検査値を陽性と陰性に分ける境の値です。基準範囲とは目的が違い、標的疾患の有無を分けるために決めます。カットオフを上げると感度が下がり、特異度が上がります。（9.5 節（p. 100）、14.2 節（p. 163））

感度（sensitivity）　疾患のある人のうち、検査が陽性になる人の割合です。（9.2 節（p. 96））

感度分析（sensitivity analysis）　解析の選び方を変えても結論が保たれるかを確かめる解析です。検査の感度とは関係のない言葉です。（7.6 節（p. 77））

共変量（covariate）　研究ごとの特徴（場面、カットオフ、測定法など）のうち、精度のばらつきを説明するためにモデルに入れる変数です。研究間の比較なので、観察研究と同じ限界があります。（14.2 節（p. 163））

逆分散法（inverse variance method）　各研究の推定値に、分散の逆数を重みとして掛けて平均する方法です。精度の高い研究ほど重みが大きくなります。（5.3 節（p. 45））

偽陽性割合（false positive proportion）　疾患のない人のうち、検査が陽性になる人の割合で、1 から特異度を引いた値です。SROC 曲線の横軸になります。（9.2 節（p. 96））

組み入れ基準、除外基準（inclusion criteria, exclusion criteria）　どの研究をレビューに含めるかを、計画の段階で決めておく条件です。（2.3 節（p. 23））

系統的レビュー（systematic review）　問いを先に決め、決めた方法で漏れなく研究を集め、評価し、まとめる研究です。メタ解析はその中で

数値を統合する部分です。システマティックレビューとも呼ばれます。(1.5 節（p. 19))

研究間分散 τ^2（between-study variance） ランダム効果モデルで、研究ごとの真の効果が散らばる程度を表す分散です。I^2 と違い、効果の尺度での大きさを表します。(5.4 節（p. 46)、6.1 節（p. 58))

検査レビューバイアス（test review bias） 対象検査を判定する人が、参照基準の結果を知っている偏りです。目視で判定する検査のように、判定に主観が入る検査で問題になります。(12.5 節（p. 131))

個人データのメタ解析（individual participant data meta-analysis） 試験ごとの集計値ではなく、参加者一人ひとりのデータを集めて統合する方法です。本書では扱いません。(8.6 節（p. 92))

固定効果モデル（common effect model） すべての研究が同じ一つの真の効果を推定していると考えるモデルです。meta パッケージは common と表示します。(5.4 節（p. 46))

さ行

差異的検証バイアス（differential verification bias） 対象検査の結果によって、使う参照基準が変わる偏りです。精度が高く出る方向に動くことが多くなります。(12.5 節（p. 131))

サブグループ解析（subgroup analysis） 研究を特徴で群に分け、群ごとの統合結果を比べる解析です。研究間の比較なので、事前に決めておくことと、試験数が少ないときに控えることが求められます。(6.4 節(p. 64))

参照基準（reference standard） 標的疾患の有無を決めるために用いる、最も確かな方法です。PCT の例では血液培養にあたります。(11.1 節(p. 118))

出版バイアス（publication bias） 結果が有意な研究ほど発表されやすいために、集めた研究が偏ることです。(7.1 節（p. 72))

小規模研究効果（small-study effects）　小さい研究ほど効果が大きく出る傾向です。出版バイアスのほか、小さい研究の質の低さや対象の違いでも生じます。（7.1 節（p. 72））

抄録の選別（title/abstract screening）　検索で得た文献を、題名と抄録を読んで組み入れの候補に絞る作業です。検査のスクリーニングと紛れないよう、本書では選別と呼びます。（3.3 節（p. 29）、11.3 節（p. 121））

診断オッズ比（diagnostic odds ratio, DOR）　陽性尤度比を陰性尤度比で割った値です。感度と特異度を一つの数に集約するので、どちらが優れているのかが分からなくなります。（9.4 節（p. 98）、13.5 節（p. 151））

診断レビューバイアス（diagnostic review bias）　参照基準を判定する人が、対象検査の結果を知っている偏りです。精度が高く出る方向に動くことが多くなります。（12.5 節（p. 131））

信頼区間（confidence interval）　推定値の不確かさを表す範囲です。本書では 95% 信頼区間を使います。（1.1 節（p. 13））

信頼領域（confidence region）　二変量モデルで、要約点の不確かさを表す楕円の範囲です。95% 信頼領域を使います。（13.6 節（p. 153））

スペクトラムバイアス（spectrum bias）　重症の患者と健常者を比べるような研究で、臨床の場面より精度が高く出る偏りです。症例対照デザインで起こりやすくなります。（12.5 節（p. 131））

潜在クラスモデル（latent class model）　参照基準が不完全なときに、真の疾患の有無を直接は観測できない潜在変数とみなして、感度、特異度、有病割合を推定するモデルです。Cochrane の DTA ハンドブックに紹介がありますが、本書では扱いません。（11.1 節（p. 118））

■ た行

対象検査（index test）　レビューで精度を評価する検査です。PCT の例では PCT にあたります。（11.1 節（p. 118））

直接比較（head-to-head comparison）　同じ患者で 2 つの検査を両方測った研究による比較です。別々の研究どうしを比べる間接比較より、対象の違いによる偏りが入りにくくなります。（14.6 節（p. 173））

データ抽出（data extraction）　組み入れた研究から、研究の特徴と結果の数を決めた様式に書き写す作業です。2 人が独立に行います。（4.1 節（p. 34）、12.1 節（p. 127））

データを見てから決めたカットオフ　同じデータで最適なカットオフを選ぶことです。その研究の偶然のばらつきに合う位置が選ばれるので、精度が高く出ます。QUADAS-2 では対象検査の領域を高と判定します。（12.5 節（p. 131）、14.5 節（p. 170））

特異度（specificity）　疾患のない人のうち、検査が陰性になる人の割合です。（9.2 節（p. 96））

取り込みバイアス（incorporation bias）　対象検査の結果が、参照基準の判定の一部に組み込まれている偏りです。精度が高く出ると考えられますが、その大きさを実証した証拠は乏しいとされています。（12.5 節（p. 131））

な行

二変量モデル（bivariate model）　logit 感度と logit 特異度を、2 次元の正規分布として同時にモデル化する方法です。Reitsma らが提案しました。要約点と、その信頼領域と予測領域を出せます。（10.4 節（p. 111）、13.3 節（p. 148））

ネットワークメタ解析（network meta-analysis）　3 つ以上の介入を、直接比べた試験と間接的な比較を組み合わせて一度に比べる方法です。本書では扱いません。（8.6 節（p. 92））

は行

バイアスのリスク（risk of bias）　研究の方法の欠陥のために、結果が真の値からずれている恐れです。介入では RoB 2、検査では QUADAS-2 で評価します。（4.3 節（p. 37）、12.4 節（p. 130））

標準化平均差（standardized mean difference, SMD）　平均差を標準偏差で割った値です。研究ごとに測定の尺度が違うときに使います。（5.2 節（p. 44））

標的疾患（target condition）　検査で見つけたい疾患や状態です。PCT の例では菌血症にあたります。（11.1 節（p. 118））

ファネルプロット（funnel plot）　横軸に効果、縦軸に精度（標準誤差など）をとり、研究を点で示す図です。小さい研究が片側に偏ると、小規模研究効果を疑います。（7.2 節（p. 73））

フォレストプロット（forest plot）　研究ごとの推定値と信頼区間を四角と線で、統合した結果を菱形で示す図です。（5.8 節（p. 54）、13.1.1 節（p. 143））

不適切な除外（inappropriate exclusion）　判定の難しい患者や、境界域の値の患者を解析から除く偏りです。精度が高く出ると考えられます。（12.5 節（p. 131））

部分的検証バイアス（partial verification bias）　一部の人だけが参照基準を受ける偏りです。検査陽性の人ほど参照基準で確かめられやすいと、感度が高く、特異度が低く出ます。（12.5 節（p. 131）、14.5 節（p. 170））

プロトコル（protocol）　レビューの問い、方法、解析の計画を、検索を始める前に書いた文書です。PROSPERO に登録し、後から解析を選ぶことによる偏りを防ぎます。（2.4 節（p. 24））

平均差（mean difference, MD）　連続量のアウトカムで、2 群の平均の差です。（5.2 節（p. 44））

ま行

メタ回帰（meta-regression）　研究の特徴を説明変数にして、効果の大きさとの関係を回帰で調べる方法です。研究数が少ないと見かけの関連が出やすくなります。（6.5 節（p. 67））

メタ解析（meta-analysis）　複数の研究の結果を統計的に統合する方法です。（1.3 節（p. 16））

や行

尤度比（likelihood ratio）　疾患のある人で検査が陽性（陰性）になる割合を、疾患のない人で同じ結果になる割合で割った値です。陽性尤度比は感度を偽陽性割合で割り、陰性尤度比は 1 から感度を引いた値を特異度で割って求めます。（9.4 節（p. 98）、13.5 節（p. 151））

有病割合（prevalence）　対象者のうち、標的疾患をもつ人の割合です。時間の分母をもたないので、率ではなく割合と呼びます。（9.3 節（p. 97）、15.1 節（p. 177））

陽性的中割合（positive predictive value）　検査が陽性になった人のうち、本当に疾患のある人の割合です。一般には陽性的中率とも呼ばれます。有病割合が低いほど下がります。（9.3 節（p. 97）、15.1.2 節（p. 180））

要約点（summary point）　二変量モデルで推定した、感度と特異度の平均の組です。ROC 平面の上の 1 点で示します。カットオフが混ざった研究からは出さず、同じカットオフの研究だけで出します。（10.4 節（p. 111）、13.5 節（p. 151））

予測区間（prediction interval）　次に行う研究の真の効果が入りそうな範囲です。研究間のばらつきを含むので、信頼区間より広くなります。（6.3 節（p. 62））

予測領域（prediction region）　二変量モデルで、次の研究の感度と特異度の組が入りそうな範囲を表す楕円です。95% 予測領域を使います。

（13.6 節（p. 153））

ら行

ランダム効果モデル（random effects model）　研究ごとの真の効果が分布をもつと考え、その平均を推定するモデルです。固定効果モデルより小さい研究の重みが相対的に大きくなります。（5.4 節（p. 46））

リスク比（risk ratio, RR）　2 群のリスク（事象が起きた人の割合）の比です。（5.2 節（p. 44））

リビングシステマティックレビュー（living systematic review）　新しい証拠が出るたびに取り込んで、更新し続ける系統的レビューです。本書では扱いません。（8.6 節（p. 92））

連続補正（continuity correction）　2×2 表に 0 のセルがあると対数がとれないので、すべてのセルに 0.5 などを足す処理です。mada の reitsma は 0.5 を足します。（5.6 節（p. 50）、13.1 節（p. 141））

B.3 ギリシア文字と記号

本文の式や説明に出てくる文字と記号です。ギリシア文字には大文字と小文字があり、数式では別の意味で使い分けます。見出し語の横の小さな字は、読み方です。

τ （タウ）　ギリシア文字の小文字で、アルファベットの t にあたります。本書では、真の効果が試験ごとに散らばる程度の標準偏差を表し、降圧薬 A では $\tau = 0.18$（対数リスク比の尺度）でした。メタ解析では、研究間の標準偏差を τ で表すのが慣例です。ほかの場面では、順位相関の Kendall の τ にも使います。（5.4 節（p. 46）、6.1 節（p. 58））

τ^2（タウ二乗）　τ を 2 乗した値で、研究間分散のことです。本書では、ランダム効果モデルの重みに足す量として、また異質性の指標として出てきます。推定には REML などを使い、降圧薬 A では $\tau^2 = 0.034$ でした。統計では、分散を標準偏差の 2 乗として書くのが一般的で、研究の中のばらつきには σ^2 や v を使い、研究の間のばらつきを τ^2 と書き分けることが多くなります。（5.4 節（p. 46）、6.1 節（p. 58））

κ（カッパ）　ギリシア文字の小文字で、アルファベットの k にあたります。本書では、2 人の判定がどれだけ一致したかを表す κ 係数に出てきます。偶然の一致を差し引いた一致の度合いで、1 に近いほどよく一致していることを表します。検査では、判定者どうしの一致の度合いを示すときによく使います。（3.3 節（p. 29）、11.3 節（p. 121））

Σ（シグマ）　ギリシア文字の大文字で、本書では Q 統計量の式に、全試験を足すという記号として出てきます。統計では、合計を表すのに使います。同じ文字の小文字 σ は別の意味をもち、母集団の標準偏差を表すのによく使います。標本から計算した標準偏差には s を使うことが多く、本書の式には σ は出てきません。（6.1 節（p. 58））

±（プラスマイナス）　値の前後に幅をつけて示す記号です。本書では、平均の対数 $\pm 1.96\ \tau$ という中央 95% の範囲の式と、相関が ±1 に張り付くという説明に出てきます。統計では、平均 ± SD のように、ばらつきや誤差の幅を表す形でよく使います。± のあとの数が SD か標準誤差か信頼区間の半分の幅かは論文によって違うので、書き方を確かめてから読みます。（6.3.1 節（p. 63）、13.4 節（p. 150））

×（かける）　掛け算の記号です。本書では、2×2 表の「2 行 2 列」の意味でも使います。2×2 表は、疾患の有無と検査の陽性、陰性を組み合わせた 4 つのマスの表です。（4.2 節（p. 35）、9.1 節（p. 95））

÷（わる）　割り算の記号です。I^2 を（Q − 自由度）÷ Q で求める式などに出てきます。（6.1 節（p. 58））

≈（ほぼ等しい）　左右の値がほぼ等しいことを表す記号です。計算結果を丸めた値を書くときに使います。（14.2 節（p. 163））

2 （2 乗）　右肩に付く 2 は、2 乗を表します。τ^2 は τ を 2 乗した値で、分散は標準偏差の 2 乗です。I^2 と R^2 の 2 は名前の一部で、I や R を 2 乗して求める値ではありません。（5.4 節（p. 46）、6.1 節（p. 58））

$\bar{y}$ （ワイバー）　文字の上に付けた横線（バー）は、平均を表すのによく使います。本書では、各試験の推定値 y を統合した値を $\bar{y}$ と書きます。y と重み w の右下の i は、i 番目の試験を表す添字です。（6.1 節（p. 58））

付録 C

参考文献

この章で分かること

本文で著者と年で示した文献を、教科書、指針、方法論、ソフトウェア、例題の 5 つに分けて並べます。各群の中は著者名のアルファベット順です。

C.1 教科書

- Deeks JJ, Bossuyt PM, Leeflang MMG, Takwoingi Y (eds). Cochrane Handbook for Systematic Reviews of Diagnostic Test Accuracy. Version 2. Chichester: Wiley, 2023.
- Deeks JJ, Higgins JPT, Altman DG. Chapter 10: Analysing data and undertaking meta-analyses. In: Higgins JPT, et al (eds). Cochrane Handbook for Systematic Reviews of Interventions. Version 6.0. Cochrane, 2019.
- Higgins JPT, Thomas J, et al (eds). Cochrane Handbook for Systematic Reviews of Interventions. Version 6.5. Cochrane, 2024. training.cochrane.org/handbook

- Macaskill P, et al. Chapter 9: Understanding meta-analysis. In: Deeks JJ, et al (eds). Cochrane Handbook for Systematic Reviews of Diagnostic Test Accuracy. Version 2.0. Cochrane, 2023.
- Takwoingi Y, et al. Chapter 10: Undertaking meta-analysis. In: Deeks JJ, et al (eds). Cochrane Handbook for Systematic Reviews of Diagnostic Test Accuracy. Version 2.0. Cochrane, 2023.

介入のハンドブックは第 1 部の全体に対応します。Deeks 2019 は介入のハンドブックの第 10 章で、予測領域の推定が研究数の少ないときに不安定になる点の出典として、本書の第 10 章が引いています。診断精度（DTA）のハンドブックでは、Macaskill 2023（第 9 章）がメタ解析の考え方、Takwoingi 2023（第 10 章）がその実際を扱っており、本書の第 2 部はこの 2 つの章を背景にしています。Takwoingi 2023 は同じ例題を SAS、Stata、R の 3 つで解いているので、本書の第 13 章のコードと読み比べると、ソフトウェアが違っても同じモデルを当てはめていることが確かめられます。

C.2
指針

報告の指針、バイアスのリスクの評価の道具、確実性の判定の枠組みを集めます。

- Bossuyt PM, et al. STARD 2015: an updated list of essential items for reporting diagnostic accuracy studies. BMJ 2015;351:h5527.
- Cohen JF, et al. Preferred reporting items for journal and conference abstracts of systematic reviews and meta-analyses of diagnostic test accuracy studies (PRISMA-DTA for Abstracts): checklist, explanation, and elaboration. BMJ 2021;372:n265.
- Guyatt GH, et al. GRADE: an emerging consensus on rating quality

of evidence and strength of recommendations. BMJ 2008;336(7650):924-926.

- Guyatt GH, et al. Core GRADE 2: choosing the target of certainty rating and assessing imprecision. BMJ 2025;389:e081904.
- Guyatt GH, et al. Core GRADE 3: rating certainty of evidence: assessing inconsistency. BMJ 2025;389:e081905.
- McInnes MDF, et al. Preferred Reporting Items for a Systematic Review and Meta-analysis of Diagnostic Test Accuracy Studies: the PRISMA-DTA statement. JAMA 2018;319(4):388-396.
- Moher D, et al. Preferred reporting items for systematic review and meta-analysis protocols (PRISMA-P) 2015 statement. Syst Rev 2015;4:1.
- Page MJ, et al. The PRISMA 2020 statement: an updated guideline for reporting systematic reviews. BMJ 2021;372:n71.
- Page MJ, et al. ROB-ME: a tool for assessing risk of bias due to missing evidence in systematic reviews with meta-analysis. BMJ 2023;383:e076754.
- Rethlefsen ML, et al. PRISMA-S: an extension to the PRISMA statement for reporting literature searches in systematic reviews. Syst Rev 2021;10:39.
- Schünemann HJ, et al. GRADE guidelines: 21 part 1. Study design, risk of bias, and indirectness in rating the certainty across a body of evidence for test accuracy. J Clin Epidemiol 2020;122:129-141.
- Schünemann HJ, et al. GRADE guidelines: 21 part 2. Test accuracy: inconsistency, imprecision, publication bias, and other domains for rating the certainty of evidence and presenting it in evidence profiles and summary of findings tables. J Clin Epidemiol 2020;122:142-152.
- Sterne JAC, et al. ROBINS-I: a tool for assessing risk of bias in non-randomised studies of interventions. BMJ 2016;355:i4919.
- Sterne JAC, et al. RoB 2: a revised tool for assessing risk of bias in

randomised trials. BMJ 2019;366:l4898.
- Whiting PF, et al. QUADAS-2: a revised tool for the quality assessment of diagnostic accuracy studies. Ann Intern Med 2011;155(8):529-536.
- Whiting PF, et al. QUADAS-3: a revised tool for the quality assessment of diagnostic test accuracy studies. Ann Intern Med 2026;179(4):548-555. doi:10.7326/ANNALS-25-02104
- Yang B, et al. QUADAS-C: a tool for assessing risk of bias in comparative diagnostic accuracy studies. Ann Intern Med 2021;174(11):1592-1599.

C.3
方法論

- Bradburn MJ, Deeks JJ, Berlin JA, Russell Localio A. Much ado about nothing: a comparison of the performance of meta-analytical methods with rare events. Stat Med 2007;26(1):53-77.
- Chu H, Cole SR. Bivariate meta-analysis of sensitivity and specificity with sparse data: a generalized linear mixed model approach. J Clin Epidemiol 2006;59(12):1331-1332.
- Deeks JJ, Macaskill P, Irwig L. The performance of tests of publication bias and other sample size effects in systematic reviews of diagnostic test accuracy was assessed. J Clin Epidemiol 2005;58(9):882-893.
- DerSimonian R, Laird N. Meta-analysis in clinical trials. Control Clin Trials 1986;7(3):177-188.
- Egger M, et al. Bias in meta-analysis detected by a simple, graphical test. BMJ 1997;315(7109):629-634.
- Harbord RM, et al. A unification of models for meta-analysis of diagnostic accuracy studies. Biostatistics 2007;8(2):239-251.
- Hartung J, Knapp G. A refined method for the meta-analysis of controlled

clinical trials with binary outcome. Stat Med 2001;20(24):3875-3889.

- Higgins JPT, Thompson SG. Quantifying heterogeneity in a meta-analysis. Stat Med 2002;21(11):1539-1558.
- Higgins JPT, Thompson SG, Deeks JJ, Altman DG. Measuring inconsistency in meta-analyses. BMJ 2003;327(7414):557-560.
- IntHout J, Ioannidis JPA, Borm GF. The Hartung-Knapp-Sidik-Jonkman method for random effects meta-analysis is straightforward and considerably outperforms the standard DerSimonian-Laird method. BMC Med Res Methodol 2014;14:25.
- IntHout J, Ioannidis JPA, Rovers MM, Goeman JJ. Plea for routinely presenting prediction intervals in meta-analysis. BMJ Open 2016;6(7):e010247.
- Jones HE, et al. Quantifying how diagnostic test accuracy depends on threshold in a meta-analysis. Stat Med 2019;38(24):4789-4803.
- Leeflang MMG, et al. Variation of a test's sensitivity and specificity with disease prevalence. CMAJ 2013;185(11):E537-E544.
- Lijmer JG, et al. Empirical evidence of design-related bias in studies of diagnostic tests. JAMA 1999;282(11):1061-1066.
- Reitsma JB, et al. Bivariate analysis of sensitivity and specificity produces informative summary measures in diagnostic reviews. J Clin Epidemiol 2005;58(10):982-990.
- Riley RD, Higgins JPT, Deeks JJ. Interpretation of random effects meta-analyses. BMJ 2011;342:d549.
- Rutjes AW, et al. Evidence of bias and variation in diagnostic accuracy studies. CMAJ 2006;174(4):469-476.
- Rutter CM, Gatsonis CA. A hierarchical regression approach to meta-analysis of diagnostic test accuracy evaluations. Stat Med 2001;20(19):2865-2884.
- Sidik K, Jonkman JN. A simple confidence interval for meta-analysis.

Stat Med 2002;21(21):3153-3159.

- Steinhauser S, et al. Modelling multiple thresholds in meta-analysis of diagnostic test accuracy studies. BMC Med Res Methodol 2016;16:97.
- Sterne JAC, et al. Recommendations for examining and interpreting funnel plot asymmetry in meta-analyses of randomised controlled trials. BMJ 2011;343:d4002.
- Whiting P, et al. Sources of variation and bias in studies of diagnostic accuracy: a systematic review. Ann Intern Med 2004;140(3):189-202.
- Zwinderman AH, Bossuyt PM. We should not pool diagnostic likelihood ratios in systematic reviews. Stat Med 2008;27(5):687-697.

C.4 ソフトウェア

- Balduzzi S, Rücker G, Schwarzer G. How to perform a meta-analysis with R: a practical tutorial. Evid Based Ment Health 2019;22(4):153-160.
- Doebler P, Sousa-Pinto B. mada: Meta-Analysis of Diagnostic Accuracy. R package version 0.5.12, 2025.
- Viechtbauer W. Conducting meta-analyses in R with the metafor package. J Stat Softw 2010;36(3):1-48.

C.5 例題

本書で用いた実データと、第 14 章で読み比べた論文です。

- Colditz GA, et al. Efficacy of BCG vaccine in the prevention of tubercu-

losis. Meta-analysis of the published literature. JAMA 1994;271(9):698-702.

- Kriston L, et al. Meta-analysis: are 3 questions enough to detect unhealthy alcohol use? Ann Intern Med 2008;149(12):879-888.
- Tang BM, et al. Accuracy of procalcitonin for sepsis diagnosis in critically ill patients: systematic review and meta-analysis. Lancet Infect Dis 2007;7(3):210-217.
- Wacker C, et al. Procalcitonin as a diagnostic marker for sepsis: a systematic review and meta-analysis. Lancet Infect Dis 2013;13(5):426-435.